

UNIVERSITÉ DU QUÉBEC À MONTRÉAL

ÉVALUATION EMPIRIQUE D'ACTIFS CANADIENS PAR L'APPRENTISSAGE
AUTOMATIQUE

MÉMOIRE

PRÉSENTÉ

COMME EXIGENCE PARTIELLE

DE LA MAÎTRISE EN ÉCONOMIQUE

PAR

GUILLAUME VAUDESCAL

DÉCEMBRE 2024

REMERCIEMENTS

Ce mémoire fut une aventure mémorable avec ses hauts et ses bas, me poussant hors de ma zone de confort et me permettant de développer grandement mes compétences de recherche.

Je tiens à remercier en premier lieu mes directeurs de recherche, Philippe Goulet Coulombe et Dalibor Stevanovic. Philippe, merci de m'avoir prodigué tes précieux conseils tout au long de ma rédaction et tes recommandations avisées, ce mémoire ne serait pas ce qu'il est sans toi. Dalibor, merci pour ta patience, le soutien financier et tout ce que tu apportes à ce département d'économie, nous permettant à nous étudiant, d'évoluer dans un cadre enrichissant et dynamique.

Je tiens également à remercier ma famille. Mes parents qui m'ont toujours soutenu malgré les difficultés. Mon petit frère, Maxens, mon concertiste et compositeur préféré. Et bien évidemment, mon frère jumeau, Thomas, qui sait déjà de ce que je pense de lui et qu'une section de remerciement ne suffirait pas pour exprimer toute ma gratitude.

Enfin, je n'oublie mes amis qui se reconnaîtront, qui m'ont toujours soutenu de près ou de loin.

TABLE DES MATIÈRES

REMERCIEMENTS	ii
LISTE DES FIGURES	vi
LISTE DES TABLEAUX	vii
RÉSUMÉ	viii
INTRODUCTION.....	1
CHAPITRE 1 REVUE DE LITTÉRATURE	7
1.1 Prédiction de rendements d'actifs financiers avec des algorithmes d'apprentissage machine ..	7
1.2 Construction de portefeuilles avec des stratégies longues et courtes à partir des prévisions d'algorithmes d'apprentissage machine.....	9
CHAPITRE 2 DONNÉES	12
2.1 Données macroéconomiques	12
2.1.1 Données macroéconomiques canadiennes	12
2.1.2 Données macroéconomiques américaines.....	13
2.2 Données financières	13
2.2.1 Données financières canadiennes	13
2.2.2 Données financières américaines.....	14
2.3 Transformation des données	14
2.4 Échantillons d'entraînement et de test	16
CHAPITRE 3 MÉTHODOLOGIE	18
3.1 Algorithmes pour la prédiction de rendements d'actions.....	18
3.1.1 Algorithmes de régression pour la prédiction des rendements d'actions.....	19
3.1.1.1 Ridge	19
3.1.1.2 XGBoost	20

3.1.1.3	Ada Boost	21
3.1.1.4	Extra Trees.....	22
3.1.2	Algorithmes de classification pour la prédiction des rendements d’actions	23
3.1.2.1	Régression logistique	23
3.1.2.2	XGBoost Classification	24
3.1.2.3	Hist Gradient Boosting Classification	26
3.1.2.4	Extra Trees Classification.....	26
3.2	Portefeuilles suivant une stratégie longue-courte	27
3.2.1	Stratégie de portefeuille longue-courte, top 10	28
3.2.2	Stratégie de portefeuille longue-courte, top 20	29
3.2.3	Stratégie de portefeuille longue-courte, positive et négative	29
3.3	Validation rétrospective	30
3.4	Critères de références	31
3.5	Métriques de mesures de performances pour les algorithmes de régressions	32
3.5.1	Coefficient de détermination hors-échantillon	32
3.5.2	Taux de croissance annuel composé	33
3.5.3	Ratio de Sharpe.....	33
3.5.4	Ratio de Sortino	34
3.5.5	Perte maximale	34
3.5.6	Ratio Oméga	34
3.6	Métriques de mesure de performance pour les algorithmes de classification	35
3.6.1	Score de précision.....	35
3.6.2	Statistique du test de Pesaran-Timmerman	36
3.7	Explication de l’importance des variables avec SHAP	36
CHAPITRE 4 RÉSULTATS		39
4.1	Résultats des algorithmes de régression en hors-échantillon	39
4.2	Résultats des algorithmes de classification en hors-échantillon.....	45
4.3	Importance des variables (SHAP).....	49

CONCLUSION 52

ANNEXE A RÉSULTATS COMPLÉMENTAIRES RÉGRESSIONS 54

ANNEXE B RÉSULTATS COMPLÉMENTAIRES CLASSIFICATIONS 60

ANNEXE C RÉSULTATS COMPLÉMENTAIRES SHAP 63

APPENDICE I LISTE DES ACTIONS 67

APPENDICE II LISTE DES VARIABLES 69

APPENDICE III HYPERPARAMÈTRES 79

BIBLIOGRAPHIE 85

LISTE DES FIGURES

Figure	Page
4.1 Rendements cumulatifs au Canada et aux États-Unis, stratégies de portefeuilles longues-courtes 10, 20 et ≥ 0 , 2008-01 à 2024-01 (régression)	43
4.2 Rendements cumulatifs au Canada et aux États-Unis, stratégie de portefeuille longue-courte ≥ 0 , 2008-01 à 2024-01 (classification)	47
4.3 SHAP importance des variables, 2008-01 à 2024-01	50
A.1 Rendements cumulatifs au Canada et aux États-Unis, stratégies de portefeuilles longues-courtes 10, 20 et ≥ 0 , 2008-01 à 2012-01 (régression)	55
A.2 Rendements cumulatifs au Canada et aux États-Unis, stratégies de portefeuilles longues-courtes 10, 20 et ≥ 0 , 2012-01 à 2020-01 (régression)	57
A.3 Rendements cumulatifs au Canada et aux États-Unis, stratégies de portefeuilles longues-courtes 10, 20 et ≥ 0 , 2020-01 à 2024-01 (régression)	59
B.1 Rendements cumulatifs au Canada et aux États-Unis, stratégie de portefeuille longue-courte ≥ 0 , 2008-01 à 2012-01 (classification)	60
B.2 Rendements cumulatifs au Canada et aux États-Unis, stratégie de portefeuille longue-courte 10, 20 et ≥ 0 , 2012-01 à 2020-01 (classification)	61
B.3 Rendements cumulatifs au Canada et aux États-Unis, stratégie de portefeuille longue-courte 10, 20 et ≥ 0 , 2020-01 à 2024-01 (classification)	62
C.1 SHAP importance des variables, 2008-01 à 2012-01	64
C.2 SHAP importance des variables, 2012-01 à 2020-01	65
C.3 SHAP importance des variables, 2008-01 à 2012-01	66

LISTE DES TABLEAUX

Tableau	Page
4.1 Résumé statistique des prédictions mensuelles, 2008-01 à 2024-01 (régression)	40
4.2 Résumé statistique des prédictions mensuelles, 2008-01 à 2024-01 (classification)	45
A.1 Résumé statistique des prédictions mensuelles, 2008-01 à 2012-01 (régression)	54
A.2 Résumé statistique des prédictions mensuelles, 2012-01 à 2020-01 (régression)	56
A.3 Résumé statistique des prédictions mensuelles, 2020-01 à 2024-01 (régression)	58
B.1 Résumé statistique des prédictions mensuelles, 2008-01 à 2012-01 (classification)	59
B.2 Résumé statistique des prédictions mensuelles, 2012-01 à 2020-01 (classification)	60
B.3 Résumé statistique des prédictions mensuelles, 2020-01 à 2024-01 (classification)	61
I.1 Liste des actions canadiennes avec leurs tickers associé	67
I.2 Liste des actions américaines avec leurs tickers associé	68
II.1 Données macroéconomiques LCDMA	70
II.2 Données macroéconomiques FRED-MD	75
III.1 Hyperparamètres des modèles de régressions	79
III.2 Hyperparamètres des modèles de classifications	82

RÉSUMÉ

Ce mémoire a pour objectif d'évaluer diverses techniques d'apprentissage machine de régression et de classification à l'exercice de la prédiction de rendements d'actions au Canada et aux États-Unis. Plus précisément, pour les modèles de régressions, nous utilisons le modèle Ridge, Ada Boost, XGBoost, et Extra Trees et pour les modèles de classification, nous utilisons le modèle Régression Logistique, XGBoost Classification, Hist Gradient Boosting Classification et Extra Trees Classification. À partir de ces prédictions, nous bâtissons des portefeuilles suivant une stratégie longue-courte avec divers signaux (top 10, top 20 ainsi que positif et négatif) que nous comparons à des critères de références, comme un portefeuille suivant une stratégie longue également pondérée, le TSX60, le S&P500 ou encore le NASDAQ. L'analyse a été réalisée sur plusieurs périodes à savoir 2008-01 à 2024-01, 2008-01 à 2024-01, 2008-01 à 2012-01, 2012-01 à 2020-01 et 2020-01 à 2024-01, à une fréquence mensuelle. Nous exploitons, pour le Canada et les États-Unis, des données macroéconomiques en fréquence mensuelle provenant de la base de données LCDMA et de la *Federal Reserve of Economic Data* (FRED), ainsi que 50 actions provenant du *Toronto Stock Exchange* (TSX60) et 50 actions provenant du S&P500. Nos résultats révèlent que la grande majorité de nos modèles d'apprentissage machine, indépendamment du territoire et des signaux utilisés, surperforment nos critères de références selon nos métriques d'évaluation. De plus, nous relevons que les modèles d'apprentissage machine non-linéaire possèdent de meilleures performances prédictives en hors-échantillon que les modèles linéaires, bien que cela ne résulte pas toujours en de meilleures performances économiques. Enfin, nous présentons une interprétation de nos modèles à l'aide de la méthodologie de SHAP, afin de comprendre l'importance relative de nos variables dans les prédictions.

Mots clés : Apprentissage machine, Prédiction, Stratégies longue-courte, Gestion de portefeuille, Finance quantitative, Canada, États-Unis.

INTRODUCTION

La prédiction de rendements d'actifs financiers et la construction de portefeuilles sont un enjeu important pour les fonds d'investissement, les banques ou encore les chercheurs universitaires. Ce mémoire vise à contribuer sur ce sujet en explorant l'utilisation de données financières et macroéconomiques canadiennes pour prédire les rendements d'actifs canadiens en s'appuyant sur des algorithmes d'apprentissage machine de régression et de classification et de savoir si ces données aident à prévoir les rendements. À partir de ces prédictions, des portefeuilles seront construits en utilisant différents signaux dans le cadre d'une stratégie longue-courte. Enfin, une étude comparative avec le marché américain sera menée en appliquant la même méthodologie, dans le but d'enrichir le cadre d'analyse en mettant en évidence les similitudes et différences entre ces deux marchés.

L'évolution de la théorie moderne de portefeuille depuis la seconde moitié du 19^{ème} siècle, a constitué un moteur clé du développement de la finance moderne, en introduisant des concepts novateurs pour la gestion du risque et du rendement. De Harry Markowitz aux méthodes d'apprentissage machine actuelles, chaque étape de cette évolution a été caractérisée par des innovations notables, souvent motivées par les limites des modèles précédents.

L'origine de la théorie moderne du portefeuille remonte à 1952 avec les travaux d'Harry Markowitz. Dans son article fondateur, « *Portfolio Selection* », Markowitz (1952) introduit l'idée selon laquelle les investisseurs ne devraient pas évaluer les actifs de manière isolée, mais dans un cadre de portefeuille global. Plus précisément, il montre que le risque d'un portefeuille ne dépend pas seulement des risques individuels des actifs qui le composent, mais aussi de la manière dont ces actifs sont corrélés les uns avec les autres. Le modèle de Markowitz, appelé modèle de moyenne-variance, repose sur deux mesures. La première est la moyenne des rendements espérés (comme indicateur du rendement) et la deuxième est la variance (comme indicateur du risque). Sa principale innovation réside dans la mise en lumière de la diversification. En ce sens, en combinant des actifs faiblement corrélés, il est possible de réduire le risque global du portefeuille sans nécessairement diminuer son rendement espéré. Cette découverte a introduit la notion de « frontière efficiente », qui définit l'ensemble des portefeuilles offrant le meilleur rendement possible pour un niveau de

risque donné. Cependant, la théorie de Markowitz s'appuie sur des hypothèses parfois contraignantes, notamment l'hypothèse selon laquelle les rendements suivent une distribution normale, et celle qui considère la variance comme une mesure exhaustive du risque. Or, cette approche ne prend pas en compte certaines propriétés importantes des distributions de rendement, comme l'asymétrie (*skewness*) et l'« aplatissement » (*kurtosis*), qui se manifestent souvent lors de crises financières. Ces limitations ont ainsi ouvert la voie à des extensions et des critiques dans la littérature ultérieure.

Au cours des années 1960, les travaux de William Sharpe (1964), John Lintner (1965) et Jan Mossin (1966) ont abouti au *Capital Asset Pricing Model* (CAPM), considéré comme une prolongation naturelle du cadre conceptuel de Markowitz. Ce modèle opère une simplification importante en mettant l'accent sur le risque systématique ou « risque de marché », c'est-à-dire la part de risque qui ne peut être éliminé par la diversification. Contrairement à Markowitz, qui s'intéresse à la composition globale du portefeuille, le CAPM analyse la relation entre le risque d'un actif donné et celui du marché dans son ensemble. Il introduit également la notion de bêta, qui traduit la sensibilité d'un actif aux variations du marché. D'après le CAPM, le rendement attendu d'un actif se limite essentiellement à sa prime de risque, proportionnelle à son bêta. Cette avancée a marqué un tournant en gestion de portefeuille, car elle clarifie le lien entre le risque et le rendement prévu, tout en fournissant un cadre relativement simple pour évaluer les actifs. Malgré son importance, le CAPM a vite montré ses limites. Des études empiriques ont en effet mis en évidence que d'autres facteurs, outre le bêta du marché, influencent les rendements. Par exemple, la recherche a mis en évidence que les petites entreprises et les titres dits « *value* » (faible ratio cours/valeur comptable) obtiennent régulièrement des performances supérieures à celles des grandes entreprises et des actions de croissance, un phénomène que le CAPM ne parvient pas à expliquer, comme l'ont souligné Banz (1981) ou Fama et French (1992). C'est notamment ce constat qui a favorisé l'émergence de modèles plus avancés, capables de prendre en compte plusieurs facteurs pour mieux rendre compte de la diversité des rendements boursiers.

En réponse aux limites du CAPM, Eugene Fama et Kenneth French (1993) ont développé en 1993 un modèle à trois facteurs. Ce modèle, au-delà du bêta de marché, inclut deux autres facteurs

empiriquement fondés, la taille de l'entreprise et la valeur. En ce sens, le facteur de taille capture la tendance des petites entreprises à générer des rendements plus élevés, tandis que le facteur de valeur reflète la surperformance des actions sous-évaluées par rapport aux actions de croissance. Plus tard, Fama et French (2015) ont étendu leur modèle en introduisant deux nouveaux facteurs, la rentabilité et l'investissement. Plus précisément, la rentabilité capture la tendance des entreprises à forte rentabilité à obtenir des rendements plus élevés, tandis que le facteur d'investissement explique que les entreprises ayant des niveaux d'investissement plus faibles ont tendance à mieux performer. Ce modèle à cinq facteurs représente aujourd'hui une avancée significative par rapport au CAPM et demeure une référence dans la littérature académique. Ces modèles multifactoriels, malgré leur succès, posent encore des questions sur le choix des facteurs et leur robustesse à travers les différentes périodes et marchés. En ce sens, Harvey et al. (2016) mentionnent que les facteurs peuvent être sensibles à l'échantillonnage ou aux périodes spécifiques et qu'ils ne sont pas nécessairement stables dans le temps.

La théorie de l'arbitrage (*Arbitrage Pricing Theory*, APT), introduite par Stephen Ross (1976), offre une alternative flexible au CAPM. Contrairement au CAPM, qui repose sur un seul facteur de marché, l'APT propose que les rendements des actifs puissent être expliqués par plusieurs facteurs macroéconomiques. Ces facteurs peuvent inclure des variables telles que l'inflation, la croissance économique ou des chocs sectoriels. L'APT a l'avantage de ne pas restreindre la modélisation à un seul facteur, mais elle ne fournit pas non plus de cadre précis pour identifier les facteurs pertinents, ce qui laisse aux chercheurs et aux gestionnaires de portefeuille la tâche d'estimer ces facteurs de manière empirique. En conséquence, l'APT est souvent critiquée pour son manque de clarté dans la sélection des facteurs, ce qui rend l'application pratique plus complexe que celle du CAPM.

Parallèlement aux développements des théories en gestion de portefeuilles, l'hypothèse des marchés efficients (EMH) a dominé la finance académique pendant des décennies. Formulée par Eugene Fama (1970), l'EMH affirme que les prix des actifs intègrent pleinement toutes les informations disponibles. En ce sens, d'après cette théorie, un investisseur ne peut surpasser systématiquement le marché, car toute nouvelle information est instantanément prise en compte dans les prix. Cependant, au fil du temps, l'EMH a été remise en cause par des études montrant que les investisseurs ne sont pas toujours rationnels, et que les marchés ne réagissent pas

instantanément aux nouvelles informations. Les travaux de Daniel Kahneman et Amos Tversky (1979) sur la théorie des perspectives (*prospect theory*) ont montré que les décisions des investisseurs sont souvent influencées par des biais cognitifs et émotionnels, comme l'aversion à la perte ou l'excès de confiance. Ces recherches ont donné naissance à la finance comportementale, champ d'expertise de Shiller (2003) notamment, qui tente d'expliquer les anomalies de marché observées, telles que les bulles spéculatives ou les krachs.

L'évolution la plus récente dans la théorie de portefeuille provient de l'avènement des technologies de l'information et des techniques de gestion de grands ensembles de données (*big data*) et d'apprentissage machine (*machine learning*). Ces outils, qui permettent de traiter des volumes massifs de données et de modéliser des relations non-linéaires, ouvrent de nouvelles perspectives pour la prédiction des rendements et la gestion des portefeuilles. Contrairement aux modèles traditionnels basés sur des hypothèses paramétriques rigides, les algorithmes d'apprentissage machine, tels que les réseaux de neurones profonds (*deep learning*) ou l'apprentissage par renforcement (*reinforcement learning*), apprennent à partir des données elles-mêmes, sans nécessiter de connaissances préalables sur les relations entre les variables. Ces techniques permettent non seulement de prédire les rendements à partir de vastes ensembles de données, mais aussi de concevoir des portefeuilles dynamiques et adaptatifs, capables de s'ajuster en temps réel aux conditions changeantes du marché.

Selon Gu et al. (2018) l'apprentissage machine dans l'évaluation empirique des rendements d'actifs pourrait être défini selon les trois caractéristiques suivantes ; Premièrement, une collection diversifiée de modèles à haute dimension pour la prédiction statistique. Deuxièmement, cela est combiné avec des méthodes dites de régularisation pour la sélection de modèles et l'atténuation du surapprentissage (*overfit*). Troisièmement, des algorithmes efficaces pour la recherche parmi un grand nombre de spécifications de modèles potentiels.

De nombreux modèles d'apprentissage machine ont alors vu le jour dans la littérature, captant significativement mieux les non-linéarités, et possédant de meilleures performances que les modèles dits linéaires. On peut citer certains modèles d'apprentissage machine, tel que les réseaux neuronaux, les machines à vecteur de support (SVM), ou encore les arbres de décisions comme utilisés par Ballings et al. (2015) dans leur étude.

C'est dans ce contexte que la littérature s'est récemment tournée vers l'application de l'apprentissage machine pour la construction de portefeuilles, notamment à travers des stratégies longues et courtes (*long-short*). En effet, ces stratégies consistent à exploiter simultanément des positions longues (achat d'actifs dont le prix est anticipé à la hausse) et des positions courtes (vente d'actifs dont le prix est anticipé à la baisse). Cette approche permet de maximiser le rendement tout en minimisant l'exposition au risque de marché, en misant sur la performance relative entre actifs surévalués et sous-évalués selon les prédictions des modèles d'apprentissage machine. En ce sens, plusieurs études, comme celle de Goulet Coulombe et Göbel (2023), ont notamment montré que les modèles d'apprentissage machine permettent une meilleure sélection des actifs à inclure dans les positions longues ou courtes que les techniques traditionnelles, améliorant ainsi la performance globale des portefeuilles.

Cependant, le recours à l'intelligence artificielle en gestion de portefeuille soulève des enjeux importants, notamment en matière de transparence et d'explicabilité. En effet, les modèles d'apprentissage machine sont souvent qualifiés de "boîtes noires", car il est difficile d'expliquer clairement comment ces modèles arrivent à leurs décisions. Comme l'indique Lòpez de Prado (2018), cette opacité peut générer des problèmes de confiance et de régulation quant à leur utilisation.

Dans ce mémoire, nous nous attellerons de répondre à la question suivante : « Dans quelle mesure l'utilisation d'algorithmes d'apprentissage machine linéaire et non-linéaire de régression et de classification permet-elle de prédire les rendements d'actifs financiers canadiens, et quelles sont les performances de ces portefeuilles construits à partir de ces prédictions, suivant des stratégies longues et courtes avec différents signaux en comparant avec le marché américain ? ».

En vue de répondre à cette question, plusieurs algorithmes d'apprentissage machine de régression et de classification seront utilisés dans notre étude à savoir : Ridge, XGBoost, Ada Boost et Extra Trees pour les algorithmes de régression et Régression logistique, XGBoost Classification, Hist Gradient Boosting Classification ainsi qu'Extra Trees Classification pour les algorithmes de classification. Puis, à partir de ces prédictions, nous construisons des portefeuilles suivant des stratégies longues et courtes en fonction de différents signaux (top 10, top 20 ainsi que positif et négatif). Une analyse de l'importance des variables prédictives macroéconomiques sera également

réalisée afin de rajouter un volet d'explicabilité à notre étude en utilisant la méthode de SHAP (*SHapley Additive exPlanations*). Nous exploitons d'une part des données des données d'indicateurs macroéconomiques canadiens (LCDMA ; *Large Canadian Database for Macroeconomic Analysis*) et d'autre part des données de séries chronologiques financières canadiennes provenant du *Toronto stock exchange* (TSX). Pour le marché américain, nous utilisons des données macroéconomiques provenant de la *Federal Reserve of Economic Data* (FRED) et des données de séries chronologiques financières américaines provenant du *Standard & Poor's* (SP).

L'objectif sera de construire des portefeuilles suivant des stratégies longues et courtes en fonction de différents signaux à l'aide des prédictions des modèles à chaque période en hors-échantillon en fréquence mensuelle sur les périodes 2008-01 à 2024-01, 2008-01 à 2012-01, 2012-01 à 2020-01 et de 2020-01 à 2024-01. Puis nous comparerons ces dernières en fonction des différentes métriques retenues pour le marché canadien et américain. En ce sens, il sera utilisé comme métriques de performance hors-échantillon pour les algorithmes de régression, le R^2 hors-échantillon, le taux de croissance annuel composé (TCAC), le ratio de Sharpe, le ratio de Sortino et le ratio Oméga. Pour les métriques des algorithmes de classification en hors-échantillon, cela sera le score de précision, la statistique du test de Pesaran-Timmermann, le TCAC, le ratio de Sharpe, le ratio de Sortino et le ratio Oméga.

Le présent mémoire sera divisé de la manière suivante. Le premier chapitre présentera une revue de littérature des méthodes de prévisions de séries chronologiques financières avec des algorithmes d'apprentissage machine et de la construction de portefeuilles avec des stratégies longues et courtes à partir des prédictions des modèles. Le deuxième chapitre sera consacré à la présentation des données macroéconomiques et financières, et de comment les données sont transformées en vue d'entraîner les modèles. Par la suite, le troisième chapitre explicitera la méthodologie et les modèles utilisés. Enfin, le quatrième chapitre sera consacré aux résultats obtenus.

CHAPITRE 1

REVUE DE LITTÉRATURE

Dans ce chapitre, nous réalisons une revue de la littérature en deux parties. La première concernant la littérature de l'utilisation de techniques d'apprentissage machine pour la prévision des rendements financiers, et la deuxième pour la constitution de portefeuilles avec des stratégies longues et courtes à partir de ces prédictions.

1.1 Prévision de rendements d'actifs financiers avec des algorithmes d'apprentissage machine

L'utilisation de l'apprentissage machine appliquée au problème de la prédiction des rendements de séries chronologiques financières est un sujet en croissance ces dernières années dans la littérature (bien que l'utilisation de données macroéconomiques pour la prédiction d'actifs au Canada reste relativement peu étudiée). En effet, les chercheurs constatent que les algorithmes d'apprentissage machine permettent d'améliorer significativement les prévisions de séries chronologiques de rendements d'actifs, comparativement aux méthodes de prévision traditionnelles.

Avramov et al. (2023) dans leur article, étudie l'efficacité des méthodes d'apprentissage machine comparativement à des méthodes économiques traditionnelles, comme les modèles de Fama-French, afin de prédire les rendements boursiers. Selon les résultats dans l'article, les signaux d'apprentissage machine montrent une forte capacité prédictive, mais leurs performances chutent avec l'exclusion des entreprises à petites capitalisations (*microcaps*) et des entreprises en difficulté, car ces modèles exploitent les inefficiences spécifiques de ces actions volatiles, qui génèrent des opportunités d'arbitrage. Malgré des coûts de transaction élevée dus à un turnover important et des positions extrêmes, ces modèles surpassent les approches traditionnelles, surtout en période de crise, en identifiant des actions sous-évaluées similaires aux anomalies de marché connues.

Dans l'article de Feng et al. (2020) "*Taming the Factor Zoo : A Test of New Factors*", ces derniers abordent le problème du "zoo des facteurs", où la prolifération de facteurs prédictifs en finance rend difficile la distinction entre ceux qui sont pertinents et ceux qui sont des coïncidences statistiques. Les auteurs proposent une méthode basée sur l'apprentissage machine, notamment le modèle lasso, pour sélectionner les facteurs les plus significatifs dans un cadre de haute

dimensionnalité. Après cette sélection, ils réalisent différents tests statistiques afin d'évaluer l'importance des facteurs tout en contrôlant le taux de fausses découvertes. Leurs résultats montrent que seule une fraction des facteurs identifiés dans la littérature reste significative une fois le risque de surajustement pris en compte.

Dans l'article "*Shrinking the Cross-Section*", Kozak, Nagel et Santosh (2020) proposent une nouvelle approche pour mieux capturer les variations de rendements attendus en construisant un facteur d'actualisation stochastique (*Stochastic Discount Factor*, SDF) à partir d'un grand nombre de prédicteurs basés sur des caractéristiques des actions. Contrairement aux modèles classiques (comme les trois, ou cinq facteurs de Fama-French) qui utilisent un nombre limité de facteurs, leur approche considère un ensemble large de facteurs potentiels tout en évitant le surajustement grâce à une technique de rétrécissement (*shrinkage*) bayésien. L'idée principale de leur méthode est de réduire l'influence des facteurs associés à une faible variance, qui sont souvent source de bruit, tout en conservant les contributions des composantes principales (CP) de haute variance. Cette approche bayésienne impose une pénalité de type L2 (similaire à une régularisation de type ridge), qui diminue les coefficients des facteurs non significatifs sans pour autant les réduire complètement à zéro, comme le ferait une pénalisation L1 stricte (lasso). Dans leurs résultats, les auteurs montrent que cette méthode, en s'appuyant sur un petit nombre de CP de haute variance, capture efficacement la dynamique des rendements boursiers dans un cadre à haute dimension, en surpassant les modèles à facteurs restreints traditionnels.

Clouâtre (2020) utilise différents réseaux de neurones (RNN, LSTM...) afin de prévoir les rendements de l'indice S&P/TSX, soit l'indice associé à la bourse de Toronto (Toronto Stock Exchange). La série temporelle du S&P/TSX exploitée depuis Bloomberg, s'étend sur la période du 2018-12-27 au 2019-07-10, avec des observations intrajournalières à intervalles de 15 minutes. Les régresseurs utilisés sont les séries temporelles du cours de l'USD/CAD, l'indice VIXC (qui représente la volatilité implicite du marché basée sur les options à 30 jours) ainsi que le TXGM (*TSX Global Mining Index*). Afin de comparer la qualité des prévisions entre les modèles, Clouâtre (2020) performe un test Dickey-Fuller augmenté. Ainsi, ce dernier observe que le meilleur modèle est le modèle RNN à trois couches composées de 100 neurones, qui utilise uniquement le premier retard de chaque variable comme régresseur.

Linck et Frota Decourt (2016) ont testé la relation entre certaines variables macroéconomiques et le prix des actions de l'indice Bovespa de 2000 à 2010 avec un modèle multifacteurs. Dans leurs résultats ils constatent que seuls les taux d'intérêt et la croissance économique (PIB) sont statistiquement significatifs. En utilisant seulement ces deux variables dans le modèle de régression, le R^2 a pu déterminer 11 % de la variation du prix des actions. En revanche, Linck et Frota Decourt (2016) soutiennent que pour améliorer le pouvoir explicatif du modèle, cela nécessiterait l'inclusion d'autres variables systémiques, telles que les taux de change ou les taux de chômage.

Enfin, il convient de souligner les défis que soulève l'utilisation de l'apprentissage machine dans un contexte de prévision, où les données sont abondantes et où les relations entre variables sont souvent complexes et non linéaires. Parmi ces enjeux figure notamment le surapprentissage, qui survient fréquemment dès lors que les modèles sont calibrés sur des jeux de données restreints ou qu'ils intègrent un grand nombre de variables prédictives, une situation décrite par Hastie et al. (2009) dans « *The Elements of Statistical Learning* ». Pour atténuer ces difficultés, on recourt généralement à des techniques de régularisation et de validation croisée. En effet, la régularisation limite le poids des variables les moins pertinentes, tandis que la validation croisée évalue le modèle sur des sous-échantillons indépendants, réduisant ainsi le risque de surapprentissage. Par ailleurs, l'explicabilité des algorithmes demeure un autre enjeu majeur, dans la mesure où ces derniers sont souvent qualifiés de « boîtes noires ». En réponse à cela, des approches comme SHAP (*Shapley Additive Explanations*), introduites par Lundberg et Lee (2017), ont été développées pour mettre en évidence l'apport individuel de chaque variable et mieux comprendre l'influence qu'elle exerce sur la prédiction.

1.2 Construction de portefeuilles avec des stratégies longues et courtes à partir des prévisions d'algorithmes d'apprentissage machine

La construction de portefeuilles avec des stratégies longues et courtes basée sur les prévisions d'apprentissage machine, consiste à prendre des positions longues sur les actifs dont les rendements futurs sont prévus comme étant élevés et des positions courtes sur ceux dont les rendements sont prévus comme étant faibles. Cette stratégie permet d'exploiter les signaux prédictifs générés par les modèles d'apprentissage machine, optimisant ainsi l'allocation des actifs pour maximiser les rendements attendus tout en répartissant les risques.

L'article de Gu et al. (2020) "*Empirical Asset Pricing via Machine Learning*", se penche sur l'application des techniques d'apprentissage machine à l'évaluation empirique des actifs financiers. Ils analysent dans leur article un vaste ensemble de données comprenant plus de 30 000 actions individuelles sur une période de 60 ans, de 1957 à 2016. De plus, chaque action est associée à 94 caractéristiques prédictives, incluant des variables fondamentales, techniques et macroéconomiques, portant le nombre total de prédicteurs à plus de 900. Pour gérer cette haute dimensionnalité, les auteurs utilisent des techniques de réduction de dimensionnalité telles que la régression sur composantes principales (PCR) et les moindres carrés partiels (PLS). Ils comparent également une variété de méthodes d'apprentissage machine, notamment Elastic Net, les arbres de décision, les méthodes de *boosting* comme XGBoost, et les réseaux de neurones profonds. Ils constatent que les méthodes non-linéaires, en particulier les forêts aléatoires et les réseaux de neurones, surpassent significativement les modèles linéaires en termes de performance prédictive hors-échantillon. Leurs résultats montrent que l'utilisation de l'apprentissage machine permet d'améliorer considérablement la mesure des primes de risque des actions. Enfin, dans la dernière partie de leur article, ils utilisent directement les prévisions de ces modèles à chaque période afin de constituer des portefeuilles suivant une stratégie longue-courte. Chaque mois, les actions sont classées en déciles en fonction des prévisions fournies par chaque modèle. Plus précisément, avec une pondération égale, une position longue est prise sur le décile contenant les actions aux rendements prévus les plus élevés (décile 10) et une position courte sur celles aux rendements prévus les plus faibles (décile 1). Les portefeuilles sont ensuite réajustés mensuellement et pondérés par la valeur des actifs.

Krauss et al. (2017) dans leur article, "*Deep Neural Networks, Gradient-Boosted Trees, Random Forests : Statistical Arbitrage on the S&P 500*", explorent l'efficacité des techniques d'apprentissage machine pour le trading statistique sur l'indice S&P 500. Ils utilisent trois algorithmes qu'ils combinent et sont ensuite agrégés selon différents types d'ensembles. En ce sens, les modèles employés par les auteurs sont les réseaux de neurones profonds, les forêts aléatoires et les arbres de décision boostés pour prédire les rendements quotidiens des actions entre 1992 et 2015. Leur stratégie consiste à générer des signaux de *trading* en classant les actions selon leur probabilité de surperformer le marché, les actions du haut du classement étant achetées (positions longues) et celles du bas vendu à découvert (positions courtes). Les principaux résultats indiquent

que leur stratégie d'arbitrage statistique, basée sur la combinaison des modèles appliqués aux actions du S&P 500 de 1992 à 2015, a généré des rendements annuels significatifs de 73 % après coûts de transaction, avec un ratio de Sharpe de 1,81, surpassant nettement les performances du marché. Ils soulignent également que les forêts aléatoires ont réalisé les meilleures performances parmi les modèles testés, et que l'agrégation des modèles en un ensemble égal-pondéré a encore amélioré les résultats. Toutefois, les auteurs remarquent que l'efficacité de la stratégie a diminué après 2001 en raison de la popularisation croissante des techniques d'apprentissage automatique.

Dans l'article « *Dissecting Characteristics Nonparametrically* », Freyberger et al. (2020) ont proposé une approche non paramétrique pour modéliser la relation entre les caractéristiques des actions et leurs rendements futurs. En ce sens, leur méthode permet de capturer les effets non-linéaires et les interactions complexes sans imposer de forme fonctionnelle spécifique. Les auteurs ont ainsi obtenu des performances supérieures comparativement aux régressions linéaires de panels, en appliquant des techniques d'apprentissage machine pour prédire les rendements et en construisant des portefeuilles suivant une stratégie longue-courte basée sur ces prédictions.

Chen et al. (2021) ont mis au point un modèle qui intègre l'apprentissage profond dans l'évaluation des actifs financiers. Concrètement, ils ont estimé le facteur d'actualisation stochastique (*Stochastic Discount Factor*) en intégrant directement les conditions d'absence d'arbitrage dans la structure même du modèle. En ce sens, en prédisant les rendements des actifs et en construisant des portefeuilles longues-courtes fondés sur ces facteurs, ils ont démontré que leur approche parvenait à saisir des schémas complexes dans les données, améliorant ainsi la performance des portefeuilles par rapport aux méthodes traditionnelles.

Zhang et al. (2020) introduisent une méthode innovante baptisée « *ListFold* », fondée sur un nouvel algorithme d'apprentissage par classement. Contrairement à d'autres approches qui se concentrent sur la prédiction des rendements absolus des actions, leur modèle s'intéresse plutôt au classement relatif de ces rendements. Pour y parvenir, ils ont conçu une fonction de perte originale qui met l'accent sur les extrêmes du classement, afin d'équilibrer de manière optimale les positions longues et courtes. Testée sur le marché chinois sur la période 2006-2019, cette approche a affiché un rendement annualisé hors-échantillon de 38 % et un ratio de Sharpe de 2,0, surpassant ainsi des modèles de référence tels que « *ListMLE* » et des réseaux de neurones.

CHAPITRE 2

DONNÉES

Dans ce chapitre, nous présentons en détail les bases de données utilisées ainsi que les transformations qui y ont été appliquées afin de réaliser les prédictions et construire les portefeuilles.

2.1 Données macroéconomiques

Les données macroéconomiques sont les prédicteurs principaux utilisés dans cette étude pour anticiper les rendements des actifs financiers. Elles sont issues de bases de données couvrant plusieurs indicateurs économiques clés à la fois pour le Canada et pour les États-Unis. Ces données sont agrégées de manière mensuelle, et couvrent la période de janvier 2000 à janvier 2024 dans le cadre d'analyse de ce mémoire, après transformation.

2.1.1 Données macroéconomiques canadiennes

Les prédicteurs macroéconomiques canadiens utilisés proviennent de la LCDMA (*Large Canadian Database for Macroeconomic Analysis*) construite par Fortin-Gagnon et al. (2022), en utilisant huit différents groupes de variables à savoir ; (1) production, (2) travail, (3) logement, (4) stocks et commandes des fabricants, (5) monnaie et crédit, (6) commerce international et flux financiers, (7) prix et (8) marchés boursiers. Cette base de données est accessible sur le site web de la chaire en macroéconomie et prévision de l'ESG en format mensuel et désaisonnalisé. Chaque base de données est disponible en deux versions : la première est constituée des « données brutes collectées auprès de Statistique Canada depuis 1914 », tandis que la seconde est un « panel stationnaire et équilibré », dont la première observation remonte à janvier 1981. Pour ce mémoire, c'est cette version stationnaire qui est utilisée. Le panel téléchargé contient 405 séries chronologiques (hors-séries discontinus), dont la première observation de chaque série correspond à janvier 1981 et la dernière à décembre 2024. Les séries possèdent ainsi un total de 528 observations mensuelles. Dans notre cadre d'analyse, nous gardons seulement les données depuis janvier 2000 à janvier 2024, ce qui réduit le nombre d'observations à 289 pour chaque série.

2.1.2 Données macroéconomiques américaines

Les prédicteurs macroéconomiques américains utilisés proviennent de la FRED-MD (*Federal Reserve of Economic Data – Monthly Database*) assemblée par Mckracken et Ng (2015), réparties en huit différents groupes de variables à savoir ; (1) production et revenu, (2) marché du travail, (3) consommation et commandes, (4) commandes et inventaires, (5) monnaie et crédit, (6) taux d'intérêt et taux de change, (7) prix et (8) marché boursier. Cette base de données est également en format mensuel désaisonnalisé sur la période de janvier 1959 à décembre 2024, avec 792 observations pour chaque série chronologique. Dans notre cadre d'analyse, nous gardons également seulement les données depuis janvier 2000 à janvier 2024, ce qui réduit le nombre d'observations à 289 pour chaque série.

2.2 Données financières

En plus des informations macroéconomiques, cette étude mobilise également des données financières tirées de Yahoo Finance afin d'alimenter nos modèles de prévision. Ces séries chronologiques retracent l'évolution des prix des actifs et permettent d'évaluer leur dynamique au fil du temps. Dans ce contexte, nous retenons plus précisément la variable « *Close* » pour chaque action, que nous convertissons en rendements. Ces rendements constituent la variable dépendante au cœur de nos modèles prédictifs. Par définition, la variable « *Close* » correspond au dernier prix enregistré pour un actif financier à la clôture d'une journée d'échange sur les marchés (*trading*). Ce prix de clôture revêt une importance particulière, puisqu'il reflète la valeur finale de l'actif pour la journée, susceptible d'influencer les décisions d'investissement de la prochaine journée. Par ailleurs, nous incluons également les retards de ces séries financières parmi nos prédicteurs, afin de renforcer la fiabilité de nos estimations.

2.2.1 Données financières canadiennes

Les données financières canadiennes proviennent du TSX (*Toronto Stock Exchange*) en format mensuel sur la période de janvier 2000 à janvier 2024. Dans le cadre de ce mémoire, nous avons sélectionné un échantillon de 50 actions canadiennes, représentant 289 observations pour chacune des séries chronologiques financières.

2.2.2 Données financières américaines

Pour le marché américain, nous utilisons des données de séries chronologiques financières mensuelles issues du *Standard & Poor's* (S&P), couvrant également la période de janvier 2000 à janvier 2024. Afin de comparer les deux marchés, nous avons aussi sélectionné un échantillon de 50 actions américaines, totalisant 289 observations pour chaque série.

2.3 Transformation des données

Pour renforcer la robustesse et la comparabilité des données dans notre analyse, différentes transformations ont été appliquées aux informations financières et macroéconomiques. Ces ajustements visent à stabiliser les séries temporelles, à limiter l'effet des valeurs extrêmes et à garantir que les prédicteurs soient adaptés aux modèles d'apprentissage machine.

Les données macroéconomiques canadiennes, provenant de la base de données de la LCDMA, ont majoritairement été préalablement transformées en première différence du logarithme afin de capturer les variations relatives d'une période à l'autre tout en réduisant la non-stationnarité des séries. Cette transformation permet de stabiliser la variance et de linéariser la tendance des séries en cas de croissance exponentielle. Le détail de ces transformations est disponible en annexe de l'article de Fortin-Gagnon et al. (2022) et la nôtre. La première différence logarithmique est calculée comme suit :

$$\Delta \ln(X_t) = \ln(X_t) - \ln(X_{t-1}) \quad (2.1)$$

où X_t représente la valeur de la variable à la période t . Cette opération permet d'obtenir une série en pourcentage de variation périodique, facilitant l'interprétation et la comparabilité entre indicateurs. Certaines variables n'ont nécessité aucune transformation, car elles étaient déjà stationnaires ou ne présentaient pas de tendance marquée. D'autres variables ont été transformées par première différence pour capturer les changements absolus d'une période à l'autre, ce qui est pertinent pour des indicateurs comme les taux d'intérêt ou les ratios de crédit. Enfin, quelques séries ont été uniquement transformées en logarithme afin de modérer l'échelle des valeurs, sans différenciation temporelle.

Pour les données macroéconomiques américaines, extraites de la base de données FRED, les données ont également été transformées au préalable. La documentation de ces transformations est disponible en annexe de l'article de Mckraken et Ng (2015) et la nôtre. Toutefois, afin d'assurer la stationnarité des séries temporelles, nous avons réalisé une standardisation des données (*standard scaling*), qui consiste à transformer chaque prédicteur en soustrayant sa moyenne et en le divisant par son écart-type. Cette méthode permet d'obtenir des données centrées autour de zéro ainsi qu'avec une variance unitaire, ce qui facilite la convergence des modèles d'apprentissage machine et améliore la qualité des prédictions. La transformation est formalisée comme suit pour chaque prédicteur X :

$$X^{standardisé} = \frac{X - \mu}{\sigma} \quad (2.2)$$

Où $X^{standardisé}$ est la valeur standardisée du prédicteur X , μ la moyenne de X calculée sur l'ensemble d'entraînement, et σ , l'écart-type de X , également calculé sur l'ensemble d'entraînement. Lors de la préparation des données, nous calculons μ (la moyenne) et σ (l'écart-type) uniquement à partir de l'ensemble d'entraînement, afin d'éviter toute « fuite de données » (*data leakage*) susceptible de fausser l'évaluation hors-échantillon. Ensuite, à l'étape de test ou de prédiction, chaque nouvelle donnée est standardisée en utilisant ces mêmes valeurs de μ et σ issues de l'entraînement, selon la formule :

$$X^{test,standardisé} = \frac{X^{test} - \mu}{\sigma} \quad (2.3)$$

En appliquant cette procédure de standardisation de manière progressive, on évite que le modèle ait accès à des informations futures pendant l'apprentissage. Cela préserve la fiabilité et la validité des prédictions hors-échantillon. Par ailleurs, ces transformations contribuent à stabiliser les séries temporelles et à les rapprocher d'une distribution normale, renforçant ainsi la performance globale des modèles.

D'autre part, les données financières sont transformées en rendements arithmétiques pour mieux saisir les variations relatives des actifs sur les marchés canadien et américain. Le rendement arithmétique d'un actif entre deux périodes t et $t + 1$ est calculé comme suit :

$$R_{t+1} = \frac{P_{t+1} - P_t}{P_t} \quad (2.4)$$

Où R_{t+1} est le rendement arithmétique pour la période $t + 1$, P_{t+1} correspond au prix de l'actif à la période $t + 1$, et P_t est le prix de l'actif à la période t .

2.4 Échantillons d'entraînement et de test

Pour garantir une évaluation rigoureuse des modèles, les données ont été séparées en échantillons d'entraînement et de test selon des périodes temporelles distinctes. Trois ensembles d'entraînement et quatre ensembles de tests ont été définis, couvrant des périodes spécifiques pour capturer différentes dynamiques du marché. Les périodes d'entraînements couvrent 2000-01 à 2007-12, 2000-01 à 2011-12 et 2000-01 à 2019-12. Les ensembles de tests correspondent de 2008-01 à 2024-01, 2008-01 à 2012-01, 2012-01 à 2020-01 et 2020-01 à 2024-01.

Les prédictions sont réalisées de sorte à prédire une période à l'avance à une fréquence mensuelle. En ce sens, les modèles sont spécifiquement entraînés pour prédire le rendement d'actifs au mois suivant ($t + 1$) à partir des données disponibles jusqu'à la période actuelle (t). La méthodologie repose sur l'utilisation de fenêtres temporelles expansives (*expanding windows*) avec un ajustement du modèle à chaque nouvelle observation. Cela signifie que la taille de l'ensemble d'entraînement augmente progressivement à chaque itération, intégrant les données les plus récentes tout en conservant les observations passées. Formellement, à chaque étape k , l'ensemble d'entraînement est défini comme suit :

$$\text{Entraînement}_k = \{X_t, Y_t \mid t \in [t_{\text{début}}, t_k]\}, \quad \text{Test}_k = \{X_{t+1}, Y_{t+1} \mid t = t_k\} \quad (2.5)$$

où $t_{\text{début}}$ est le début de la période d'entraînement et t_k est la dernière période incluse dans l'ensemble d'entraînement à chaque étape k . Les données macroéconomiques et financières ont

été alignées sur une base temporelle commune, assurant ainsi une correspondance entre les prédictors (variables explicatives) et les variables cibles (rendements d'actifs). De plus, il est important de noter que les données d'entraînements varient selon le marché étudié. En ce sens, dans le cadre de l'analyse canadienne, seuls les prédictors macroéconomiques issus de la base de données LCDMA et les données financières canadiennes sont pris en compte. À l'inverse, pour le marché américain, les prédictors macroéconomiques proviennent de la base FRED-MD, et les données financières d'actifs américains. Cette différenciation permet de respecter les spécificités économiques et structurelles propres à chaque territoire, assurant ainsi des modèles adaptés à leur contexte respectif. Enfin l'optimisation des hyperparamètres a été effectuée à l'aide d'une méthode bayésienne. Plus précisément, selon Snoek et al. (2012), cette méthode permet d'explorer efficacement l'espace des hyperparamètres en modélisant les relations entre ces derniers et les performances des modèles, minimisant ainsi les calculs superflus tout en identifiant les configurations optimales.

CHAPITRE 3

MÉTHODOLOGIE

Dans ce chapitre, nous décrivons la collection de méthodes d'apprentissage machine de régression et de classification que nous utilisons dans notre analyse ainsi que la méthodologie d'optimisation des portefeuilles suivant une stratégie longue-courte et des signaux choisis. Nous définissons également les métriques employées pour évaluer la performance hors-échantillon des portefeuilles. Enfin, nous détaillerons l'utilisation de la méthode SHAP, afin d'interpréter dans nos résultats l'importance des variables dans les prédictions des modèles.

3.1 Algorithmes pour la prédiction de rendements d'actions

Dans le cadre de cette étude, nous nous intéressons à la prédiction des rendements d'actions en utilisant des méthodes d'apprentissage machine. L'objectif principal est de modéliser la relation entre un ensemble de variables prédictives, comprenant des indicateurs macroéconomiques et les rendements passés des actions, afin de prédire à chaque période les rendements des actions cotées sur les marchés canadiens et américains. Cette étape est nécessaire en premier lieu afin que, dans un second temps, nous construisions des portefeuilles suivant une stratégie longue-courte avec les prédictions réalisées des modèles selon différents signaux.

Formellement, considérons un ensemble d'actions indexées par i et des périodes temporelles t . Pour chaque action i à la période t , nous disposons d'un vecteur de variables prédictives $x_{i,t}$ et nous cherchons à prédire le rendement futur $r_{i,t+1}$. Les variables prédictives $x_{i,t}$ comprennent à la fois des variables macroéconomiques et les rendements passés des actions. Les variables macroéconomiques peuvent inclure, notamment le taux d'intérêt, l'inflation et le produit intérieur brut (PIB), tandis que les rendements passés englobent les rendements retardés (*laggés*) de l'action i (12 *lags*). Le problème de prédiction peut être formulé comme l'estimation d'une fonction inconnue f qui relie les variables prédictives aux rendements futurs :

$$r_{i,t+1} = f(x_{i,t}) + \epsilon_{i,t+1} \quad (3.1)$$

où $\epsilon_{i,t+1}$ représente un terme d'erreur aléatoire traduisant les facteurs non pris en compte par le modèle. L'utilisation de méthodes d'apprentissage machine permet d'estimer la fonction f en mettant en évidence des relations potentiellement complexes et non linéaires entre les variables prédictives et les rendements futurs. Cette approche s'appuie sur la littérature financière, notamment Gu et al. (2020), qui souligne que les marchés financiers sont influencés par une multitude de facteurs interdépendants, rendant les hypothèses linéaires classiques insuffisantes pour capturer pleinement ces dynamiques.

Dans cette étude, deux approches principales sont envisagées pour la prédiction des rendements d'actions, permettant d'exploiter différemment l'information contenue dans les données. La première approche repose sur la régression, où l'objectif est de prédire la valeur numérique exacte du rendement futur $r_{i,t+1}$ d'un actif donné. Cette méthode consiste à estimer directement le niveau de rendement, offrant ainsi une vision quantitative des performances attendues pour chaque actif. La seconde approche est celle de la classification, dans laquelle l'objectif est de prédire la direction du rendement futur, c'est-à-dire de déterminer si le rendement sera positif ou négatif. Cette approche binaire facilite la prise de décision en matière de gestion de portefeuille, en fournissant des indications claires pour des positions d'achat ou de vente.

3.1.1 Algorithmes de régression pour la prédiction des rendements d'actions

Dans cette section, nous présentons les méthodes de régression utilisées pour la prédiction des rendements d'actions dans notre étude. Ces approches permettent de modéliser la relation des variables prédictives macroéconomiques et financières, aux rendements futurs.

3.1.1.1 Ridge

Le modèle de régression Ridge théorisé par Hoerl et Kennard (1970), également connu sous le nom de régression linéaire à pénalité L2, cherche à minimiser une fonction de coût composée de l'erreur quadratique moyenne et d'un terme de régularisation. Mathématiquement, il s'agit de minimiser la fonction suivante :

$$J(\beta) = \sum_{i=1}^n \left(y_i - \beta_0 - \sum_{j=1}^p \beta_j x_{ij} \right)^2 + \lambda \sum_{j=1}^p \beta_j^2 \quad (3.2)$$

où y_i est la valeur de la variable cible pour l'observation i , x_i est la valeur de la j -ème variable explicative pour l'observation i , β est le vecteur de paramètres à estimer, et λ est le paramètre de régularisation qui contrôle la force de la pénalisation. La régularisation introduite par le terme $\sum_{j=1}^p \beta_j^2$ permet de réduire la variance en diminuant les valeurs de β_j , ce qui rend le modèle plus robuste aux données bruitées et aux corrélations entre les variables explicatives. La solution analytique de la régression Ridge est donnée par :

$$\hat{\beta} = (X^T X + \lambda I)^{-1} X^T y \quad (3.3)$$

où X est la matrice des observations, y est le vecteur des valeurs cibles, et I est la matrice identité de taille $p \times p$.

3.1.1.2 XGBoost

XGBoost est une méthode de *boosting* par gradient développé par Chen et Guestrin (2016). Son objectif est de minimiser une fonction de perte en ajustant successivement des arbres de décision afin de corriger les erreurs des arbres précédents. Cette méthode augmente les performances et la stabilité du modèle tout en minimisant sa variance. Soit une fonction de perte $L(y, \hat{y})$ définie pour une tâche de régression (typiquement l'erreur quadratique). À chaque itération t , le modèle construit un nouvel arbre $f_t(x)$ qui minimise la fonction suivante :

$$\mathcal{L}^{(t)} = \sum_{i=1}^n L(y_i, \hat{y}_i^{t-1} + f_t(x_i)) + \Omega(f_t) \quad (3.4)$$

où $\hat{y}_i^{t-1}$ est la prédiction pour l'observation i après $t - 1$ itérations, $f_t(x_i)$ est l'arbre ajouté à l'itération t , $\Omega(f_t)$ est un terme de régularisation qui contrôle la complexité de l'arbre pour éviter

le surapprentissage. La régularisation est introduite par un terme $\Omega(f_t) = \gamma T + \frac{1}{2} \lambda \sum_{j=1}^T w_j^2$, où T est le nombre de feuilles de l'arbre et w_j les valeurs des feuilles. XGBoost emploie une optimisation en second ordre en utilisant le gradient et le hessien de la fonction de perte, ce qui lui permet d'avoir une convergence rapide et précise.

3.1.1.3 Ada Boost

L'Ada Boost, initialement conçu pour la classification, peut être adapté à un problème de régression en suivant la méthodologie de Freund (1999). Contrairement à la classification où l'objectif est de minimiser une erreur de classification pondérée, en régression, l'objectif est de minimiser une erreur de prédiction continue pondérée, telle que l'erreur absolue ou l'erreur quadratique. À chaque itération t , le modèle ajuste un prédicteur faible $h_t(x)$ pour minimiser une fonction de perte pondérée $L(y, \hat{y})$, où $\hat{y}$ est la prédiction du modèle. L'objectif global est de minimiser une fonction de perte pondérée sur les n observations, définie comme suit :

$$\mathcal{L}^{(t)} = \sum_{i=1}^n w_i^{(t)} \cdot L(y_i, h_t(x_i)) \quad (3.5)$$

où $w_i^{(t)}$ est le poids associé à l'observation i à l'itération t , $L(y_i, h_t(x_i))$ est une fonction de perte, typiquement l'erreur quadratique $(y_i - h_t(x_i))^2$. Les poids des n observations sont initialisés uniformément :

$$w_i^{(1)} = \frac{1}{n}, \quad \forall i \in \{1, \dots, n\} \quad (3.6)$$

À chaque itération t , un modèle faible $h_t(x)$ est ajusté pour minimiser la fonction de perte pondérée $\mathcal{L}^{(t)}$. L'erreur pondérée du modèle faible est donnée par :

$$\epsilon_t = \frac{\sum_{i=1}^n w_i^{(t)} \cdot L(y_i, h_t(x_i))}{\sum_{i=1}^n w_i^{(t)}} \quad (3.7)$$

Puis le poids attribué au modèle $h_t(x)$ dans la combinaison finale est défini comme suit :

$$\alpha_t = \frac{1}{2} \ln \left(\frac{1 - \epsilon_t}{\epsilon_t} \right), \quad \text{avec } \epsilon_t < 0.5 \quad (3.8)$$

Si $\epsilon_t < 0.5$, cela indique que le modèle est moins performant que le hasard et il est écarté. Les poids des observations sont ajustés pour accorder plus d'importance aux observations mal prédites :

$$w_i^{(t+1)} = w_i^{(t)} \cdot \exp \left(\alpha_t \cdot \frac{L(y_i, h_t(x_i))}{Z_t} \right) \quad (3.9)$$

Où Z_t est un facteur de normalisation pour garantir que la somme des poids reste égale à 1 :

$$Z_t = \sum_{i=1}^n w_i^{(t)} \cdot \exp \left(\alpha_t \cdot \frac{L(y_i, h_t(x_i))}{\max_i L(y_i, h_t(x_i))} \right) \quad (3.10)$$

La prédiction finale du modèle AdaBoost est obtenue comme une combinaison pondérée des prédictions des modèles faibles :

$$\hat{y}(x) = \frac{\sum_{t=1}^T \alpha_t \cdot h_t(x)}{\sum_{t=1}^T \alpha_t} \quad (3.11)$$

3.1.1.4 Extra Trees

Le modèle des arbres extrêmement randomisés (*Extra Trees*) théorisé par Geurts et al. (2006), est une version modifiée des forêts aléatoires, introduisant encore plus de variance en sélectionnant de façon aléatoire les points de coupure dans les arbres. L'algorithme repose sur la création de plusieurs arbres de décision, chacun construit à partir d'échantillons aléatoires du jeu de données.

À chaque nœud de chaque arbre, l'algorithme choisit une fraction des variables m sur p de façon aléatoire et sélectionne les seuils de manière aléatoire plutôt qu'en maximisant un critère comme la

réduction d'entropie ou la réduction de variance. La prédiction finale est obtenue en prenant la moyenne (pour la régression) ou le vote majoritaire (pour la classification) sur tous les arbres.

Mathématiquement, soit $D = \{(x_i, y_i)\}_{i=1}^n$ le jeu de données. Pour chaque arbre t et chaque nœud j , on choisit une sous-partie aléatoire $F_j \subset \{1, \dots, p\}$ des variables. Puis, pour chaque variable $f \in F_j$, on choisit un point de coupure s aléatoire dans la distribution des valeurs de f . Enfin, on sépare le nœud en deux sous-ensembles en fonction de ce point de coupure.

Lorsque les arbres sont entièrement construits, la prédiction finale du modèle Extra Trees s'obtient en moyennant les prédictions de tous les arbres (dans le cas d'une classification, on prend un vote majoritaire ou proportionnel). Ainsi, pour une nouvelle observation x , le modèle peut s'écrire :

$$\hat{y}(x) = \frac{1}{K} \sum_{t=1}^K T_t(x) \quad (3.12)$$

Où $\hat{y}(x)$ représente la prédiction finale du modèle pour l'observation x , $T_t(x)$ désigne la prédiction de l'arbre t , et K le nombre total d'arbres.

3.1.2 Algorithmes de classification pour la prédiction des rendements d'actions

Cette section présente les différents algorithmes de classification utilisée afin de classifier la direction future des rendements, c'est-à-dire s'ils seront positifs ou négatifs. Contrairement aux algorithmes de régression qui estiment une valeur continue, les algorithmes de classification attribuent une classe discrète à chaque observation.

3.1.2.1 Régression logistique

La régression logistique, théorisée par Cox (1958), est un modèle statistique principalement utilisé pour les problèmes de classification binaire, tels que la prédiction de la direction des rendements d'actions (positif ou négatif). Elle modélise la probabilité qu'une observation appartienne à une certaine classe en fonction d'un ensemble de variables prédictives. Dans notre contexte, la régression logistique permet d'estimer la probabilité que le rendement futur d'une action soit positif,

compte tenu des variables macroéconomiques et des rendements passés. Formellement, soit $y_{i,t+1}$ la variable binaire indiquant la direction du rendement futur de l'action i à la période $t + 1$:

$$y_{i,t+1} = \begin{cases} 1, & \text{si } r_{i,t+1} > 0 \\ 0, & \text{si } r_{i,t+1} \leq 0 \end{cases} \quad (3.13)$$

où $r_{i,t+1}$ est le rendement de l'action i à la période $t + 1$ dans l'équation. Le modèle de régression logistique estime la probabilité conditionnelle $P(y_{i,t+1} = 1 \mid \mathbf{x}_{i,t})$ en utilisant la fonction logistique (sigmoïde) :

$$P(y_{i,t+1} = 1 \mid \mathbf{x}_{i,t}) = \sigma(\beta_0 + \mathbf{x}_{i,t}^\top \beta) = \frac{1}{1 + \exp(-(\beta_0 + \mathbf{x}_{i,t}^\top \beta))} \quad (3.14)$$

où $\mathbf{x}_{i,t}$ est le vecteur des variables prédictives pour l'action i à la période t , β est le vecteur des coefficients associés aux variables prédictives, β_0 est l'ordonnée à l'origine (interception), $\sigma(\cdot)$ est la fonction sigmoïde et $\exp(\cdot)$ représente l'exponentielle. Le modèle est entraîné en estimant les paramètres β_0 et β qui maximisent la vraisemblance des données observées. Cela équivaut à minimiser la fonction de coût basée sur l'entropie croisée (*log-loss*) :

$$L(\beta_0, \beta) = - \sum_{i=1}^N \left[y_{i,t+1} \log P(y_{i,t+1} = 1 \mid \mathbf{x}_{i,t}) + (1 - y_{i,t+1}) \log (1 - P(y_{i,t+1} = 1 \mid \mathbf{x}_{i,t})) \right] \quad (3.15)$$

où N est le nombre total d'observations. La régression logistique présente l'avantage d'être interprétable. Les coefficients β indiquent l'impact marginal des variables prédictives sur le logarithme du rapport de chances (*log-odds*) du rendement positif. Par exemple, un coefficient positif pour une variable macroéconomique signifie qu'une augmentation de cette variable est associée à une probabilité accrue d'obtenir un rendement positif.

3.1.2.2 XGBoost Classification

XGBoost comme mentionné précédemment, est un algorithme d'apprentissage machine basé sur le principe du renforcement de gradient (*gradient boosting*), optimisé pour la performance et

l'efficacité computationnelle. Le XGBoost Classification est la version de cet algorithme adaptée aux problèmes de classification, y compris la classification binaire utilisée pour prédire la direction des rendements d'actions. Le renforcement de gradient construit un modèle prédictif « fort » en combinant plusieurs modèles « faibles » (généralement des arbres de décision peu profonds) de manière séquentielle. À chaque étape, un nouvel arbre est entraîné pour corriger les erreurs du modèle précédent en minimisant une fonction de perte différentiable. Formellement, soit $\hat{y}_{i,t+1}^{(k)}$ la prédiction après k itérations, le modèle est construit comme :

$$\hat{y}_{i,t+1}^{(k)} = \sum_{m=1}^k f_m(x_{i,t}) \quad (3.16)$$

où f_m est l'arbre de décision appris à l'itération m et $\hat{y}_{i,t+1}^{(k)}$ est la somme des prédictions des arbres jusqu'à l'itération k . Le modèle XGBoost Classification minimise une fonction de perte régulière pour trouver les arbres f_m optimaux :

$$L^{(k)} = \sum_{i=1}^N \ell(y_{i,t+1}, \hat{y}_{i,t+1}^{(k-1)} + f_k(x_{i,t})) + \Omega(f_k) \quad (3.17)$$

où ℓ est la fonction de perte et $\Omega(f_k)$ est le terme de régularisation pour contrôler la complexité du modèle. L'optimisation se fait en utilisant une approximation de la fonction de perte par une expansion de Taylor de second ordre, ce qui permet de calculer les gradients et les hessiennes pour chaque arbre :

$$L^{(k)} \approx \sum_{i=1}^N \left[g_i f_k(x_{i,t}) + \frac{1}{2} h_i f_k(x_{i,t})^2 \right] + \Omega(f_k) \quad (3.18)$$

où $g_i = \frac{\partial \ell(y_{i,t+1}, \hat{y}_{i,t+1}^{(k-1)})}{\partial \hat{y}_{i,t+1}^{(k-1)}}$ est le gradient et $h_i = \frac{\partial^2 \ell(y_{i,t+1}, \hat{y}_{i,t+1}^{(k-1)})}{\partial (\hat{y}_{i,t+1}^{(k-1)})^2}$ est la hessienne.

3.1.2.3 Hist Gradient Boosting Classification

Le Hist Gradient Boosting Classification, fortement inspiré des travaux de Ke et al. (2017), est une variante du renforcement de gradient qui utilise des histogrammes pour accélérer l'entraînement des modèles, en particulier sur de grands ensembles de données. Il s'agit d'une implémentation optimisée du renforcement de gradient qui est relativement plus efficace en termes de calcul et de mémoire. Au lieu de considérer chaque valeur de caractéristique individuellement, le Hist Gradient Boosting regroupe les valeurs de chaque caractéristique en un nombre réduit de bacs (*bins*) d'histogramme. En effet, cette quantification permet de réduire la complexité du calcul lors de la recherche des seuils optimaux pour les divisions des arbres de décision. Le modèle suit le même principe général que le renforcement de gradient traditionnel, en construisant le modèle prédictif comme une somme de fonctions de base (arbres de décision) :

$$\hat{y}_{i,t+1}^{(k)} = \sum_{m=1}^k f_m(x_{i,t}) \quad (3.19)$$

La différence réside dans la manière dont les arbres f_m sont construits. Lors de la construction des arbres les valeurs des variables prédictives sont discrétisées en histogrammes avec un nombre fixe de bacs et les meilleures divisions (*splits*) sont recherchées parmi les limites des bacs plutôt que parmi toutes les valeurs possibles. L'utilisation des histogrammes permet de réduire considérablement le nombre de candidats pour les seuils de division, ce qui accélère l'algorithme sans sacrifier significativement la performance du modèle. La fonction de perte et l'optimisation restent similaires à celles utilisées dans le renforcement de gradient traditionnel.

3.1.2.4 Extra Trees Classification

L'Extra Trees Classification, ou *Extremely Randomized Trees Classifier*, est un algorithme d'apprentissage machine basé sur les arbres de décision, qui construit une forêt d'arbres de décision pour la classification. Il est similaire aux forêts aléatoires (*Random Forests*) mais introduit davantage de randomisation lors de la construction des arbres, ce qui peut améliorer la généralisation du modèle, comme discuté pour son homologue de régression. Chaque arbre est bâti à partir d'échantillons aléatoires du jeu de données. À chaque nœud, on tire une fraction de variables

$\ell \subset \{1, \dots, p\}$ au hasard, puis on sélectionne de façon aléatoire plusieurs seuils de coupure dans la distribution des valeurs de chaque variable candidate. Le seuil retenu est celui qui maximise le critère de séparation (Gini dans notre cas). Pour une nouvelle observation x , chaque arbre T_t renvoie soit une classe majoritaire (vote direct), soit une distribution de probabilités sur les classes (dans ce cas, la classe finale peut être choisie par vote majoritaire ou par agrégation probabiliste). Ainsi, la prédiction globale de l'ensemble se définit comme le vote majoritaire parmi les K arbres, ou la somme normalisée de leurs distributions de probabilités. Cette approche permet d'obtenir un modèle de classification robuste, grâce à la double randomisation dans la sélection des variables et dans les points de coupure à chaque nœud.

3.2 Portefeuilles suivant une stratégie longue-courte

La stratégie de portefeuille longue-courte (*long-short portfolio*), est une approche d'investissement visant à exploiter les prévisions de rendements en prenant simultanément des positions longues sur les actifs anticipés comme performants et des positions courtes sur ceux prévus comme sous-performant. Dans le cadre de cette étude, nous utilisons les prédictions générées par les algorithmes d'apprentissage machine de régression et de classification, pour construire un portefeuille suivant une stratégie longue-courte, en tirant parti des informations issues des variables macroéconomiques et des rendements passés.

La méthodologie de construction du portefeuille repose sur un processus systématique. Pour chaque période t , les modèles d'apprentissage machine fournissent des prédictions des rendements futurs $\hat{r}_{i,t+1}$ pour chaque action i de notre univers d'investissement. Ces prédictions peuvent provenir des modèles de régression, qui estiment directement les rendements futurs, ou des modèles de classification, qui fournissent des probabilités que les rendements soient positifs. Les actions sont ensuite classées en fonction des prédictions obtenues. Pour les modèles de régression, les actifs sont ordonnés selon les valeurs prédites $\hat{r}_{i,t+1}$. Pour les modèles de classification, on s'appuie sur la probabilité prédite $P(y_{i,t+1} = 1 | x_{i,t})$ afin de déterminer si un actif a plus de chances de présenter un rendement positif ou négatif et, par conséquent, de le placer en position longue ou courte.

La sélection des positions longues et courtes pour les algorithmes de régressions s'effectue en divisant les actions en quantiles, généralement en formant des portefeuilles constitués des déciles supérieurs et inférieurs. Les actions avec les prédictions de rendements les plus élevées sont sélectionnées pour les positions longues, tandis que celles avec les prédictions les plus faibles sont choisies pour les positions courtes. Chaque action au sein des positions longues ou courtes est pondérée de manière égale, assurant ainsi une diversification au sein de chaque segment du portefeuille et suivant ainsi la méthodologie de pondération de Gu et al. (2020).

La construction du portefeuille s'effectue en combinant les positions longues et courtes selon les poids définis, créant ainsi un portefeuille globalement neutre au marché. Cette neutralité vise à isoler l'alpha généré par les prédictions des modèles, en minimisant l'exposition au risque systématique du marché. Le portefeuille est rééquilibré à une fréquence mensuelle, alignée avec la fréquence des prédictions et des mises à jour des données macroéconomiques. À chaque nouvelle période, le processus de sélection et d'allocation est répété en utilisant les données les plus récentes, ce qui permet d'adapter le portefeuille aux conditions changeantes du marché.

Dans notre contexte, nous utilisons trois types de stratégies de signaux de portefeuilles différents à savoir une stratégie où on sélectionne à chaque période en position longue, les 10 rendements prédits les plus élevés par les modèles, et en position courte, les 10 actions dont la performance prédite est la plus basse. Également nous employons une deuxième stratégie qui suit la même logique que la première mais avec 20 actions. Enfin, nous mettons en œuvre une stratégie qui consiste à sélectionner toutes les actions avec des rendements prévus positifs en position longue et négatifs en position courte.

3.2.1 Stratégie de portefeuille longue-courte, top 10

Pour cette stratégie lors de la construction du signal, il est sélectionné à chaque période les 10 rendements prédits les plus élevés par les modèles, que l'on pondère de manière égale dans le portefeuille. De la même manière, les 10 actions dont la performance prédite est la plus faible sont également pondérées de manière égale mais en position courte. Soit $\hat{r}_{t+1}$ les rendements prévus pour la période $t + 1$. Les poids du portefeuille suivant une stratégie longue-courte sont définis comme :

$$w_i = \begin{cases} \frac{1}{10} & \text{si } i \in \mathcal{A}_{haut} \\ -\frac{1}{10} & \text{si } i \in \mathcal{A}_{bas} \\ 0 & \text{sinon} \end{cases} \quad (3.20)$$

où w_i correspond aux poids attribués à chaque action i dans le portefeuille, $\mathcal{A}_{haut}$ correspond à la sélection des 10 actions avec les rendements les plus élevés prédits et $\mathcal{A}_{bas}$ à la sélection des 10 actions avec les rendements dont la performance prédite est la plus faible.

3.2.2 Stratégie de portefeuille longue-courte, top 20

La méthodologie est similaire à la première stratégie pour la construction du signal, mais avec une sélection de 20 actions au lieu de 10. De ce fait, les poids du portefeuille suivant une stratégie longue-courte sont définis comme :

$$w_i = \begin{cases} \frac{1}{20} & \text{si } i \in \mathcal{A}_{haut} \\ -\frac{1}{20} & \text{si } i \in \mathcal{A}_{bas} \\ 0 & \text{sinon} \end{cases} \quad (3.21)$$

où w_i correspond aux poids attribués à chaque action i dans le portefeuille, $\mathcal{A}_{haut}$ correspond à la sélection des 20 actions avec les rendements les plus élevés prédits et $\mathcal{A}_{bas}$ à la sélection des 20 actions avec les rendements dont la performance prédite est la plus faible.

3.2.3 Stratégie de portefeuille longue-courte, positive et négative

Enfin, cette stratégie lors de la construction du signal, consiste à sélectionner toutes les actions avec des rendements prévus positifs et négatifs. Les actions avec des rendements prévus positifs sont pondérées de manière égale en position longue, et celles avec des rendements prévus négatifs sont pondérées de manière égale en position courte. De surcroit, cette stratégie s'applique également aux prédictions issues de la classification, où les rendements prévus positifs (labellisé par un 1) sont associés à des positions longues et inversement où les rendements prévus négatifs (labellisé

par 0) sont associés à des positions courte à chaque période. Ainsi, les poids du portefeuille sont définis comme :

$$w_i = \begin{cases} \frac{1}{|A_{\text{positif}}|} & \text{si } i \in \mathcal{A}_{\text{positif}} \\ -\frac{1}{|A_{\text{negatif}}|} & \text{si } i \in \mathcal{A}_{\text{negatif}} \\ 0 & \text{sinon} \end{cases} \quad (3.22)$$

où w_i correspond aux poids attribués à chaque action i dans le portefeuille, $\mathcal{A}_{\text{positif}}$ correspond à la sélection des actions avec des rendements prévus positifs et $\mathcal{A}_{\text{negatif}}$ à la sélection des actions avec des rendements prévus négatifs.

3.3 Validation rétrospective

Le calcul du rendement global et le protocole de validation rétrospective (*backtesting*) permet d'évaluer la pertinence et la robustesse des stratégies de portefeuilles longues et courtes élaborées à l'aide d'algorithmes d'apprentissage machine. Sur chaque période d'investissement, le rendement global du portefeuille $R_{p,t+1}$ est déterminé à partir de la formule :

$$R_{p,t+1} = \sum_{i \in \mathcal{A}_{\text{haut}}} w_{i,t} R_{i,t+1} + \sum_{i \in \mathcal{A}_{\text{bas}}} w_{i,t} R_{i,t+1} \quad (3.23)$$

où $\mathcal{A}_{\text{haut}}$ regroupe les actions sélectionnées en position longue (c'est-à-dire celles pour lesquelles le modèle prévoit les rendements les plus élevés), tandis que $\mathcal{A}_{\text{bas}}$ contient les actions placées en position vendeuse (*short*), prédites de sous-performer par les modèles en $t + 1$. Les poids $w_{i,t}$ associés à chaque titre sont fixés de manière à assurer une neutralité au marché. C'est-à-dire que la somme totale des poids sur l'ensemble des positions longues est égale et opposée à celle des positions courtes, de sorte que le portefeuille ne soit pas biaisé par la tendance globale du marché. Quant à $R_{i,t+1}$, il représente le rendement effectivement constaté pour l'action i pour la période $t + 1$.

Pour évaluer la validité de ces stratégies, on met en œuvre une méthodologie de validation rétrospective. En ce sens, l'on sépare l'historique des données en deux sous-ensembles, à savoir un échantillon d'entraînement et un échantillon de test. L'échantillon d'entraînement sert au calibrage et au réglage (hyperparamétrage) des algorithmes, tandis que l'échantillon de test, non exploré durant la phase de modélisation, permet de mesurer la capacité réelle des modèles à prévoir de nouveaux rendements. Cette division vise à prévenir toute fuite d'information (*data snooping*), de sorte que les performances obtenues sur la partie test reflètent des conditions aussi proches que possible de la réalité.

Dans cette optique, les prédictions pour chaque mois de l'échantillon de test sont produites uniquement à partir des données disponibles jusqu'à la date de la prédiction, en respectant strictement l'ordre chronologique. Cela garantit qu'aucune information future n'intervienne de façon directe ou indirecte dans l'estimation des modèles. Le choix des actions à inclure dans les positions longues et courtes s'effectue alors en fonction des rendements anticipés sur ce mois, et les poids $w_{i,t}$ sont définis selon la stratégie retenue, comme mentionné précédemment.

3.4 Critères de références

Dans l'objectif d'évaluer la performance de nos portefeuilles construits à partir des prédictions des modèles d'apprentissage machine, nous les comparons à des critères de références (*Benchmarks*). Ces critères de références permettent de déterminer si nos stratégies apportent une valeur ajoutée par rapport aux approches d'investissement relativement plus « traditionnelles ».

Le premier critère de référence est un portefeuille suivant une stratégie longue pondérée également. En ce sens, cette stratégie est constituée en investissant de manière égale dans toutes les actions de l'univers d'investissement sans appliquer de stratégie de sélection basée sur des prédictions. De ce fait, chaque action reçoit un poids égal $w_i = \frac{1}{N}$, où N est le nombre total d'actions dans le portefeuille.

Nous comparons également les performances de nos portefeuilles aux principaux indices boursiers, à savoir le S&P/TSX 60 (TSX60) pour le marché canadien, et pour le marché américain, le S&P 500 et le NASDAQ Composite. L'indice TSX60 comprend les 60 plus grandes entreprises cotées

à la Bourse de Toronto, reflétant d'une certaine manière la performance globale du marché canadien. D'autre part le S&P 500, composé des 500 plus grandes capitalisations d'entreprises américaines, est également un indicateur clé afin de suivre la vigueur économique du marché américain. Enfin, le NASDAQ Composite inclut plus de 3 000 actions, avec une forte concentration d'entreprises technologiques et à forte croissance. La comparaison avec ces indices boursiers nous permet d'évaluer si nos stratégies surperforment les marchés dans leur ensemble.

3.5 Métriques de mesures de performances pour les algorithmes de régressions

Dans cette section, nous présentons les métriques utilisées pour évaluer la performance des algorithmes de régression appliqués à la prédiction des rendements d'actions. Ces métriques permettent d'analyser la précision prédictive des modèles, mais également la performance des portefeuilles construits à partir de ces prédictions. Les mesures considérées incluent le coefficient de détermination hors-échantillon (R^2 hors-échantillon), le taux de croissance annuel composé (TCAC), le ratio de Sharpe, le ratio de Sortino, la perte maximale et le ratio Oméga.

3.5.1 Coefficient de détermination hors-échantillon

Le coefficient de détermination hors-échantillon ($R^2_{\text{HÉ}}$) est une mesure statistique mise en lumière par Campbell et Thompson (2008), qui évalue la capacité prédictive d'un modèle en comparant ses prédictions aux rendements réels sur un ensemble de données non utilisé pour l'entraînement. Il est défini comme suit :

$$R^2_{\text{HÉ}} = 1 - \frac{\sum_{t=1}^{T_{\text{test}}} (r_t - \hat{r}_t)^2}{\sum_{t=1}^{T_{\text{test}}} (r_t - \bar{r}_{\text{train}})^2} \quad (3.24)$$

où r_t est le rendement réel à la période t dans l'échantillon de test, $\hat{r}_t$ est le rendement prédit par le modèle à la période t , $\bar{r}_{\text{train}}$ est le rendement moyen dans l'échantillon d'entraînement et T_{test} est le nombre de périodes dans l'échantillon de test. Un $R^2_{\text{HÉ}}$ positif indique que le modèle prédit mieux les rendements que le modèle de référence consistant à utiliser la moyenne des rendements d'entraînement pour la prédiction.

3.5.2 Taux de croissance annuel composé

Le taux de croissance annuel composé (TCAC) ou rendement annualisé r^A , mesure le rendement annuel moyen d'un investissement sur une période donnée, en tenant compte de la capitalisation des gains. Selon Bodie et al. (2014), le TCAC permet de comparer différentes stratégies d'investissement sur une base annuelle, facilitant ainsi l'évaluation de leur performance relative sur le long terme. Le TCAC ou rendement annualisé r^A , est calculé selon la formule :

$$r^A = \left(\frac{V_f}{V_i} \right)^{\frac{1}{n}} - 1 \quad (3.25)$$

où V_f est la valeur finale du portefeuille, V_i est la valeur initiale du portefeuille et n est le nombre d'années.

3.5.3 Ratio de Sharpe

Le ratio de Sharpe (1966) est une mesure du rendement ajusté au risque d'un portefeuille. Il évalue le rendement excédentaire par unité de risque en comparant le rendement moyen du portefeuille au taux sans risque et en le divisant par l'écart type des rendements du portefeuille. La formule du ratio de Sharpe (SR) est donnée par :

$$SR = \frac{E[R_p] - R_f}{\sigma_p} \quad (3.26)$$

où $E[R_p]$ est le rendement espéré moyen du portefeuille, R_f est le taux sans risque et σ_p est l'écart type des rendements du portefeuille. Un ratio de Sharpe élevé indique que le portefeuille offre un rendement excédentaire élevé par rapport à sa volatilité, ce qui est souhaitable pour les investisseurs cherchant à maximiser le rendement tout en minimisant le risque.

3.5.4 Ratio de Sortino

Le ratio de Sortino et van der Meer, (1991) est une variante du ratio de Sharpe qui se concentre uniquement sur la volatilité négative (les pertes) plutôt que sur la volatilité totale. La formule du ratio de Sortino (ST) est définie comme :

$$ST = \frac{E[R_p] - R_f}{\sigma_d} \quad (3.27)$$

où $E[R_p]$ est le rendement espéré moyen du portefeuille, R_f est le taux sans risque, et σ_d est l'écart type des rendements en dessous du seuil cible (*downside deviation*). Le ratio de Sortino est considéré comme une mesure plus pertinente lorsque les rendements ne sont pas symétriquement distribués, car les investisseurs sont généralement plus préoccupés par les baisses de rendement que par les hausses inattendues.

3.5.5 Perte maximale

Cette métrique représente la perte maximale (P^{max}) qu'un portefeuille a subie depuis un sommet historique jusqu'à un creux avant qu'un nouveau sommet ne soit atteint. En ce sens, elle mesure la pire perte en capital qu'un investisseur aurait pu subir en restant investi dans le portefeuille. Formellement, la perte maximale (*Maximum Drawdown*) est calculée comme :

$$P^{max} = \max_{t \in [0, T]} \left(\frac{\text{Valeur maximale historique jusqu'à } t - \text{Valeur à } t}{\text{Valeur maximale historique jusqu'à } t} \right) \quad (3.28)$$

3.5.6 Ratio Oméga

Le ratio Oméga (Ω) de Keating et Shadwick (2002), est une mesure de performance qui compare les gains potentiels aux pertes potentielles en utilisant l'intégralité de la distribution des rendements, plutôt que de se limiter aux moments statistiques de premier et second ordre (moyenne et écart type). Il est défini en fonction d'un seuil de rendement cible Ω :

$$\Omega = \frac{\int_{\theta}^{\infty} [1 - F(r)] dr}{\int_{-\infty}^{\theta} F(r) dr} \quad (3.29)$$

où $F(r)$ est la fonction de distribution cumulative des rendements et Ω est le rendement cible choisi (dans notre étude le taux sans risque). Le numérateur représente l'espérance des gains au-delà du seuil θ , tandis que le dénominateur représente l'espérance des pertes en deçà de Ω . Un ratio Oméga supérieur à 1 indique que les gains potentiels dépassent les pertes potentielles, ce qui est favorable pour l'investisseur.

3.6 Métriques de mesure de performance pour les algorithmes de classification

Dans cette section, nous détaillons les métriques utilisées pour évaluer la performance des algorithmes de classification. Certaines métriques mesurent la performance dans la prédiction de la direction des rendements d'actions. Et d'autres évaluent la performance des portefeuilles construits à partir des signaux générés par les prédictions des modèles. Les métriques considérées incluent le score de précision, la statistique du test de Pesaran-Timmerman, le taux de croissance annuel composé (TCAC), le ratio de Sharpe, le ratio de Sortino, la perte maximale et le ratio Oméga. Il ne sera pas détaillé de nouveau formellement le taux de croissance annuel composé (TCAC), le ratio de Sharpe, le ratio de Sortino, la perte maximale et le ratio Oméga.

3.6.1 Score de précision

Le score de précision (SP) est une métrique permettant d'évaluer la performance des modèles de classification binaire. Il mesure la proportion d'observations correctement classées par le modèle par rapport au nombre total d'observations. Formellement, il est défini comme :

$$SP = \frac{\text{Nombre de prédictions correctes}}{\text{Nombre total de prédictions}} = \frac{VP + VN}{VP + VN + FP + FN} \quad (3.30)$$

où VP (Vrai Positif) est le nombre de rendements positifs correctement prédits, VN (Vrai Négatif) est le nombre de rendements négatifs correctement prédits, FP (Faux Positif) est le nombre de rendements négatifs incorrectement prédits comme positifs et FN (Faux Négatif) est le nombre de rendements positifs incorrectement prédits comme négatifs. Le score de précision fournit une

mesure globale de la performance du modèle, mais peut être trompeur en présence de classes déséquilibrées. Dans le contexte financier, où les rendements positifs et négatifs peuvent ne pas être équilibrés, il est important de considérer cette limitation, comme peuvent le souligner Provost et Fawcett (2013) dans leur livre.

3.6.2 Statistique du test de Pesaran-Timmerman

Ce test proposé par Pesaran et Timmerman (1992), est utilisé pour évaluer la capacité du modèle à prédire correctement la direction des changements dans les rendements d'actions. Il teste l'hypothèse nulle selon laquelle les prédictions du modèle ne sont pas meilleures que le hasard en termes de direction du changement. La statistique du test est calculée comme suit :

$$PT = \frac{(N_{11}N_{00} - N_{10}N_{01})}{\sqrt{N_1N_0N_1 \cdot N_0}} \quad (3.31)$$

où N_{11} est le nombre d'observations quand le modèle et le marché ont tous deux indiqué une augmentation, N_{00} est le nombre d'observations lorsque le modèle et le marché ont tous deux indiqué une diminution, N_{10} est le nombre d'observations où le modèle a indiqué une augmentation mais le marché une diminution et N_{01} est le nombre d'observations où le modèle a indiqué une diminution mais le marché une augmentation. De plus, $N_1 = N_{11} + N_{10}$ correspond au nombre de prédictions du modèle d'augmentation, $N_0 = N_{01} + N_{00}$ est le nombre de prédictions du modèle de diminution, $N_{1.} = N_{11} + N_{10}$ évalue le nombre de réalisations d'augmentation du marché et enfin $N_{0.} = N_{10} + N_{00}$ mesure le nombre de réalisations de diminution du marché. La statistique suit approximativement une loi normale standard sous l'hypothèse nulle. Une valeur PT élevée en valeur absolue indique que le modèle a une capacité prédictive significative de la direction des rendements.

3.7 Explication de l'importance des variables avec SHAP

Ces dernières années, dans le domaine de l'apprentissage machine appliqué à la finance, l'interprétabilité des modèles est devenue une préoccupation majeure. Les modèles complexes, tels que les forêts aléatoires, les méthodes de *boosting* ou les réseaux de neurones profonds, ont souvent

réalisé des performances prédictives supérieures comparativement aux autres modèles de la littérature selon Gu et al. (2020) mais au détriment de leur transparence. C'est à partir de cet enjeu de transparence et d'explicabilité que la méthode SHAP (*SHapley Additive exPlanations*) fut développé afin d'expliquer l'importance des variables dans les prédictions des modèles d'apprentissage machine.

La méthode SHAP, introduite par Lundberg et Lee (2017), repose sur la théorie des jeux coopératifs, en particulier sur le concept des valeurs de Shapley (1953). Plus particulièrement, les valeurs de Shapley attribuent à chaque joueur d'un jeu la contribution marginale moyenne de ce joueur au gain total, en considérant toutes les permutations possibles des joueurs. En transposant ce concept à l'apprentissage machine, chaque variable prédictive est considérée comme un "joueur" qui contribue à la prédiction du modèle. Les valeurs SHAP permettent ainsi de décomposer la prédiction d'un modèle complexe en une somme de contributions individuelles de chaque variable, offrant une interprétation cohérente et mathématiquement justifiée de l'importance des variables.

Formellement, considérons un modèle prédictif complexe f qui estime le rendement futur d'une action en fonction d'un vecteur de variables prédictives $x = (x_1, x_2, \dots, x_M)$, où M est le nombre total de variables. La prédiction du modèle pour une observation donnée est $f(x)$. La méthode SHAP vise à décomposer cette prédiction en une somme additive des contributions de chaque variable :

$$f(x) = \phi_0 + \sum_{i=1}^M \phi_i \quad (3.32)$$

où ϕ_0 représente la valeur de base du modèle (par exemple, la moyenne des prédictions sur l'ensemble des données) et ϕ_i est la valeur SHAP de la variable x_i , reflétant sa contribution à la prédiction par rapport à la valeur de base. La valeur SHAP pour une variable x_i est calculée en prenant la moyenne des contributions marginales de x_i sur toutes les combinaisons possibles de variables. Elle est définie par :

$$\phi_i = \sum_{S \subseteq M \setminus \{i\}} \frac{|S|! (M - |S| - 1)!}{M!} [f_{S \cup \{i\}}(x_{S \cup \{i\}}) - f_S(x_S)] \quad (3.33)$$

où M est l'ensemble de toutes les variables, S est un sous-ensemble de variables n'incluant pas x_i , $|S|$ est le nombre de variables dans S , f_S est le modèle restreint aux variables de S , et x_S est le vecteur des valeurs correspondantes. Cette formule assure une attribution équitable de l'importance entre les variables, en respectant les propriétés d'efficacité, de symétrie, d'absence d'influence et d'additivité.

Dans le cadre de notre étude, deux variantes principales de la méthode SHAP ont été utilisées pour interpréter les modèles de prévision des rendements, l'analyse globale et locale. L'analyse globale identifie les variables prédictives les plus influentes en mesurant leur contribution moyenne aux prédictions, permettant une vue d'ensemble des relations entre les variables et les rendements futurs. L'analyse locale, quant à elle, met l'accent sur l'impact individuel de chaque variable pour des observations spécifiques. Plus particulièrement, elle permet de déterminer comment les valeurs des variables, qu'elles soient élevées ou faibles, influencent la prédiction, et si cet effet est positif ou négatif.

CHAPITRE 4

RÉSULTATS

Le présent chapitre détaille et discute des résultats obtenus à partir de la méthodologie et des modèles présentés dans le chapitre 3. En effet, dans un premier lieu, nous analyserons les performances des algorithmes de régressions selon les métriques de performances par stratégie pour le Canada et les États-Unis. Dans un deuxième temps, la même analyse sera réalisée pour les algorithmes de classification. Enfin, en dernier lieu, nous interpréterons les résultats de la méthodologie SHAP, afin de comprendre quelles variables ont le plus contribué aux prédictions et dans quelle mesure.

4.1 Résultats des algorithmes de régression en hors-échantillon

Dans cette partie, nous réalisons une analyse des résultats hors-échantillon pour le Canada et les États-Unis, de différents modèles d'apprentissage machine de régressions pour la période de 2008-01 à 2024-01 (les résultats pour les autres périodes sont disponibles en annexe). Ces résultats sont analysés selon nos métriques définies ultérieurement dans le chapitre 3. Comme mentionné dans le chapitre 2, nos données sont divisées en échantillon d'entraînement de 2000-01 à 2007-12, correspondant à 96 observations, et de 2008-01 à 2024-01 de test, correspondant à 193 observations. Les modèles sont évalués à l'aide d'un cadre temporel à fenêtres expansives (*expanding windows*), intégrant progressivement les données les plus récentes dans l'échantillon d'entraînement, sans exclure les observations antérieures. Nos résultats obtenus sont affichés dans le tableau 4.1, qui est un résumé statistique des prédictions mensuelles réalisées sur la période 2008-01 à 2024-01. Nous comparons un modèle linéaire, à savoir le modèle Ridge, à trois autres modèles non-linéaires que sont XGBoost, Ada Boost et Extra Trees selon chaque métrique. En ce sens, cette comparaison des métriques pour chaque modèle est également menée selon nos 3 stratégies de portefeuille longue-courte suivant différents signaux en plus des critères de références.

Tableau 4.1 : Résumé statistique des prédictions mensuelles, 2008-01 à 2024-01 (régression)

	Canada						États-Unis					
	$R^2_{H\hat{E}}$	r^A	SR	ST	P^{max}	Ω	$R^2_{H\hat{E}}$	r^A	SR	ST	P^{max}	Ω
Longue-courte 10												
Ridge	-1,18	16,51	0,81	1,16	64,37	1,16	-0,39	12,97	0,64	0,93	73,69	1,13
XGBoost	-0,25	11,95	0,65	0,91	65,49	1,13	-0,21	11,36	0,61	1,87	69,54	1,13
Ada Boost	-0,11	14,77	0,75	1,05	70,02	1,15	-0,55	11,77	0,60	0,86	76,92	1,13
Extra Trees	-0,01	10,99	0,59	0,83	70,50	1,12	-0,01	14,56	0,71	1,02	66,57	1,15
Longue-courte 20												
Ridge	-1,18	12,00	0,67	0,94	66,75	1,14	-0,39	14,25	0,70	1,00	69,84	1,15
XGBoost	-0,25	12,32	0,69	0,97	63,52	1,14	-0,21	13,01	0,66	0,94	70,49	1,14
Ada Boost	-0,11	11,37	0,64	0,90	67,27	1,14	-0,48	13,43	0,67	0,96	72,59	1,14
Extra Trees	-0,01	11,91	0,67	0,94	62,57	1,14	-0,01	13,49	0,68	0,97	69,89	1,14
Longue-courte ≥ 0												
Ridge	-1,18	9,40	0,69	1,06	37,96	1,17	-0,39	8,51	0,67	0,97	41,01	1,14
XGBoost	-0,25	9,06	0,55	0,77	67,75	1,11	-0,21	8,83	0,54	0,78	62,14	1,13
Ada Boost	-0,11	3,71	0,33	0,45	65,90	1,07	-0,48	10,74	0,67	0,98	65,87	1,16
Extra Trees	-0,01	11,34	0,65	0,91	64,33	1,14	-0,01	13,21	0,67	0,95	69,87	1,14
Critères de références												
Même Pondération		5,86	0,45	0,55	44,59	1,09		7,19	0,64	0,90	42,96	1,13
TSX60		1,76	0,23	0,31	49,80	1,05		1,76	0,23	0,31	49,80	1,05
SP500		5,28	0,42	0,53	53,25	1,09		5,28	0,42	0,53	53,25	1,09
NASDAQ		7,84	0,59	0,83	51,26	1,12		7,84	0,59	0,83	51,26	1,12

Notes : La première colonne du tableau correspond au R^2 hors-échantillon : $R^2_{H\hat{E}}$ (hors-échantillon). La deuxième correspond aux rendements annualisés (ou TCAC) : r^A . La troisième au ratio de Sharpe : SR . La quatrième au ratio de Sortino : ST . La cinquième correspond à la perte maximale : P^{max} (maximum drawdown). Enfin, la sixième colonne correspond au ratio oméga : Ω . Toutes les statistiques, à l'exception du SR , ST et Ω , sont exprimées en points de pourcentage. Les 3 premières lignes grisées se rapportent aux différents signaux des stratégies longues-courtes des portefeuilles et la quatrième ligne grisée correspond aux différents critères de références (benchmarks). La première ligne grisée correspond à la méthodologie ultérieurement définie de la section 3.2.1, la deuxième ligne grisée à celle de la section 3.2.2, la troisième ligne grisée à celle de la section 3.2.3 et pour la section des différents critères de références à la section 3.3. Les chiffres en **gras** sont la meilleure statistique de chaque section séparée par une ligne grisée. Les chiffres en **vert** représentent la meilleure statistique de l'ensemble de la colonne (c'est-à-dire pour toutes les stratégies de portefeuilles et pour les différents critères de références).

D'après les résultats présentés dans le tableau 4.1 pour le Canada et les États-Unis, c'est le modèle Extra Trees qui possède le meilleur R^2 hors-échantillon sur la période 2008-01 à 2024-01, avec un R^2 de -0,01 %, indiquant que la moyenne historique comme prédiction fait mieux, mais cette métrique ne constate pas si le modèle classe bien ou non les actions à acheter ou vendre. Plus précisément pour le Canada, les modèles non-linéaires affichent de meilleurs R^2 hors-échantillon que le modèle linéaire Ridge avec un R^2 hors-échantillon de -1,18 % pour ce dernier, alors que le R^2 de XGBoost est de -0,25 % et celui de Ada Boost est de -0,11 %. Toutefois, pour le marché US, c'est le modèle Ada Boost qui détient le R^2 hors-échantillon le plus faible avec un R^2 de -0,55 % comparativement à -0,39 % pour Ridge et -0,21 % pour XGBoost. Un R^2 négatif signifie que le modèle réalise en moyenne, une performance moindre que la simple moyenne historique des rendements pour prédire la période test. On peut supposer que cela est dû à un échantillon d'entraînement trop « petit », des hyperparamètres non optimaux (par exemple, un taux

d'apprentissage trop élevé ou une profondeur d'arbre trop limitée) ou encore que d'autres prédicteurs pourraient être plus efficace à la prédiction de rendements d'actifs comme des indicateurs techniques (moyenne mobile simple, indice de force relative...) ou financiers (*momentum*, volatilité historique...). Dans notre contexte ces axes d'améliorations ne sont pas appliqués, car cela se justifie par une volonté de garder un temps d'entraînement des modèles relativement court.

D'autre part, lorsque l'on analyse les rendements annualisés sur la période de 2008-01 à 2024-01 au Canada, c'est le modèle Ridge qui détient la meilleure performance avec 16,51 % de rendement annualisés en moyenne sur la période pour la stratégie de portefeuille longue-courte 10, comparativement à 7,84 % de rendements annualisés pour le critère de référence qui a le mieux performé, à savoir le NASDAQ. Dans le cas des États-Unis, le modèle ayant les meilleurs rendements annualisés est Extra Trees, toutes stratégies confondues, qui atteint 14,56 % de rendements annualisés pour la stratégie de portefeuille longue-courte 10, surperformant largement les critères de références, comme le S&P500 et le NASDAQ sur la même période. Le modèle Ridge pour la stratégie de portefeuille longue-courte 10 au Canada, se démarque également en détenant les meilleurs ratios de Sharpe et de Sortino avec respectivement un ratio de Sharpe de 0,81 et de Sortino de 1,16 sur la période d'analyse. Pour les États-Unis, c'est le modèle Extra Trees pour la stratégie de portefeuille longue-courte 10, qui possède également les ratios de Sharpe et de Sortino les plus élevés, avec un ratio de Sharpe de 0,71 et de Sortino de 1,02.

Ces résultats, où le modèle Ridge présente un R^2 hors-échantillon négatif, mais parvient néanmoins à générer une meilleure performance économique que d'autre modèle ayant un R^2 plus élevé à travers une stratégie de portefeuille longue-courte, ne sont pas sans précédent dans la littérature. Par exemple, Campbell et Thompson (2008) montrent qu'un faible pouvoir prédictif, mesuré par le R^2 hors-échantillon, ne signifie pas nécessairement une absence de valeur économique lorsqu'il s'agit de construire des portefeuilles. Leurs travaux indiquent qu'un modèle peut échouer à battre la moyenne historique des rendements sur le plan statistique, mais réussir à mieux classer les actifs entre gagnants et perdants, produisant ainsi de meilleurs rendements une fois exploités dans une stratégie d'investissement. D'autres études, comme celle de Rapach et al. (2010), renforcent cette idée que, même en l'absence de signaux fortement prédictifs pour le niveau des rendements, la


capacité à différencier la dynamique relative des actifs peut suffire à générer un avantage. Dans notre contexte, bien que le R^2 hors-échantillon du modèle Ridge soit négatif, ce modèle parvient vraisemblablement à mieux hiérarchiser les actions, permettant ainsi de sélectionner plus efficacement les titres à inclure dans les portefeuilles suivant une stratégie longue-courte et ainsi d'obtenir de meilleurs rendements annualisés.

D'autre part, on peut remarquer que le modèle qui semble le moins volatile sur la période d'analyse indépendamment du territoire est le modèle linéaire Ridge. En effet, le modèle ayant enregistré la perte maximale la plus faible sur la période 2008-01 à 2024-01 pour le Canada et les États-Unis est le modèle Ridge pour la stratégie de portefeuille longue-courte ≥ 0 , avec pour le Canada une perte maximale de 37,96 % et pour les États-Unis de 41,01 %. De plus, au Canada, le modèle Ridge possède le meilleur oméga ratio comparativement à tous les autres modèles, pour la stratégie de portefeuille longue-courte ≥ 0 , avec un oméga ratio de 1,17. Pour les États-Unis c'est le modèle Ada Boost pour la stratégie longue-courte ≥ 0 également, avec un oméga ratio de 1,16.


Les résultats semblent indiquer que les modèles d'apprentissage machine non-linéaires possèdent relativement de meilleurs R^2 hors-échantillons que le modèle linéaire. En revanche, cette métrique n'est pas toujours un bon indicateur de performance en termes de rendement annualisés, comme on a pu noter les relatives bonnes performances du modèle Ridge à travers les différentes stratégies et comparativement aux critères de références. Il est possible que le modèle Ridge a également pu aussi bien performer du à l'absence d'un nombre trop élevé de données d'entraînement, naviguant mieux que les modèles non-linéaires nécessitant plus de données d'entraînement afin de mieux comprendre la structure des données.

La figure 4.1 illustre les rendements cumulatifs obtenus au Canada et aux États-Unis à l'aide de différentes stratégies de portefeuilles longues-courtes pour les périodes de 2008-01 à 2024-01. Les stratégies évaluées incluent les portefeuilles suivant des stratégies longues-courtes basées sur des seuils de sélection de 10, 20, et supérieurs ou inférieurs à zéro. Les modèles employés sont les mêmes que ceux de la figure 4.1 à savoir Ridge, AdaBoost, XGBoost, et Extra Trees, dont nous évaluons l'évolution de leurs rendements cumulatifs en logarithme. Nous effectuons également une comparaison à nos stratégies de référence à savoir la stratégie de portefeuille longue pondéré également (*Equally Weighted* sur le graphique) et les indices TSX60, S&P500, et NASDAQ.


Figure 4.1 : Rendements cumulatifs au Canada et aux États-Unis, stratégies de portefeuilles longues-courtes 10, 20 et ≥ 0 , 2008-01 à 2024-01 (régression)



(a) Longue-courte 10, Canada



(b) Longue-courte 10, États-Unis




(c) Longue-courte 20, Canada



(d) Longue-courte 20, États-Unis



(e) Longue-courte ≥ 0 , Canada



(f) Longue-courte ≥ 0 , États-Unis

En premier lieu, on peut noter que les rendements cumulatifs à travers les stratégies semblent être relativement corrélés entre eux, c'est-à-dire qu'ils évoluent dans les mêmes directions, en des proportions similaires. Ces résultats sont relativement en concordance avec ceux de Chen et al. (2024) et Hanauer et Kalsbach (2023), qui obtiennent des portefeuilles lors de prédictions mensuelles hors-échantillon fortement corrélé. Selon eux, cela peut être expliqué par plusieurs facteurs, comme l'utilisation de caractéristiques communes, la similarité des signaux économiques exploités, et la structure méthodologique partagée entre les modèles, tels que l'entraînement sur des fenêtres similaires. De plus, l'utilisation d'un univers d'actions étroitement lié aux indices de référence (TSX60 pour le Canada et S&P500 pour les États-Unis) pourrait contribuer à la corrélation observée entre les différentes stratégies de portefeuille. En effet, en sélectionnant des titres qui constituent le socle même de la performance de ces indices, cela réduit mécaniquement la dispersion potentielle des rendements. Autrement dit, même si chaque algorithme dispose de sa propre logique (linéaire et non-linéaire) et de ses propres hyperparamètres, ils s'appuient ainsi sur une base d'actions déjà fortement corrélées entre elles et représentative d'un même marché.

D'un autre côté, comme l'illustre déjà le tableau 4.1, les portefeuilles élaborés à l'aide des modèles d'apprentissage machine semblent présenter une volatilité plus élevée que les critères de référence. En effet, en s'appuyant sur la figure 4.1, on remarque en effet qu'au cours des périodes de crise économique, notamment en 2008 avec la crise des subprimes et en 2020 lors de la pandémie de COVID-19, les fluctuations de marché ont été particulièrement marquées. Ces deux événements ont ainsi engendré une forte incertitude, augmentant la volatilité dans les marchés, aussi bien au Canada qu'aux États-Unis. Dans ce contexte, les modèles d'apprentissage machine, ont réagi avec plus de sensibilité aux variations rapides des données, en surpondérant certains mouvements de marché. Cette sensibilité accrue peut se traduire par des écarts de performance plus prononcés, à la hausse comme à la baisse, comme on a pu le constater dans le tableau 4.1. Cependant, les critères de référence ont été moins exposés à la volatilité du marché. On peut supposer que ces derniers, en s'appuyant sur un univers relativement plus large d'investissement, et de leur construction reposant sur une large diversification, subissent une moindre sensibilité aux variations de marché.

4.2 Résultats des algorithmes de classification en hors-échantillon

Dans cette partie, nous réalisons une analyse des résultats hors-échantillon pour le Canada et les États-Unis, de différents modèles d'apprentissage machine de classifications pour la période de 2008-01 à 2024-01 (les résultats pour les autres périodes sont disponibles en annexe). Ces résultats sont analysés selon nos métriques définies ultérieurement dans le chapitre 3. Les résultats obtenus sont présentés dans le tableau 4.2, qui est un résumé statistique des prédictions mensuelles réalisées sur la période 2008-01 à 2024-01. Nous comparons un modèle linéaire, à savoir le modèle de régression logistique, à trois autres modèles non-linéaires dans leurs formes de classification que sont XGBoost, Ada Boost et Extra Trees, analysés selon chacune de nos métriques. Nous utilisons notre stratégie de portefeuille longue-courte propre à la classification définie dans la section 3.2.3. Plus particulièrement cette stratégie consiste à sélectionner toutes les actions avec des rendements prévus positifs et négatifs où les actions avec des rendements prévus positifs sont pondérées de manière égale en position longue, et celles avec des rendements prévus négatifs sont pondérées de manière égale en position courte.

Tableau 4.2 : Résumé statistique des prédictions mensuelles, 2008-01 à 2024-01 (classification)

	Canada							États-Unis						
	SP	PT	r^A	SR	ST	P^{max}	Ω	SP	PT	r^A	SR	ST	P^{max}	Ω
Longue-courte ≥ 0														
Régression logistique	0,56	0,13	8,96	0,62	0,86	65,99	1,15	0,58	0,11	8,81	0,64	0,91	42,04	1,13
XGBoost Classification	0,57	0,18	6,50	0,49	0,69	66,17	1,11	0,51	0,52	11,36	0,61	0,87	69,54	1,13
Hist Gradient Boosting Classification	0,66	0,01**	5,88	0,55	0,76	37,96	1,12	0,52	0,52	8,15	0,53	0,75	64,27	1,11
Extra Trees Classification	0,56	0,20	5,25	0,49	0,69	42,89	1,11	0,51	0,72	7,29	0,61	0,88	43,86	1,13
Critères de références														
Même Pondération			5,86	0,45	0,55	44,59	1,09			7,19	0,64	0,90	42,96	1,13
TSX60			1,76	0,23	0,31	49,80	1,05			1,76	0,23	0,31	49,80	1,05
SP500			5,28	0,42	0,53	53,25	1,09			5,28	0,42	0,53	53,25	1,09
NASDAQ			7,84	0,59	0,83	51,26	1,12			7,84	0,59	0,83	51,26	1,12

Notes : La première colonne du tableau correspond au score de précision : SP. La deuxième correspond au test de la statistique du test de Pesaran-Timmerman : PT. Pour cette statistique dans le tableau, 1* indique que les résultats sont significatifs à un niveau de confiance de 90 % ($p < 0,1$), 2* à 95 % ($p < 0,05$) et 3* à 99 % ($p < 0,01$). La troisième correspond aux rendements annualisés (ou TCAC) : r^A . La quatrième au ratio de Sharpe : SR. La cinquième au ratio de Sortino : ST. La sixième correspond à la perte maximale : P^{max} (maximum drawdown). Enfin, la septième colonne correspond au ratio oméga : Ω . Toutes les statistiques, à l'exception du SR, ST et Ω , sont exprimées en points de pourcentage. La première ligne grisée se rapporte au signal de la stratégie longue-courte de classification des portefeuilles défini dans la section 3.2.3 et la deuxième ligne grisée correspond aux différents critères de références (benchmarks) mentionnés à la section 3.3. Les chiffres en **gras** sont la meilleure statistique de chaque section séparée par une ligne grisée. Les chiffres en **vert** représentent la meilleure statistique de l'ensemble de la colonne (c'est-à-dire pour toutes les stratégies de portefeuilles et pour les différents critères de références).

La première colonne du tableau 4.2 indique le score de précision des modèles, c'est-à-dire qu'elle est la proportion de prédictions correctes (hausse ou baisse) réalisées. Les valeurs au Canada varient entre 0,55 et 0,66, ce qui signifie qu'entre 55 % et 66 % des prédictions mensuelles réalisées

sont exactes. Aux États-Unis les valeurs fluctuent plus entre 0,51 et 0,58, ce qui indique que entre 51 % et 58 % des prédictions réalisées sont correctes. Au Canada, c'est le modèle Hist Gradient Boosting Classification qui se démarque, avec un score de précision de 0,66 alors qu'aux États-Unis c'est le modèle linéaire de régression logistique qui performe relativement le mieux, avec un score de précision de 0,58 sur la période d'analyse. Un score de précision supérieur à 0,50 suggère que le modèle est meilleur qu'un simple lancer de pièce pour prévoir la direction des rendements, mais cela ne garantit pas pour autant une surperformance économique.

Dans la deuxième colonne du tableau 4.2, il est utilisé comme métrique la statistique du test de Pesaran-Timmerman, qui évalue l'habileté du modèle à prédire correctement les hausses et les baisses, en tenant compte de la dépendance temporelle (autocorrélation) des rendements. Dans les résultats pour les algorithmes de classification, seul le modèle Hist Gradient Boosting Classification est significatif au seuil de 95%. Cela indique que les prédictions directionnelles du modèle sont relativement fiables, avec un niveau de confiance élevé, et qu'elles ne peuvent pas être attribuées au hasard avec une probabilité supérieure à 5 %.


Toutefois, une valeur haute de la statistique du test de Pesaran-Timmerman n'indique pas toujours que le modèle performera bien économiquement. En effet, lorsque nous regardons la métrique des rendements annuels au Canada, c'est le modèle linéaire de régression logistique qui performe le mieux avec un rendement annualisé de 8,96 % entre 2008-01 à 2024-01. Aux États-Unis, c'est le modèle XGBoost avec un rendement annualisé de 11,36 % sur la même période. On constate ainsi que, globalement, les rendements se situent dans une fourchette allant de 5 à 9 % pour le Canada, et entre 7 et 12 % pour les États-Unis, surpassant majoritairement les critères de références.

Pour la métrique du ratio de Sharpe et de Sortino, c'est le modèle de régression logistique qui a le mieux performé comparativement aux autres modèles. En effet, pour le Canada, le modèle détient un ratio de Sharpe de 0,62 et de Sortino de 0,86, relativement moins élevé qu'aux États-Unis, où le ratio de Sharpe s'élève à 0,64 et le ratio de Sortino à 0,91. De plus, lorsqu'on analyse la métrique de la perte maximale, c'est également le modèle de régression logistique qui dispose de la valeur la plus faible, avec une perte maximale de 42,04 %. Pour le Canada, c'est le modèle de Hist Gradient Boosting Classification qui détient la valeur la plus faible avec une perte maximale de 37,96 %. Enfin, le modèle de régression logistique possède également le meilleur ratio oméga sur

les deux territoires d'analyse, avec un ratio oméga de 1,15 pour le Canada et 1,13 pour les États-Unis.

La figure 4.2 illustre les rendements cumulatifs obtenus au Canada et aux États-Unis pour la stratégie de portefeuille longue-courte des algorithmes de classification pour les périodes de 2008-01 à 2024-01. La stratégie utilisée est une stratégie longue-courte basée sur des seuils de sélection supérieurs ou inférieurs à zéro, utilisant les prédictions des modèles à chaque période pour cela, comme décrit dans la section 3.2.3. Les modèles employés sont les mêmes que ceux de la figure 4.1 à savoir Ridge, AdaBoost, XGBoost, et Extra Trees, dont nous évaluons l'évolutions de leurs rendements cumulatifs en logarithme. Nous réalisons également une comparaison à nos stratégies de référence à savoir la stratégie de portefeuille longue pondéré également et les indices TSX60, S&P500, et NASDAQ.

Figure 4.2 : Rendements cumulatifs au Canada et aux États-Unis, stratégie de portefeuille longue-courte ≥ 0 , 2008-01 à 2024-01 (classification)



Nous dénotons dans la figure 4.2 pour le Canada et les États-Unis que tous les modèles de classification surpassent les critères de références en termes de rendement annualisé (hormis le modèle Extra Trees Classification aux États-Unis qui performe moins bien que le NASDAQ). De surcroît au Canada, le modèle XGBoost a particulièrement souffert de la crise des subprimes en 2008, affichant une volatilité nettement plus prononcée que les autres modèles. En revanche, en 2020, lors de la pandémie de COVID-19, c'est le modèle de régression logistique qui a été le plus impacté par le choc initial, bien qu'il ait enregistré une reprise marquée par la suite, se redressant

fortement après cette période de haute volatilité. Pour les États-Unis, les modèles ont adopté des trajectoires de rendements annualisés plus homogènes, bien que le modèle XGBoost qui a le mieux performé sur la période d'analyse, a également été relativement fortement impacté par la crise de 2020. Toutefois, on observe que ce dernier a pu récupérer de manière relativement courte ses pertes dans les mois qui ont succédé.


Lorsque nous comparons les résultats de nos algorithmes de régression et de classification, on peut dénoter certains points intéressants. En effet, les algorithmes d'apprentissage machine de régressions paraissent obtenir de meilleurs rendements annualisés et ratio oméga en moyenne, comparativement aux algorithmes de classification. Toutefois, les modèles de régressions semblent relativement plus volatiles que les modèles de classification. On peut supposer que cette différence peut s'expliquer notamment par la logique de sélection qui n'est pas la même. En effet, en classification, un modèle comme la régression logistique associe chaque action à une probabilité (hausse ou baisse) en achetant à chaque période les actions prédites positives en position longue et négatives en position courte. En revanche, dans le cadre de la régression, on prévoit un niveau de rendement (par exemple +1 %, +5 %, -2 %) que l'on peut décider selon le signal, par exemple, de ne retenir en position longue que les 10 ou 20 valeurs affichant les plus forts rendements prévus (même opération pour les actions dont le rendement prévu est négatif en position courte). Ainsi, les stratégies des portefeuilles suivant des signaux 10, 20 se montrent plus « concentrées » (on ne choisit que les rendements extrêmes), permettant de mieux capter les écarts de marchés. Plus précisément, cette focalisation sur un nombre restreint de titres accentue la sensibilité du portefeuille aux erreurs de prévision. Dès lors qu'un ou deux actifs mal évalués se retrouvent dans la sélection des seuils 10 ou 20, ils peuvent pénaliser fortement la performance et contribuer à une volatilité plus élevée. En classification, au contraire, les positions sont réparties sur un ensemble relativement plus large réduisant la concentration mais limitant potentiellement aussi la capacité à exploiter les écarts de rendements les plus importants. Enfin, on pourrait s'attendre à des résultats comparables entre la stratégie de régression et de classification prenant des positions longues sur les actions anticipées à la hausse et courtes sur les actions escomptées à la baisse, mais les résultats divergent relativement. Cela peut être partiellement attribué à la construction distincte des modèles entre ceux de régression et de classification, notamment en ce qui concerne leur manière de traiter les données et d'assigner des prédictions.

4.3 Importance des variables (SHAP)

La figure 4.3 illustre les résultats obtenus avec la méthode SHAP de notre modèle de classification Hist Gradient Boosting Classification entre 2008-01 et 2024-01. Cette méthodologie permet de mettre en évidence l'influence de chaque variable sur les prédictions de rendement des actions, à la fois au niveau global comme on peut le voir sur la figure (a) et (b), mais aussi au niveau local avec la figure (c) et (d). Cette décomposition permet d'identifier pour chaque variable son importance moyenne dans la décision (analyse globale) ainsi que la façon dont elle affecte individuellement certaines observations (analyse locale). Plus particulièrement, sur l'axe horizontal de la figure, la valeur SHAP révèle si la variable fait monter la prévision (points à droite de zéro) ou la fait baisser (points à gauche). De surcroît, la couleur, du bleu au rouge, traduit l'intensité de la variable (le bleu étant équivalent à une valeur faible, et le rouge à une valeur élevée).


On peut noter dans la figure 4.3, que pour les variables globales au Canada, les variables *TSX_LO* (bourse de Toronto plus bas) et *TSX_CLO* (bourse de Toronto clôture) arrivent en tête des facteurs explicatifs les plus influents. Ces derniers sont suivis par *OIL_ALB_new* (production de pétrole en Alabama en m^3), *TOT_HRS_CAN* (heures totales travaillées au Canada), *IMP_CONS_BP_new* (importations de biens de consommation) et *EMP_CAN* (emploi total au Canada). De plus, comme on peut l'observer dans la figure 4.3, les familles de variables les plus représentées sont celles des marchés boursiers, marché du travail, les prix ainsi que la production. Aux États-Unis, les facteurs explicatifs les plus influents sur la période d'analyse sont *WPSFD49207* (biens finis) et *UEMP15T26* (chômeurs civils 15-26 semaines). Également, les variables *BAA* (rendement des obligations d'entreprises de notation Baa), *IPNCONGD* (biens de consommation non durables), *AMDMUOx* (commandes non exécutées biens durables), *BAAFFM* (différentiel entre le rendement des obligations d'entreprise Baa et le taux des fonds fédéraux) et *UEMP15OV* (chômeurs civils 15 semaines et plus), figurent parmi les plus déterminants. Par ailleurs, les familles de variables les plus représentées aux États-Unis sont celles des prix, marché du travail et taux d'intérêts et taux de change. En addition, on remarque que la distribution des variables en termes d'importance pour l'analyse globale est relativement plus asymétrique au Canada qu'aux États-Unis. En ce sens, pour le Canada, un plus petit nombre de variables influence les prédictions comparativement aux États-Unis, où l'importance est répartie de manière relativement plus uniforme entre un nombre plus grand de variables.

Figure 4.3 : SHAP importance des variables, 2008-01 à 2024-01



(a) Analyse globale, Canada

(b) Analyse globale, États-Unis



(c) Analyse locale, Canada

(d) Analyse locale, États-Unis

À propos de l'analyse locale pour le Canada de la variable *TSX_LO* (bourse de Toronto plus bas), on relève une concentration de points rouge à droite de l'axe neutre (valeur de SHAP 0) et des points bleus en moins grand nombre plus dispersés à gauche. L'amas de points rouge indiquant des valeurs élevées de *TSX_LO*, informe qu'elles contribuent positivement à la prédiction. En contraste, les points bleus à gauche de la figure correspondant à une faible valeur de *TSX_LO*, rapportant que ces valeurs contribuent négativement aux prédictions du modèle. Pour la variable *TSX_CLO* (bourse de Toronto clôture), les résultats sont relativement moins clairs, avec un amas relativement dispersé de points bleus et rouge à gauche de l'axe neutre, et à droite des points rouges. On peut interpréter cela que, dans la partie gauche certaines valeurs élevées et faibles de *TSX_CLO* impactent négativement les prédictions du modèle, indiquant un certain contextualisme de l'effet de cette variable sur les prédictions. Toutefois, la partie droite indique que des valeurs élevées de *TSX_CLO*, signifiant une contribution positive à la prédiction. Pour la variable *OIL_ALB_new* (production de pétrole en Alabama en m^3), on relève des points rouges se situant à gauche de l'axe neutre, notifiant que des valeurs élevées de la variable contribuent négativement aux prédictions du modèle. Pour les autres variables, on dénote des amas de points plus centrés vers 0, signifiant que ce soit des valeurs élevées ou faibles des variables, elles n'ont que peu d'impacts sur les prédictions.

Par ailleurs, pour l'analyse locale aux États-Unis, on peut observer dans la figure 4.3 pour la variable *WPSFD49207* (biens finis), que des valeurs élevées de cette dernière impactent négativement les prédictions. En contraste avec les valeurs faibles qui impactent positivement les prédictions, mais dans une moindre mesure, car elles se situent relativement proches de l'axe neutre. Pour la variable *UEMP15T26* (chômeurs civils 15-26 semaines), les valeurs faibles de cette variable contribuent négativement aux prédictions alors que des valeurs élevées participent positivement aux prédictions. D'ailleurs, la variable de la famille du marché du travail *UEMP15OV* (chômeurs civils 15 semaines et plus), contribue similairement aux prédictions du modèle que la variable *UEMP15T26*, ayant des valeurs élevées et faibles réparties relativement de la même manière. D'autre part, pour la variable *BAA* (rendement des obligations d'entreprises de notation Baa), on note sur la figure des valeurs hautes des rendements des obligations de notation Baa contribuent négativement aux prédictions du modèle, tandis que des valeurs faibles de cette dernière, contribuent relativement positivement aux prédictions.

CONCLUSION

Dans ce mémoire, nous nous sommes intéressés à l'exercice de prédire les rendements d'actions de plusieurs titres à une fréquence mensuelle, au Canada et aux États-Unis à l'aide de différents algorithmes d'apprentissage machine. Nous avons utilisé différents algorithmes d'apprentissage machine, linéaire et non-linéaire, de régression et de classification, en hors-échantillon sur la période de 2008-01 à 2024-01 (les autres périodes étant disponibles en annexe). L'objectif a été de construire des portefeuilles suivant des stratégies longue-courte à partir de ces prédictions selon différents signaux (top 10, top 20 ainsi que positif et négatif). Nous avons construits des portefeuilles que nous avons analysés à travers plusieurs métriques afin de comprendre quels modèles ont été les plus performants et si certains types de modèles (linéaire et non-linéaire) et familles (classification et régression) performaient mieux que les autres.

Concernant nos résultats, on a pu déterminer pour les modèles de régressions, que c'est le modèle linéaire Ridge qui possède le rendement annualisé le plus élevé avec 16,51 % pour la stratégie de portefeuille longue-courte top 10 au Canada, avec un ratio de Sharpe de 0,81 sur la période d'analyse. Concernant les États-Unis, c'est le modèle Extra Trees pour la stratégie de portefeuille longue-courte top 10 également, avec un rendement annualisé de 14,56 % et un ratio de Sharpe de 0,71. Pour les modèles de classification au Canada, c'est le modèle de régression logistique qui s'est illustré avec 8,96 % de rendements annualisés et un ratio de Sharpe de 0,62. Pour les États-Unis c'est le modèle XGBoost Classification qui a affiché les meilleures performances, en obtenant 11,36 % de rendements annualisés et un ratio de Sharpe de 0,61. Les résultats ainsi obtenus, semble indiquer que la plupart des modèles battent systématiquement le marché, avec une performance du TSX60 sur la période de 1,76 % et du S&P500 de 5,28 % en terme de rendements annualisés. Par ailleurs, si les modèles non-linéaires se distinguent par un pouvoir prédictif hors-échantillon supérieur à celui des modèles linéaires, cela ne se traduit pas systématiquement par une meilleure performance économique. Toutefois, il conviendrait de mener des tests complémentaires afin de vérifier la robustesse de ces résultats dans d'autres configurations ou contextes de marché. Les résultats soulignent également que les variables les plus importantes dans la prédiction de rendements au Canada sont les variables de prix, tels que *TSX_LO* et *TSX_CLO*. Et pour les États-Unis, ce sont majoritairement des variables de prix et du marché du travail, comme *WPSFD49207*

(biens finis) et *UEMP15T26* (chômeurs civils 15-26 semaines) qui figurent parmi les principaux facteurs explicatifs.

Bien que ce mémoire ait révélé l'intérêt d'intégrer des données macroéconomiques et des techniques d'apprentissage machine pour prédire les rendements d'actifs afin de construire des portefeuilles, elle ouvre également plusieurs perspectives de recherche. En premier lieu, l'utilisation de facteurs financiers éprouvés, tels que le momentum, la taille ou les ratios valeur/croissance, constituerait un enrichissement notable afin d'améliorer la précision prédictive des modèles. De plus, en terme de type de données pour l'entraînement des modèles, on pourrait intégrer des données non structurées, telles que les signaux issus de l'analyse des sentiments (*sentometrics*), notamment discuté par Ardia et al. (2021), ou encore des signaux de Google *Trends*, permettant d'étudier le nombre de requête relatif d'un certain terme en particulier à travers le temps. En second lieu, il serait pertinent d'explorer des méthodes de pondération alternatives dans la construction des portefeuilles. En effet, une pondération basée sur le classement (*ranking*) des prédictions permettrait de concentrer l'allocation des poids sur les titres affichant les rendements prévus les plus élevés. Troisièmement, l'accroissement de la granularité des données pourrait affiner encore les prévisions. En ce sens, l'emploi de données de plus haute fréquence (journalières ou intrajournalières) faciliterait le suivi de dynamiques de marché à court terme et permettrait des rééquilibrages plus fréquents des modèles. Toutefois, ces approches engendreraient une complexité computationnelle plus élevée, ainsi qu'un risque accru de surajustement, appelant un contrôle rigoureux de la qualité des données et des hyperparamètres. Enfin, on pourrait intégrer des coûts de transaction pour un réalisme accru de nos stratégies.


ANNEXE A RÉSULTATS COMPLÉMENTAIRES RÉGRESSIONS

Tableau A.1 : Résumé statistique des prédictions mensuelles, 2008-01 à 2012-01 (régression)


	Canada						États-Unis					
	$R^2_{H\hat{E}}$	r^A	SR	ST	P^{max}	Ω	$R^2_{H\hat{E}}$	r^A	SR	ST	P^{max}	Ω
Longue-courte 10												
Ridge	-1,70	10,07	0,54	0,78	61,22	1,10	-0,43	4,78	0,40	0,59	71,34	1,08
XGBoost	0,08	0,70	0,26	0,36	69,77	1,05	-0,25	2,96	0,36	0,52	76,27	1,07
Ada Boost	-0,07	8,87	0,50	0,73	62,05	1,09	-0,46	6,76	0,44	0,64	72,18	1,09
Extra Trees	0,00	1,01	0,28	0,39	70,50	1,05	-0,01	7,47	0,46	0,66	66,57	1,09
Longue-courte 20												
Ridge	-1,70	6,94	0,44	0,63	60,48	1,09	-0,43	3,44	0,35	0,51	70,78	1,07
XGBoost	0,08	4,27	0,35	0,50	63,27	1,07	-0,25	1,96	0,32	0,45	73,99	1,06
Ada Boost	-0,07	5,32	0,39	0,55	62,95	1,08	-0,46	4,51	0,38	0,55	69,63	1,08
Extra Trees	0,00	4,47	0,36	0,51	62,57	1,07	-0,01	3,44	0,35	0,50	69,89	1,07
Longue-courte ≥ 0												
Ridge	-1,70	6,22	0,48	0,69	37,13	1,09	-0,43	4,86	0,39	0,56	41,02	1,08
XGBoost	0,08	-4,24	0,07	0,10	68,11	1,01	-0,25	2,31	0,30	0,43	66,82	1,06
Ada Boost	-0,07	-2,93	0,07	0,10	65,89	1,02	-0,46	4,20	0,35	0,49	53,21	1,07
Extra Trees	0,00	4,20	0,35	0,49	63,22	1,07	-0,01	2,89	0,34	0,48	69,88	1,07
Critères de références												
Même Pondération		1,29	0,19	0,27	40,10	1,04		2,50	0,27	0,38	42,96	1,05
TSX60		-2,61	-0,02	-0,02	49,80	1,00		-2,61	-0,02	-0,02	49,80	1,00
SP500		-2,40	-0,01	-0,02	53,25	1,00		-2,40	-0,01	-0,02	53,25	1,00
NASDAQ		-0,03	0,15	0,21	51,26	1,03		-0,03	0,15	0,21	51,26	1,03

Notes : La première colonne du tableau correspond au R^2 hors-échantillon : $R^2_{H\hat{E}}$ (hors-échantillon). La deuxième correspond aux rendements annualisés (ou TCAC) : r^A . La troisième au ratio de Sharpe : SR . La quatrième au ratio de Sortino : ST . La cinquième correspond à la perte maximale : P^{max} (maximum drawdown). Enfin, la sixième colonne correspond au ratio oméga : Ω . Toutes les statistiques, à l'exception du SR , ST et Ω , sont exprimées en points de pourcentage. Les 3 premières lignes grisées se rapportent aux différents signaux des stratégies longues-courtes des portefeuilles et la quatrième ligne grisée correspond aux différents critères de références (benchmarks). La première ligne grisée correspond à la méthodologie ultérieurement définie de la section 3.2.1, la deuxième ligne grisée à celle de la section 3.2.2, la troisième ligne grisée à celle de la section 3.2.3 et pour la section des différents critères de références à la section 3.3. Les chiffres en **gras** sont la meilleure statistique de chaque section séparée par une ligne grisée. Les chiffres en **vert** représentent la meilleure statistique de l'ensemble de la colonne (c'est-à-dire pour toutes les stratégies de portefeuilles et pour les différents critères de références).


Figure A.1 : Rendements cumulatifs au Canada et aux États-Unis, stratégies de portefeuilles longues-courtes 10, 20 et ≥ 0 , 2008-01 à 2012-01 (régression)




(a) Longue-courte 10, Canada




(b) Longue-courte 10, États-Unis




(c) Longue-courte 20, Canada



(d) Longue-courte 20, États-Unis



(e) Longue-courte ≥ 0 , Canada



(f) Longue-courte ≥ 0 , États-Unis

Tableau A.2 : Résumé statistique des prédictions mensuelles, 2012-01 à 2020-01 (régression)


	Canada						États-Unis					
	R^2_{HE}	r^A	SR	ST	P^{max}	Ω	R^2_{HE}	r^A	SR	ST	P^{max}	Ω
Longue-courte 10												
Ridge	-0,35	16,04	1,02	1,51	31,17	1,19	-0,15	18,17	1,06	1,51	33,36	1,21
XGBoost	-0,04	19,26	1,19	1,77	25,53	1,22	-0,05	20,33	1,18	1,69	32,21	1,23
Ada Boost	-0,78	14,31	0,94	1,37	30,24	1,17	-0,18	23,95	1,33	1,93	33,74	1,26
Extra Trees	-0,01	17,16	1,02	1,50	38,70	1,19	-0,07	21,60	1,23	1,76	28,60	1,24
Longue-courte 20												
Ridge	-0,35	15,66	1,15	1,66	26,84	1,21	-0,15	19,83	1,18	1,68	30,36	1,23
XGBoost	-0,04	17,18	1,25	1,82	27,03	1,23	-0,05	20,34	1,21	1,74	31,25	1,24
Ada Boost	-0,78	17,28	1,26	1,82	28,75	1,23	-0,18	20,29	1,20	1,72	33,50	1,24
Extra Trees	-0,01	16,73	1,24	1,80	28,55	1,23	-0,07	19,95	1,19	1,71	29,64	1,24
Longue-courte ≥ 0												
Ridge	-0,35	9,49	0,72	1,10	27,21	1,19	-0,15	9,97	1,18	1,69	16,70	1,23
XGBoost	-0,04	12,84	0,69	1,16	46,03	1,16	-0,05	15,74	1,23	1,81	19,67	1,25
Ada Boost	-0,78	10,73	0,69	1,03	45,68	1,14	-0,18	18,09	1,30	1,94	22,70	1,27
Extra Trees	-0,01	16,27	1,22	1,77	27,05	1,23	-0,07	19,67	1,18	1,69	31,34	1,23
Critères de références												
Même Pondération		7,92	1,17	1,70	13,56	1,22		9,89	1,18	1,68	16,71	1,23
TSX60		2,93	0,45	0,61	24,36	1,08		2,93	0,45	0,61	24,36	1,08
SP500		8,34	0,98	1,36	19,78	1,20		8,34	0,98	1,36	19,78	1,20
NASDAQ		11,11	1,07	1,52	23,64	1,21		11,11	1,07	1,52	23,64	1,21

Notes : La première colonne du tableau correspond au R^2 hors-échantillon : R^2_{HE} (hors-échantillon). La deuxième correspond aux rendements annualisés (ou TCAC) : r^A . La troisième au ratio de Sharpe : SR. La quatrième au ratio de Sortino : ST. La cinquième correspond à la perte maximale : P^{max} (maximum drawdown). Enfin, la sixième colonne correspond au ratio oméga : Ω . Toutes les statistiques, à l'exception du SR, ST et Ω , sont exprimées en points de pourcentage. Les 3 premières lignes grisées se rapportent aux différents signaux des stratégies longues-courtes des portefeuilles et la quatrième ligne grisée correspond aux différents critères de références (benchmarks). La première ligne grisée correspond à la méthodologie ultérieurement définie de la section 3.2.1, la deuxième ligne grisée à celle de la section 3.2.2, la troisième ligne grisée à celle de la section 3.2.3 et pour la section des différents critères de références à la section 3.3. Les chiffres en **gras** sont la meilleure statistique de chaque section séparée par une ligne grisée. Les chiffres en **vert** représentent la meilleure statistique de l'ensemble de la colonne (c'est-à-dire pour toutes les stratégies de portefeuilles et pour les différents critères de références).


Figure A.2 : Rendements cumulatifs au Canada et aux États-Unis, stratégies de portefeuilles longues-courtes 10, 20 et ≥ 0 , 2012-01 à 2020-01 (régression)




(a) Longue-courte 10, Canada




(b) Longue-courte 10, États-Unis



(c) Longue-courte 20, Canada



(d) Longue-courte 20, États-Unis



(e) Longue-courte ≥ 0 , Canada



(f) Longue-courte ≥ 0 , États-Unis

Tableau A.3 : Résumé statistique des prédictions mensuelles, 2020-01 à 2024-01 (régression)


	Canada						États-Unis					
	R^2_{HE}	r^A	SR	ST	P^{max}	Ω	R^2_{HE}	r^A	SR	ST	P^{max}	Ω
Longue-courte 10												
Ridge	-2,55	21,45	0,87	1,22	62,79	1,19	-0,90	9,49	0,52	0,74	55,45	1,11
XGBoost	0,05	6,05	0,42	0,58	69,72	1,09	-0,22	11,62	0,59	0,84	50,63	1,12
Ada Boost	-0,42	2,39	0,30	0,40	66,92	1,06	-1,19	9,55	0,52	0,74	55,78	1,11
Extra Trees	-0,01	8,28	0,49	0,67	63,42	1,10	-0,14	9,57	0,52	0,74	56,13	1,11
Longue-courte 20												
Ridge	-2,55	12,13	0,62	0,86	60,80	1,14	-0,90	11,72	0,59	0,84	56,53	1,12
XGBoost	0,05	7,75	0,48	0,65	65,11	1,10	-0,22	11,11	0,57	0,81	57,11	1,12
Ada Boost	-0,42	5,25	0,39	0,53	65,13	1,09	-1,19	10,23	0,55	0,77	56,11	1,11
Extra Trees	-0,01	9,18	0,52	0,72	62,15	1,12	-0,14	10,30	0,55	0,78	55,71	1,11
Longue-courte ≥ 0												
Ridge	-2,55	4,62	0,42	0,57	38,14	1,09	-0,90	6,39	0,51	0,72	31,61	1,11
XGBoost	0,05	13,43	0,63	0,89	64,55	1,14	-0,22	6,79	0,44	0,62	56,78	1,09
Ada Boost	-0,42	1,38	0,22	0,31	53,15	1,06	-1,19	9,20	0,63	0,91	38,13	1,13
Extra Trees	-0,01	8,16	0,49	0,66	64,54	1,11	-0,14	6,85	0,56	0,79	32,08	1,12
Critères de références												
Même Pondération		5,64	0,51	0,69	36,23	1,11		6,70	0,56	0,79	30,59	1,12
TSX60		3,58	0,36	0,48	37,42	1,08		3,58	0,36	0,48	37,42	1,08
SP500		6,82	0,54	0,74	33,92	1,10		6,82	0,54	0,74	33,92	1,10
NASDAQ		9,06	0,60	0,84	36,40	1,11		9,06	0,60	0,84	36,40	1,11

Notes : La première colonne du tableau correspond au R^2 hors-échantillon : R^2_{HE} (hors-échantillon). La deuxième correspond aux rendements annualisés (ou TCAC) : r^A . La troisième au ratio de Sharpe : SR. La quatrième au ratio de Sortino : ST. La cinquième correspond à la perte maximale : P^{max} (maximum drawdown). Enfin, la sixième colonne correspond au ratio oméga : Ω . Toutes les statistiques, à l'exception du SR, ST et Ω , sont exprimées en points de pourcentage. Les 3 premières lignes grisées se rapportent aux différents signaux des stratégies longues-courtes des portefeuilles et la quatrième ligne grisée correspond aux différents critères de références (benchmarks). La première ligne grisée correspond à la méthodologie ultérieurement définie de la section 3.2.1, la deuxième ligne grisée à celle de la section 3.2.2, la troisième ligne grisée à celle de la section 3.2.3 et pour la section des différents critères de références à la section 3.3. Les chiffres en **gras** sont la meilleure statistique de chaque section séparée par une ligne grisée. Les chiffres en **vert** représentent la meilleure statistique de l'ensemble de la colonne (c'est-à-dire pour toutes les stratégies de portefeuilles et pour les différents critères de références).

Figure A.3 : Rendements cumulatifs au Canada et aux États-Unis, stratégies de portefeuilles longues-courtes 10, 20 et ≥ 0 , 2020-01 à 2024-01 (régression)




(a) Longue-courte 10, Canada



(b) Longue-courte 10, États-Unis



(c) Longue-courte 20, Canada



(d) Longue-courte 20, États-Unis



(e) Longue-courte ≥ 0 , Canada



(f) Longue-courte ≥ 0 , États-Unis

ANNEXE B


RÉSULTATS COMPLÉMENTAIRES CLASSIFICATIONS

Tableau B.1 : Résumé statistique des prédictions mensuelles, 2008-01 à 2012-01 (classification)

	Canada							États-Unis						
	SP	PT	r^A	SR	ST	P^{max}	Ω	SP	PT	r^A	SR	ST	P^{max}	Ω
Stratégie longue-courte ≥ 0														
Régression logistique	0,53	0,37	-0,17	0,13	0,18	51,29	1,03	0,57	0,22	0,54	0,18	0,25	46,83	1,03
XGBoost Classification	0,61	0,19	5,26	0,39	0,57	66,37	1,08	0,51	0,50	2,66	0,34	0,49	69,38	1,07
Hist Gradient Boosting Classification	0,65	0,10	8,56	0,52	0,82	42,78	1,11	0,64	0,07*	2,53	0,28	0,39	51,04	1,05
Extra Trees Classification	0,54	0,34	3,59	0,35	0,49	37,13	1,07	0,55	0,35	3,00	0,29	0,42	41,02	1,06
Critères de références														
Même Pondération			1,29	0,19	0,27	40,10	1,04			2,50	0,27	0,38	42,96	1,05
TSX60			-2,61	-0,02	-0,02	49,80	1,00			-2,61	-0,02	-0,02	49,80	1,00
SP500			-2,40	-0,01	-0,02	53,25	1,00			-2,40	-0,01	-0,02	53,25	1,00
NASDAQ			-0,03	0,15	0,21	51,26	1,03			-0,03	0,15	0,21	51,26	1,03

Notes : La première colonne du tableau correspond au score de précision : SP. La deuxième correspond au test de la statistique du test de Pesaran-Timmerman : PT. Pour cette statistique dans le tableau, 1* indique que les résultats sont significatifs à un niveau de confiance de 90 % ($p < 0,1$), 2* à 95 % ($p < 0,05$) et 3* à 99 % ($p < 0,01$). La troisième correspond aux rendements annualisés (ou TCAC) : r^A . La quatrième au ratio de Sharpe : SR. La cinquième au ratio de Sortino : ST. La sixième correspond à la perte maximale : P^{max} (maximum drawdown). Enfin, la septième colonne correspond au ratio oméga : Ω . Toutes les statistiques, à l'exception du SR, ST et Ω , sont exprimées en points de pourcentage. La première ligne grisée se rapporte au signal de la stratégie longue-courte de classification des portefeuilles défini dans la section 3.2.3 et la deuxième ligne grisée correspond aux différents critères de références (benchmarks) mentionnés à la section 3.3. Les chiffres en **gras** sont la meilleure statistique de chaque section séparée par une ligne grisée. Les chiffres en **vert** représentent la meilleure statistique de l'ensemble de la colonne (c'est-à-dire pour toutes les stratégies de portefeuilles et pour les différents critères de références).

Figure B.1 : Rendements cumulatifs au Canada et aux États-Unis, stratégie de portefeuille longue-courte ≥ 0 , 2008-01 à 2012-01 (classification)



(a) Longue-courte ≥ 0 , Canada

(b) Longue-courte ≥ 0 , États-Unis

Tableau B.2 : Résumé statistique des prédictions mensuelles, 2012-01 à 2020-01 (classification)

	Canada							États-Unis						
	SP	PT	r^A	SR	ST	P^{max}	Ω	SP	PT	r^A	SR	ST	P^{max}	Ω
Longue-courte ≥ 0														
Régression logistique	0,65	0,07*	11,41	1,05	1,62	21,94	1,22	0,57	0,32	13,32	1,07	1,53	27,03	1,23
XGBoost Classification	0,58	0,25	20,94	0,93	1,43	43,57	1,20	0,52	0,57	17,64	1,07	1,52	37,33	1,21
Hist Gradient Boosting Classification	0,58	0,24	21,29	0,94	1,58	46,26	1,22	0,60	0,06*	15,25	1,09	1,55	23,76	1,23
Extra Trees Classification	0,57	0,25	8,18	1,22	1,77	14,32	1,23	0,61	0,50	19,67	1,18	1,69	31,34	1,23
Critères de références														
Même Pondération			7,92	1,17	1,70	13,56	1,22			9,89	1,18	1,68	16,71	1,23
TSX60			2,93	0,45	0,61	24,36	1,08			2,93	0,45	0,61	24,36	1,08
SP500			8,34	0,98	1,36	19,78	1,20			8,34	0,98	1,36	19,78	1,20
NASDAQ			11,11	1,07	1,52	23,64	1,21			11,11	1,07	1,52	23,64	1,21

Notes : La première colonne du tableau correspond au score de précision : SP. La deuxième correspond au test de la statistique du test de Pesaran-Timmerman : PT. Pour cette statistique dans le tableau, 1* indique que les résultats sont significatifs à un niveau de confiance de 90 % ($p < 0,1$), 2* à 95 % ($p < 0,05$) et 3* à 99 % ($p < 0,01$). La troisième correspond aux rendements annualisés (ou TCAC) : r^A . La quatrième au ratio de Sharpe : SR. La cinquième au ratio de Sortino : ST. La sixième correspond à la perte maximale : P^{max} (maximum drawdown). Enfin, la septième colonne correspond au ratio oméga : Ω . Toutes les statistiques, à l'exception du SR, ST et Ω , sont exprimées en points de pourcentage. La première ligne grisée se rapporte au signal de la stratégie longue-courte de classification des portefeuilles défini dans la section 3.2.3 et la deuxième ligne grisée correspond aux différents critères de références (benchmarks) mentionnés à la section 3.3. Les chiffres en **gras** sont la meilleure statistique de chaque section séparée par une ligne grisée. Les chiffres en **vert** représentent la meilleure statistique de l'ensemble de la colonne (c'est-à-dire pour toutes les stratégies de portefeuilles et pour les différents critères de références).

Figure B.2 : Rendements cumulatifs au Canada et aux États-Unis, stratégie de portefeuille longue-courte ≥ 0 , 2012-01 à 2020-01 (classification)




Tableau B.3 : Résumé statistique des prédictions mensuelles, 2020-01 à 2024-01 (classification)


	Canada							États-Unis						
	SP	PT	r^A	SR	ST	P^{max}	Ω	SP	PT	r^A	SR	ST	P^{max}	Ω
Longue-courte ≥ 0														
Régression logistique	0,65	0,06	3,77	0,36	0,48	38,08	1,08	0,57	0,27	7,08	0,51	0,73	31,61	1,10
XGBoost Classification	0,58	0,17	17,42	0,98	1,43	37,99	1,22	0,53	0,41	5,96	0,41	0,57	56,05	1,09
Hist Gradient Boosting Classification	0,75	0,00***	1,00	0,23	0,31	63,56	1,06	0,63	0,11	1,32	0,23	0,32	57,31	1,06
Extra Trees Classification	0,56	0,14	5,52	0,49	0,66	38,14	1,11	0,54	0,50	10,65	0,56	0,79	56,05	1,12
Critères de références														
Même Pondération			5,64	0,51	0,69	36,23	1,11			6,70	0,56	0,79	30,59	1,12
TSX60			3,58	0,36	0,48	37,42	1,08			3,58	0,36	0,48	37,42	1,08
SP500			6,82	0,54	0,74	33,92	1,10			6,82	0,54	0,74	33,92	1,10
NASDAQ			9,06	0,60	0,84	36,40	1,11			9,06	0,60	0,84	36,40	1,11

Notes : La première colonne du tableau correspond au score de précision : SP. La deuxième correspond au test de la statistique du test de Pesaran-Timmerman : PT. Pour cette statistique dans le tableau, 1* indique que les résultats sont significatifs à un niveau de confiance de 90 % ($p < 0,1$), 2* à 95 % ($p < 0,05$) et 3* à 99 % ($p < 0,01$). La troisième correspond aux rendements annualisés (ou TCAC) : r^A . La quatrième au ratio de Sharpe : SR. La cinquième au ratio de Sortino : ST. La sixième correspond à la perte maximale : P^{max} (maximum drawdown). Enfin, la septième colonne correspond au ratio oméga : Ω . Toutes les statistiques, à l'exception du SR, ST et Ω , sont exprimées en points de pourcentage. La première ligne grisée se rapporte au signal de la stratégie longue-courte de classification des portefeuilles défini dans la section 3.2.3 et la deuxième ligne grisée correspond aux différents critères de références (benchmarks) mentionnés à la section 3.3. Les chiffres en **gras** sont la meilleure statistique de chaque section séparée par une ligne grisée. Les chiffres en **vert** représentent la meilleure statistique de l'ensemble de la colonne (c'est-à-dire pour toutes les stratégies de portefeuilles et pour les différents critères de références).

Figure B.3 : Rendements cumulatifs au Canada et aux États-Unis, stratégie de portefeuille longue-courte ≥ 0 , 2020-01 à 2024-01 (classification)



(a) Longue-courte ≥ 0 , Canada



(b) Longue-courte ≥ 0 , États-Unis

ANNEXE C


RÉSULTATS COMPLÉMENTAIRES SHAP

La position horizontale (axe des abscisses) correspond à la contribution (valeur SHAP) de chaque variable dans la prédiction du modèle pour une observation donnée. Les points situés à droite de zéro exercent un impact positif sur la prédiction (ils l'augmentent), tandis que ceux placés à gauche la réduisent (impact négatif). Plus un point s'éloigne de zéro, plus l'influence de cette variable (positive ou négative) est importante.

La couleur des points, qui s'étend du bleu (valeurs faibles de la variable) au rouge (valeurs élevées), indique le niveau réel de la variable pour cette observation. Un point bleu signale que la variable prend une valeur relativement basse, tandis qu'un point rouge révèle qu'elle est élevée. Cette gradation aide à visualiser le lien entre l'intensité de la variable et son effet sur la prédiction.


Sur l'ordre vertical (axe des ordonnées), on retrouve la liste des différentes variables. Les points disposés côte à côte pour une même variable montrent sa contribution, observation après observation, dans l'ensemble du jeu de données. Les regroupements de points (ou amas) renseignent sur la fréquence et l'intensité des effets. Par exemple, lorsqu'un nuage se concentre autour de zéro, cela signifie qu'en général la variable n'exerce pas d'influence marquée. À l'inverse, un large étalement (points très à gauche ou très à droite) montre qu'il existe plusieurs situations où la variable a un rôle décisif (positif ou négatif). De plus, la présence simultanée de points bleus et rouges à des positions extrêmes illustre un effet contextuel. C'est-à-dire que selon la situation, une valeur élevée (rouge) ou faible (bleue) peut soit augmenter, soit diminuer la prédiction.

Figure C.1 : SHAP importance des variables, 2008-01 à 2012-01



(a) Analyse globale, Canada


(b) Analyse globale, États-Unis




(c) Analyse locale, Canada

(d) Analyse locale, États-Unis


Figure C.2 : SHAP importance des variables, 2012-01 à 2020-01




(a) Analyse globale, Canada



(b) Analyse globale, États-Unis




(c) Analyse locale, Canada




(d) Analyse locale, États-Unis

Figure C.3 : SHAP importance des variables, 2020-01 à 2024-01



(a) Analyse globale, Canada

(b) Analyse globale, États-Unis



(c) Analyse locale, Canada

(d) Analyse locale, États-Unis

APPENDICE I

LISTE DES ACTIONS

Tableau I.1 : Liste des actions canadiennes avec leurs tickers associé

Numéro	Ticker	Nom du stock
1	ABX.TO	Barrick Gold Corporation
2	AEM.TO	Agnico Eagle Mines Limited
3	ATD.TO	Alimentation Couche-Tard Inc.
4	BB.TO	BlackBerry Limited
5	BBD-B.TO	Banco Bradesco S.A. (BBD)
6	BCE.TO	BCE Inc.
7	BMO.TO	Bank of Montreal
8	BN.TO	Brookfield Asset Management Inc.
9	BLDP.TO	Ballard Power Systems Inc.
10	BNS.TO	The Bank of Nova Scotia
11	CAE.TO	CAE Inc.
12	CCA.TO	Canadian Utilities Limited
13	CCL-B.TO	CCL Industries Inc.
14	CCO.TO	CCL Industries Inc. (Class C)
15	CM.TO	Canadian Imperial Bank of Commerce
16	CNR.TO	Canadian National Railway Company
17	CTC.TO	Canadian Tire Corporation
18	CTC-A.TO	Canadian Tire Corporation (Class A)
19	EMA.TO	Emera Inc.
20	EMP-A.TO	Emera Incorporated (Class A)
21	ENGH.TO	Enghouse Systems Limited
22	ENB.TO	Enbridge Inc.
23	FTS.TO	Fortis Inc.
24	FTT.TO	Fortis Inc. (Class A)
25	GIL.TO	Gildan Activewear Inc.
26	HR-UN.TO	H&R Real Estate Investment Trust
27	IMO.TO	Imperial Oil Limited
28	L.TO	Loblaw Companies Limited
29	MFC.TO	Manulife Financial Corporation
30	MFI.TO	Middlefield Income Plus Fund
31	MRU.TO	Metro Inc.
32	MTL.TO	Mittleton Inc.
33	NA.TO	National Bank of Canada
34	ONEX.TO	Onex Corporation
35	POW.TO	Power Corporation of Canada
36	RCI-B.TO	Rogers Communications Inc. (Class B)
37	RY.TO	Royal Bank of Canada
38	SAP.TO	Saputo Inc.
39	SJ.TO	St. John's Corporation
40	SLF.TO	Sun Life Financial Inc.
41	STN.TO	Stantec Inc.
42	SU.TO	Suncor Energy Inc.
43	T.TO	TELUS Corporation
44	TCL-A.TO	Transcontinental Inc. (Class A)
45	TECK-B.TO	Teck Resources Limited (Class B)
46	TRP.TO	TC Energy Corporation
47	TD.TO	Toronto-Dominion Bank
48	WN.TO	WestJet Airlines Ltd.
49	WDO.TO	Wheaton Precious Metals Corp.
50	XIU.TO	iShares S&P/TSX 60 Index ETF

Tableau I.2 : Liste des actions américaines avec leurs tickers associé

Numéro	Ticker	Nom du stock
1	AAPL	Apple Inc.
2	ABT	Abbott Laboratories
3	ACN	Accenture plc
4	AMGN	Amgen Inc.
5	AMZN	Amazon.com Inc.
6	AOS	A. O. Smith Corporation
7	BA	The Boeing Company
8	CAT	Caterpillar Inc.
9	CL	Colgate-Palmolive Company
10	CMCSA	Comcast Corporation
11	COST	Costco Wholesale Corporation
12	CRM	Salesforce, Inc.
13	CSCO	Cisco Systems, Inc.
14	CVX	Chevron Corporation
15	DHR	Danaher Corporation
16	DIS	The Walt Disney Company
17	GE	General Electric Company
18	GIS	General Mills, Inc.
19	GLW	Corning Incorporated
20	GOOGL	Alphabet Inc. (Google)
21	GS	Goldman Sachs Group, Inc.
22	HD	The Home Depot, Inc.
23	HON	Honeywell International Inc.
24	IBM	International Business Machines Corporation
25	INTC	Intel Corporation
26	JNJ	Johnson & Johnson
27	JPM	JPMorgan Chase & Co.
28	KO	The Coca-Cola Company
29	LIN	Linde plc
30	LLY	Eli Lilly and Company
31	LMT	Lockheed Martin Corporation
32	LOW	Lowe's Companies, Inc.
33	MCD	McDonald's Corporation
34	MDT	Medtronic plc
35	MMM	3M Company
36	MRK	Merck & Co., Inc.
37	MSFT	Microsoft Corporation
38	NKE	Nike, Inc.
39	PEP	PepsiCo, Inc.
40	PFE	Pfizer Inc.
41	PG	Procter & Gamble Co.
42	QCOM	QUALCOMM Incorporated
43	SBUX	Starbucks Corporation
44	T	AT&T Inc.
45	TXN	Texas Instruments Incorporated
46	UNH	UnitedHealth Group Incorporated
47	UPS	United Parcel Service, Inc.
48	VZ	Verizon Communications Inc.
49	WMT	Walmart Inc.
50	XOM	Exxon Mobil Corporation

APPENDICE II

LISTE DES VARIABLES

Les codes de transformation sont les suivants : 1 - pas de transformation ; 2 - première différence ; 4 - logarithme ; 5 - première différence du logarithme. *Vector(1)* et *Vector(2)* indiquent les vecteurs de StatCan. Lorsque différentes séries sont nécessaires pour construire un indicateur d'intérêt en raison de la rupture indiquée par la colonne *Date*, *Vector(1)* est la série la plus récente. Certaines variables sont tirées de la base de données économiques de la Réserve fédérale de Saint-Louis (FRED), de la Banque du Canada (BdC) et de Yahoo Finance.

Tableau II.1 : Données macroéconomiques LCDMA

No	Variable	Description	Région	Vector(1)	Vector(2)	Date	T-code
PRODUCTION							
1	GDP_new	PIB total	CAN	v41881478	v65201483	1997M1	5
2	BSI_new	PIB des entreprises	CAN	v41881479	v65201486	2007M1	5
3	GPI_new	PIB des biens	CAN	v41881485	v65201484	1997M1	5
4	SP_new	PIB des services	CAN	v41881486	v65201485	1997M1	5
5	IPI_new	PIB de la production industrielle	CAN	v41881487	v65201492	1997M1	5
6	NDM_new	PIB biens non durables	CAN	v41881488	v65201493	1997M1	5
7	DM_new	PIB biens durables	CAN	v41881489	v65201494	1997M1	5
8	OILP_new	PIB minier, pétrole et gaz	CAN	v41881501	v65201509	1997M1	5
9	CON_new	PIB construction	CAN	v41881523	v65201531	1997M1	5
10	RT_new	PIB commerce de détail	CAN	v41881688	v65201641	1997M1	5
11	WT_new	PIB commerce de gros	CAN	v41881689	v65201631	1997M1	5
12	PA_new	PIB administration publique	CAN	v41881775	v65201749	1997M1	5
13	FIN_new	PIB finance et assurance	CAN	v41881725	v65201680	1997M1	5
14	OIL_CAN	Production de pétrole (m³)	CAN	v17498	v107757044	2016M1	5
15	OIL_ALB_new	Production de pétrole (ALB) (m³)	ALB	v18050	v107757710	2016M1	5
MARCHÉ DU TRAVAIL							
16	EMP_CAN	Emploi total	CAN	v24793			5
17	EMP_SERV_CAN	Emploi services	CAN	v2057610			5
18	EMP_FOR_OIL_CAN	Emploi foresterie, pêche, minier, pétrole, gaz	CAN	v2057606			5
19	EMP_CONS_CAN	Emploi construction	CAN	v2057608			5
20	EMP_SALES_CAN	Emploi ventes (gros et détail)	CAN	v2057611			5
21	EMP_FIN_CAN	Emploi finance, assurance et immobilier	CAN	v2057613			5
22	EMP_MAN_CAN	Emploi manufacturier	CAN	v2057609			5
23	EMP_PART_CAN	Emploi à temps partiel	CAN	v2062813			5
24	UNEMP_CAN	Taux de chômage LRUNTTTTCAN156S	CAN	(FRED)	v2062815	1976M1	2
25	UNEMP_DURA_1-4_CAN	Durée du chômage (1-4 semaines)	CAN	v1078667742			5
26	UNEMP_DURA_5-13_CAN	Durée du chômage (5-13 semaines)	CAN	v1078667850			5
27	UNEMP_DURA_14-25_CAN	Durée du chômage (14-25 semaines)	CAN	v1078667958			5
28	UNEMP_DURA_27+_CAN	Durée du chômage (>27 semaines)	CAN	v1078668066			5
29	UNEMP_BENE_ANY_CAN_new	Durée du chômage moyenne	CAN	v3433887	v1078668391	1997M1	5
30	CLAIMS_CAN	Demandes initiales d'assurance-emploi, permises	CAN	v383942			1
31	TOT_HRS_CAN	Heures totales travaillées	CAN	v4391505			5
32	GOOD_HRS_CAN	Heures travaillées dans les biens	CAN	v4391507			5
LOGEMENT ET CONSTRUCTION							
33	NHOUSE_P_CAN	Indice des prix des maisons neuves (total maison+terrain)	CAN	v111955442		1990M1	5
34	start_CAN_new	Mises en chantier (unités)	CAN	v730413	v52300157	2011M1	5
35	build_tot_CAN_new	Permis de bâtir (tous)	CAN	v42064	v121293395	2011M1	5
36	build_Ind_CAN_new	Permis de bâtir (industries)	CAN	v42064	v121301795	2011M1	5
37	build_Comm_CAN_new	Permis de bâtir (non résidentiel)	CAN	v42065	v121304915	2011M1	5
FABRICATION, VENTES ET STOCKS							
38	MANU_N_ORD_new	Nouvelles commandes fabrication (total)	CAN	v723019	v800913	1992M1	5
39	MANU_UNFIL_new	Commandes non réalisées fabrication (total)	CAN	v723313	v803189	1992M1	5
40	MANU_INV_new	Inventaires fabrication (total)	CAN	v724933	v803227	1992M1	5
41	N_DUR_N_ORD_RAT_new	Ratio nls cdes/expéd. (total)	CAN	v725059	v803313	1992M1	1
42	N_DUR_INV_RAT_new	Ratio inv./expéd. (biens durables)	CAN	v725060	v803314	1992M1	1
43	DUR_NEW_ORD	Nouvelles commandes (biens durables)	CAN	v723034	v800926	1992M1	5
44	DUR_UNFIL_new	Commandes non réalisées (biens durables)	CAN	v723328	v803202	1992M1	5
45	DUR_TOT_INV_new	Inventaires (biens durables)	CAN	v724948	v803204	1992M1	5
46	DUR_INV_RAT_new	Ratio inv./expéd. (biens durables)	CAN	v725074	v803326	1992M1	1
MONNAIE ET CRÉDIT							
47	M3	M3 (brut)	CAN	v41552794			5
48	M2p	M2+ (brut)	CAN	v41552798			5
49	M_BASE1	Base monétaire	CAN	v37145			5
50	CRED_T	Crédit total	CAN	v36414			5
51	CRED_HOUS	Crédit aux ménages	CAN	v36415			5
52	CRED_MORT	Crédit hypothécaire	CAN	v36416			5
53	CRED_CONS	Crédit à la consommation	CAN	v36417			5
54	CRE_BUS	Crédit aux entreprises	CAN	v36418			5
55	BANK_RATE_L	Taux bancaire	CAN	v122550			2
56	PC_PAPER_1M	Papier commercial (taux 1 mois)	CAN	v122509	IIROC	2019M1	2
57	PC_PAPER_3M	Papier commercial (taux 3 mois)	CAN	v122491	IIROC	2019M1	2
58	GOV_AVG_1_3Y	Oblig. gouv. (moyenne) (1-3 ans)	CAN	v122558			2
59	GOV_AVG_3_5Y	Oblig. gouv. (moyenne) (3-5 ans)	CAN	v122485			2
60	GOV_AVG_5_10Y	Oblig. gouv. (moyenne) (5-10 ans)	CAN	v122486			2
61	GOV_AVG_10pY	Oblig. gouv. (moyenne) (>10 ans)	CAN	v122487			2
62	MORTG_1Y	Taux hypothécaire (1 an) BdC	CAN	v122520	(V80691333)	2019M10	2
63	MORTG_5Y	Taux hypothécaire (5 ans) BdC	CAN	v122521	(V80691335)	2019M10	2
64	TBILL_3M	Bons du Trésor (3 mois)	CAN	v122541			2
65	TBILL_6M	Bons du Trésor (6 mois)	CAN	v122552			2
66	PC_3M-Bank_rate	Papier comm. (3 mois) - T. bancaire	CAN	Difference			1
67	G_AVG_1-3_Bank_rate	Oblig. gouv. (1-3 ans) - T. bancaire	CAN	Difference			1
68	G_AVG_3-5_Bank_rate	Oblig. gouv. (3-5 ans) - T. bancaire	CAN	Difference			1
69	G_AVG_5-10_Bank_rate	Oblig. gouv. (5-10 ans) - T. bancaire	CAN	Difference			1
70	TBILL_6M-Bank_rate	Bons du Trésor (6 mois) - T. bancaire	CAN	Difference			1
71	G_AVG_10p-TBILL_3M	Oblig. gouv. (10+ ans) - BT (3 mois)	CAN	Difference			1
COMMERCE INTERNATIONAL ET FLUX							
72	RES_TOT	Total des réserves officielles de change du Canada	CAN	v122396			5
73	RES_USD	Réserves canadiennes en USD	CAN	v122398			5
74	RES_IMF	Position de réserve du Canada au FMI	CAN	v122401			5

No	Variable	Description	Région	Vector(1)	Vector(2)	Date	T-code
75	Imp_BP_new	Importations totales	CAN	v183406	v1001826653	1988M1	5
76	IOIL_BP_new	Importations de pétrole	CAN	v183426	v1001826667	1988M1	5
77	Exp_BP_new	Exportations totales	CAN	v191490	v1001827265	1988M1	5
78	EOIL_BP_new	Exportations de pétrole	CAN	v191516	v1001827279	1988M1	5
79	EX_ENER_BP_new	Exportations de produits énergétiques	CAN	v191516	v1001827278	1988M1	5
	(Sum)	Exportations de produits énergétiques	CAN	v191517	v1001827278	1988M1	
	(Sum)	Exportations de produits énergétiques	CAN	v191504	v1001827278	1988M1	
	(Sum)	Exportations de produits énergétiques	CAN	v191533	v1001827278	1988M1	
80	EX_MINER_BP_new	Exportations de minerais non métalliques	CAN	v191511	v1001827292	1988M1	5
	(Sum)	Exportations de minerais non métalliques	CAN	v191512	v1001827292	1988M1	
	(Sum)	Exportations de minerais non métalliques	CAN	v191513	v1001827292	1988M1	
	(Sum)	Exportations de minerais non métalliques	CAN	v191514	v1001827292	1988M1	
	(Sum)	Exportations de minerais non métalliques	CAN	v191515	v1001827292	1988M1	
	(Sum)	Exportations de minerais non métalliques	CAN	v191508	v1001827292	1988M1	
81	EX_METAL_BP_new	Exportations de métaux et autres produits minéraux	CAN	v191522	v1001827303	1988M1	5
	(Sum)	Exportations de métaux et autres produits minéraux	CAN	v191523	v1001827303	1988M1	
	(Sum)	Exportations de métaux et autres produits minéraux	CAN	v191524	v1001827303	1988M1	
	(Sum)	Exportations de métaux et autres produits minéraux	CAN	v191525	v1001827303	1988M1	
	(Sum)	Exportations de métaux et autres produits minéraux	CAN	v191526	v1001827303	1988M1	
	(Sum)	Exportations de métaux et autres produits minéraux	CAN	v191527	v1001827303	1988M1	
	(Sum)	Exportations de métaux et autres produits minéraux	CAN	v191528	v1001827303	1988M1	
	(Sum)	Exportations de métaux et autres produits minéraux	CAN	v191529	v1001827303	1988M1	
	(Sum)	Exportations de métaux et autres produits minéraux	CAN	v191531	v1001827303	1988M1	
	(Sum)	Exportations de métaux et autres produits minéraux	CAN	v191532	v1001827303	1988M1	
	(Sum)	Exportations de métaux et autres produits minéraux	CAN	v191535	v1001827303	1988M1	
82	EX_IND_EQUIP_BP_new	Exportations de machines industrielles, pièces et équipements	CAN	v191545	v1001827350	1988M1	5
	(Sum)	Exportations de machines industrielles, pièces et équipements	CAN	v191549	v1001827350	1988M1	
	(Sum)	Exportations de machines industrielles, pièces et équipements	CAN	v191556	v1001827350	1988M1	
83	EX_TRANSP_BP_new	Exportations de véhicules automobiles et pièces	CAN	v191550	v1001827369	1988M1	5
	(Sum)	Exportations de véhicules automobiles et pièces	CAN	v191551	v1001827369	1988M1	
	(Sum)	Exportations de véhicules automobiles et pièces	CAN	v191552	v1001827369	1988M1	
84	EX_CONS_BP_new	Exportations de biens de consommation	CAN	v191492	v1001827385	1988M1	5
	(Sum)	Exportations de biens de consommation	CAN	v191534	v1001827385	1988M1	
	(Sum)	Exportations de biens de consommation	CAN	v191547	v1001827385	1988M1	
85	IMP_METAL_BP_new	Importations de métaux et autres produits minéraux	CAN	v183446	v1001826691	1988M1	5
	(Sum)	Importations de métaux et autres produits minéraux	CAN	v183447	v1001826691	1988M1	
	(Sum)	Importations de métaux et autres produits minéraux	CAN	v183448	v1001826691	1988M1	
	(Sum)	Importations de métaux et autres produits minéraux	CAN	v183435	v1001826691	1988M1	
	(Sum)	Importations de métaux et autres produits minéraux	CAN	v183436	v1001826691	1988M1	
	(Sum)	Importations de métaux et autres produits minéraux	CAN	v183439	v1001826691	1988M1	
86	IMP_IND_EQUIP_BP_new	Importations de machines industrielles, pièces et équipements	CAN	v183450	v1001826738	1988M1	5
	(Sum)	Importations de machines industrielles, pièces et équipements	CAN	v183461	v1001826738	1988M1	
	(Sum)	Importations de machines industrielles, pièces et équipements	CAN	v183465	v1001826738	1988M1	
	(Sum)	Importations de machines industrielles, pièces et équipements	CAN	v183466	v1001826738	1988M1	
	(Sum)	Importations de machines industrielles, pièces et équipements	CAN	v183467	v1001826738	1988M1	
	(Sum)	Importations de machines industrielles, pièces et équipements	CAN	v183468	v1001826738	1988M1	
87	IMP_TRANSP_BP_new	Importations de véhicules automobiles et pièces	CAN	v183469	v1001826757	1988M1	5
	(Sum)	Importations de véhicules automobiles et pièces	CAN	v183470	v1001826757	1988M1	
	(Sum)	Importations de véhicules automobiles et pièces	CAN	v183471	v1001826757	1988M1	
88	IMP_CONS_BP_new	Importations de biens de consommation	CAN	v183457	v1001826773	1988M1	5
	(Sum)	Importations de biens de consommation	CAN	v183458	v1001826773	1988M1	
	(Sum)	Importations de biens de consommation	CAN	v183459	v1001826773	1988M1	
	(Sum)	Importations de biens de consommation	CAN	v183460	v1001826773	1988M1	
	(Sum)	Importations de biens de consommation	CAN	v183462	v1001826773	1988M1	
	(Sum)	Importations de biens de consommation	CAN	v183463	v1001826773	1988M1	
89	USDCAD_new	Taux de change CAD/USD	CAN	v37426	v111666275	2017M1	5
90	JPYCAD_new	Taux de change CAD/JPY	CAN	v37456	v111666278	2017M1	5
91	GBPCAD_new	Taux de change CAD/GBP	CAN	v37430	v111666274	2017M1	5
92	CAN_EQTY_NETFLOW	Actions canadiennes et parts de fonds de placement, flux nets	CAN	v61916203			1
93	CAN_SEC_NETFLOW	Titres canadiens, flux nets	CAN	v61915649			1
94	FOR_SEC_NETFLOW	Titres étrangers, flux nets	CAN	v61915715			1
95	CAN_US_SEC_NETFLOW	Titres canadiens, États-Unis, flux nets	CAN	v61915862			1
PRIX							
96	CPI_ALL_CAN	Indice des prix à la consommation (IPC) (ensemble)	CAN	v41690973			5
97	CPI_SHEL_CAN	IPC (logement)	CAN	v41691050			5
98	CPI_CLOT_CAN	IPC (habillement et chaussures)	CAN	v41691108			5
99	CPI_HEA_CAN	IPC (santé et soins personnels)	CAN	v41691153			5
100	CPI_MINUS_FOO_CAN	IPC (ensemble hors alimentation)	CAN	v41691232			5
101	CPI_MINUS_FEN_CAN	IPC (ensemble hors alimentation et énergie)	CAN	v41691233			5
102	CPI_GOO_CAN	IPC (biens)	CAN	v41691223			5
103	CPI_DUR_CAN	IPC (biens durables)	CAN	v41691222			5
104	CPI_SERV_CAN	IPC (services)	CAN	v41691230			5
105	IPPI_ALL_CAN	IPPI (ensemble)	CAN	v79309114			5
106	IPPI_ENER_CAN	IPPI (énergie)	CAN	v79309126			5
107	IPPI_WOOD_CAN	IPPI (bois)	CAN	v79309124			5
108	IPPI_METAL_CAN	IPPI (métaux et matériaux de construction)	CAN	v79309129			5
109	IPPI_MOTOR_CAN	IPPI (véhicules automobiles et pièces)	CAN	v79309130			5
110	IPPI_MACH_CAN	IPPI (machines industrielles et équipements)	CAN	v79309131			5
111	WTISPLC	Prix du pétrole West Texas Intermediate (WTI) (FRED)	CAN	WTISPLC			5
MARCHÉS BOURSISERS							
112	TSX_HI	Bourse de Toronto (plus haut)	CAN	v122618			5
113	TSX_LO	Bourse de Toronto (plus bas)	CAN	v122619			5
114	TSX_CLO	Bourse de Toronto (clôture)	CAN	v122620			5
115	DJI	Indice Dow Jones (clôture)	CAN	v37416	DJI (YAHOO!)		5
116	SP500	Indice Standard and Poor's (500) (YAHOO)	CAN	GSPC			5
SÉRIES PROVINCIALES / RÉGIONALES							
LOGEMENT ET CONSTRUCTION							
117	NHOUSE_P_NF	Indice des prix des logements neufs, total (maison+terrain) NF	CAN	v111955448			5
118	NHOUSE_P_PE	Indice des prix des logements neufs, total (maison+terrain) PEI	CAN	v111955454			5
119	NHOUSE_P_NS	Indice des prix des logements neufs, total (maison+terrain) NS	CAN	v111955460			5
120	NHOUSE_P_NB	Indice des prix des logements neufs, total (maison+terrain) NB	CAN	v111955466			5
121	NHOUSE_P_QC	Indice des prix des logements neufs, total (maison+terrain) QC	CAN	v111955472			5
122	NHOUSE_P_ON	Indice des prix des logements neufs, total (maison+terrain) ONT	CAN	v111955490			5
123	NHOUSE_P_MAN	Indice des prix des logements neufs, total (maison+terrain) MAN	CAN	v111955526			5

No	Variable	Description	Région	Vector(1)	Vector(2)	Date	T-code
124	NHOUSE_P_SAS	Indice des prix des logements neufs, total (maison et terrain) SAS	SAS	v111955532			5
125	NHOUSE_P_ALB	Indice des prix des logements neufs, total (maison et terrain) ALB	ALB	v111955541			5
126	NHOUSE_P_BC	Indice des prix des logements neufs, total (maison et terrain) BC	BC	v111955550			5
127	hstart_NF_new	Mises en chantier (unités) NF	NF	v730402	v52300159	1990M1	2
128	hstart_PEI_new	Mises en chantier (unités) PEI	PEI	v730403	v52300160	1990M1	2
129	hstart_NS_new	Mises en chantier (unités) NS	NS	v730404	v52300161	1990M1	5
130	hstart_NB_new	Mises en chantier (unités) NB	NB	v730405	v52300162	1990M1	2
131	hstart_QC_new	Mises en chantier (unités) QC	QC	v730406	v52300163	1990M1	5
132	hstart_ONT_new	Mises en chantier (unités) ONT	ONT	v730407	v52300164	1990M1	5
133	hstart_MAN_new	Mises en chantier (unités) MAN	MAN	v730409	v52300166	1990M1	5
134	hstart_SAS_new	Mises en chantier (unités) SAS	SAS	v730410	v52300167	1990M1	5
135	hstart_ALB_new	Mises en chantier (unités) ALB	ALB	v730411	v52300168	1990M1	5
136	hstart_BC_new	Mises en chantier (unités) BC	BC	v730412	v52300169	1990M1	5
137	build_Total_NF_new	Permis de bâtir (tous) NF	NF	v42094	v121314755	2011M1	5
138	build_Ind_NF_new	Permis de bâtir (industries) NF	NF	v42097	v121323155	2011M1	2
139	build_Comm_NF_new	Permis de bâtir (commerce) NF	NF	v42098	v121326275	2011M1	5
140	build_Total_PEI_new	Permis de bâtir (tous) PEI	PEI	v42106	v121336415	2011M1	5
141	build_Ind_PEI_new	Permis de bâtir (industries) PEI	PEI	v42109	v121341515	2011M1	2
142	build_Comm_PEI_new	Permis de bâtir (commerce) PEI	PEI	v42110	v121347635	2011M1	5
143	build_Total_NS_new	Permis de bâtir (tous) NS	NS	v42112	v121357475	2011M1	5
144	build_Ind_NS_new	Permis de bâtir (industries) NS	NS	v42115	v121365875	2011M1	5
145	build_Comm_NS_new	Permis de bâtir (commerce) NS	NS	v42116	v121368995	2011M1	5
146	build_Total_NB_new	Permis de bâtir (tous) NB	NB	v42118	v121378835	2011M1	5
147	build_Ind_NB_new	Permis de bâtir (industries) NB	NB	v42122	v121387235	2011M1	2
148	build_Comm_NB_new	Permis de bâtir (commerce) NB	NB	v42123	v121390355	2011M1	5
149	build_Total_QC_new	Permis de bâtir (tous) QC	QC	v42163	v121400195	2011M1	5
150	build_Ind_QC_new	Permis de bâtir (industries) QC	QC	v42166	v121408595	2011M1	5
151	build_Comm_QC_new	Permis de bâtir (commerce) QC	QC	v42167	v121411715	2011M1	5
152	build_Total_ONT_new	Permis de bâtir (tous) ONT	ONT	v42199	v121415555	2011M1	5
153	build_Ind_ONT_new	Permis de bâtir (industries) ONT	ONT	v42202	v121429955	2011M1	5
154	build_Comm_ONT_new	Permis de bâtir (commerce) ONT	ONT	v42203	v121433075	2011M1	2
155	build_Total_MAN_new	Permis de bâtir (tous) MAN	MAN	v42124	v121442915	2011M1	5
156	build_Ind_MAN_new	Permis de bâtir (industries) MAN	MAN	v42128	v121451315	2011M1	5
157	build_Comm_MAN_new	Permis de bâtir (commerce) MAN	MAN	v42129	v121454435	2011M1	5
158	build_Total_SAS_new	Permis de bâtir (tous) SAS	SAS	v42130	v121464275	2011M1	5
159	build_Ind_SAS_new	Permis de bâtir (industries) SAS	SAS	v42133	v121472675	2011M1	5
160	build_Comm_SAS_new	Permis de bâtir (commerce) SAS	SAS	v42134	v121475795	2011M1	5
161	build_Total_ALB_new	Permis de bâtir (tous) ALB	ALB	v42136	v121485635	2011M1	5
162	build_Ind_ALB_new	Permis de bâtir (industries) ALB	ALB	v42139	v121494035	2011M1	5
163	build_Comm_ALB_new	Permis de bâtir (commerce) ALB	ALB	v42140	v121497155	2011M1	5
164	build_Total_BC_new	Permis de bâtir (tous) BC	BC	v42250	v121506995	2011M1	5
165	build_Ind_BC_new	Permis de bâtir (industries) BC	BC	v42253	v121515395	2011M1	2
166	build_Comm_BC_new	Permis de bâtir (commerce) BC	BC	v42254	v121518515	2011M1	2
MARCHÉ DU TRAVAIL							
167	EMP_NF	Emploi total	NF	v2057622			5
168	EMP_SERV_NF	Emploi services	NF	v2057629			5
169	EMP_FOR_OIL_NF	Emploi foresterie, pêche, minier, pétrole, gaz	NF	v2057625			5
170	EMP_CONS_NF	Emploi construction	NF	v2057627			5
171	EMP_SALES_NF	Emploi ventes (gros et détail)	NF	v2057630			5
172	EMP_FIN_NF	Emploi finance, assurance et immobilier	NF	v2057632			5
173	EMP_MANU_NF	Emploi manufacturier	NF	v2057628			5
174	EMP_PEI	Emploi total	PEI	v2057641			5
175	EMP_SERV_PEI	Emploi services	PEI	v2057648			5
176	EMP_FOR_OIL_PEI	Emploi foresterie, pêche, minier, pétrole, gaz	PEI	v2057644			5
177	EMP_CONS_PEI	Emploi construction	PEI	v2057646			5
178	EMP_SALES_PEI	Emploi ventes (gros et détail)	PEI	v2057649			5
179	EMP_FIN_PEI	Emploi finance, assurance et immobilier	PEI	v2057651			5
180	EMP_MANU_PEI	Emploi manufacturier	PEI	v2057647			5
181	EMP_NS	Emploi total	NS	v2057660			5
182	EMP_SERV_NS	Emploi services	NS	v2057667			5
183	EMP_FOR_OIL_NS	Emploi foresterie, pêche, minier, pétrole, gaz	NS	v2057663			5
184	EMP_CONS_NS	Emploi construction	NS	v2057665			5
185	EMP_SALES_NS	Emploi ventes (gros et détail)	NS	v2057668			5
186	EMP_FIN_NS	Emploi finance, assurance et immobilier	NS	v2057670			5
187	EMP_MANU_NS	Emploi manufacturier	NS	v2057666			5
188	EMP_NB	Emploi total	NB	v2057679			5
189	EMP_SERV_NB	Emploi services	NB	v2057686			5
190	EMP_FOR_OIL_NB	Emploi foresterie, pêche, minier, pétrole, gaz	NB	v2057682			5
191	EMP_CONS_NB	Emploi construction	NB	v2057684			5
192	EMP_SALES_NB	Emploi ventes (gros et détail)	NB	v2057687			5
193	EMP_FIN_NB	Emploi finance, assurance et immobilier	NB	v2057689			5
194	EMP_MANU_NB	Emploi manufacturier	NB	v2057685			5
195	EMP_QC	Emploi total	QC	v2057698			5
196	EMP_SERV_QC	Emploi services	QC	v2057705			5
197	EMP_FOR_OIL_QC	Emploi foresterie, pêche, minier, pétrole, gaz	QC	v2057701			5
198	EMP_CONS_QC	Emploi construction	QC	v2057703			5
199	EMP_SALES_QC	Emploi ventes (gros et détail)	QC	v2057706			5
200	EMP_FIN_QC	Emploi finance, assurance et immobilier	QC	v2057708			5
201	EMP_MANU_QC	Emploi manufacturier	QC	v2057704			5
202	EMP_ONT	Emploi total	ONT	v2057717			5
203	EMP_SERV_ONT	Emploi services	ONT	v2057724			5
204	EMP_FOR_OIL_ONT	Emploi foresterie, pêche, minier, pétrole, gaz	ONT	v2057720			5
205	EMP_CONS_ONT	Emploi construction	ONT	v2057722			5
206	EMP_SALES_ONT	Emploi ventes (gros et détail)	ONT	v2057725			5
207	EMP_FIN_ONT	Emploi finance, assurance et immobilier	ONT	v2057727			5
208	EMP_MANU_ONT	Emploi manufacturier	ONT	v2057723			5
209	EMP_MAN	Emploi total	MAN	v2057736			5
210	EMP_SERV_MAN	Emploi services	MAN	v2057743			5
211	EMP_FOR_OIL_MAN	Emploi foresterie, pêche, minier, pétrole, gaz	MAN	v2057739			5
212	EMP_CONS_MAN	Emploi construction	MAN	v2057741			5
213	EMP_SALES_MAN	Emploi ventes (gros et détail)	MAN	v2057744			5
214	EMP_FIN_MAN	Emploi finance, assurance et immobilier	MAN	v2057746			5
215	EMP_MANU_MAN	Emploi manufacturier	MAN	v2057742			5
216	EMP_SAS	Emploi total	SAS	v2057755			5
217	EMP_SERV_SAS	Emploi services	SAS	v2057762			5

No	Variable	Description	Région	Vector(1)	Vector(2)	Date	T-code
218	EMP_FOR_OIL SAS	Emploi dans la foresterie, la pêche, l'exploitation minière, pétrolière et gazière	SAS	v2057758			5
219	EMP_CONS SAS	Emploi dans la construction	SAS	v2057760			5
220	EMP_SALES SAS	Emploi dans la vente (commerce de gros et de détail)	SAS	v2057763			5
221	EMP_FIN SAS	Emploi dans la finance, l'assurance et l'immobilier	SAS	v2057765			5
222	EMP_MANU SAS	Emploi dans la fabrication	SAS	v2057761			5
223	EMP_ALB	Emploi total	ALB	v2057774			5
224	EMP_SERV_ALB	Emploi dans les services	ALB	v2057781			5
225	EMP_FOR_OIL_ALB	Emploi dans la foresterie, la pêche, l'exploitation minière, pétrolière et gazière	ALB	v2057777			5
226	EMP_CONS_ALB	Emploi dans la construction	ALB	v2057779			5
227	EMP_SALES_ALB	Emploi dans la vente (commerce de gros et de détail)	ALB	v2057782			5
228	EMP_FIN_ALB	Emploi dans la finance, l'assurance et l'immobilier	ALB	v2057784			5
229	EMP_MANU_ALB	Emploi dans la fabrication	ALB	v2057780			5
230	EMP_BC	Emploi total	BC	v2057793			5
231	EMP_SERV_BC	Emploi dans les services	BC	v2057800			5
232	EMP_FOR_OIL_BC	Emploi dans la foresterie, la pêche, l'exploitation minière, pétrolière et gazière.	BC	v2057796			5
233	EMP_CONS_BC	Emploi dans la construction	BC	v2057798			5
234	EMP_SALES_BC	Emploi dans la vente (commerce de gros et de détail)	BC	v2057801			5
235	EMP_FIN_BC	Emploi dans la finance, l'assurance et l'immobilier	BC	v2057803			5
236	EMP_MANU_BC	Emploi dans la fabrication	BC	v2057799			5
237	UNEMP_NF	Taux de chômage	NF	v2063004			2
238	UNEMP_PEI	Taux de chômage	PEI	v2063193			2
239	UNEMP_NS	Taux de chômage	NS	v2063382			2
240	UNEMP_NB	Taux de chômage	NB	v2063571			2
241	UNEMP_OC	Taux de chômage	OC	v2063760			2
242	UNEMP_ONT	Taux de chômage	ONT	v2063949			2
243	UNEMP_MAN	Taux de chômage	MAN	v2064138			2
244	UNEMP_SAS	Taux de chômage	SAS	v2064327			2
245	UNEMP_ALB	Taux de chômage	ALB	v2064516			2
246	UNEMP_BC	Taux de chômage	BC	v2064705			2
247	EMP_PART_NF	Emploi à temps partiel	NF	v2063002			5
248	EMP_PART_PEI	Emploi à temps partiel	PEI	v2063191			5
249	EMP_PART_NS	Emploi à temps partiel	NS	v2063380			5
250	EMP_PART_NB	Emploi à temps partiel	NB	v2063569			5
251	EMP_PART_OC	Emploi à temps partiel	QC	v2063758			5
252	EMP_PART_ONT	Emploi à temps partiel	ONT	v2063947			5
253	EMP_PART_MAN	Emploi à temps partiel	MAN	v2064136			5
254	EMP_PART_SAS	Emploi à temps partiel	SAS	v2064325			5
255	EMP_PART_ALB	Emploi à temps partiel	ALB	v2064514			5
256	EMP_PART_BC	Emploi à temps partiel	BC	v2064703			5
257	UNEMP_DURAvg_NF_new	Durée moyenne du chômage	NF	v3434211	v1078669579		5
258	UNEMP_DURAvg_PEI_new	Durée moyenne du chômage	PEI	v3434535	v1078670767		5
259	UNEMP_DURAvg_NS_new	Durée moyenne du chômage	NS	v3434859	v1078671955		5
260	UNEMP_DURAvg_NB_new	Durée moyenne du chômage	NB	v3435183	v1078673143		5
261	UNEMP_DURAvg_QC_new	Durée moyenne du chômage	OC	v3435507	v1078674331		5
262	UNEMP_DURAvg_ONT_new	Durée moyenne du chômage	ONT	v3435831	v1078675519		5
263	UNEMP_DURAvg_MAN_new	Durée moyenne du chômage	MAN	v3436155	v1078676707		5
264	UNEMP_DURAvg_SAS_new	Durée moyenne du chômage	SAS	v3436479	v1078677895		5
265	UNEMP_DURAvg_ALB_new	Durée moyenne du chômage	ALB	v3436803	v1078679083		5
266	UNEMP_DURAvg_BC_new	Durée moyenne du chômage	BC	v3437127	v1078680271		5
267	CLAIMS_NF	Demandes initiales d'assurance-emploi, approuvées	NF	v383943			1
268	CLAIMS_PEI	Demandes initiales d'assurance-emploi, approuvées	PEI	v383948			1
269	CLAIMS_NS	Demandes initiales d'assurance-emploi, approuvées	NS	v383949			1
270	CLAIMS_NB	Demandes initiales d'assurance-emploi, approuvées	NB	v383950			1
271	CLAIMS_OC	Demandes initiales d'assurance-emploi, approuvées	QC	v383951			1
272	CLAIMS_ONT	Demandes initiales d'assurance-emploi, approuvées	ONT	v383952			1
273	CLAIMS_MAN	Demandes initiales d'assurance-emploi, approuvées	MAN	v383953			1
274	CLAIMS_SAS	Demandes initiales d'assurance-emploi, approuvées	SAS	v383954			1
275	CLAIMS_ALB	Demandes initiales d'assurance-emploi, approuvées	ALB	v383955			1
276	CLAIMS_BC	Demandes initiales d'assurance-emploi, approuvées	BC	v383944			1
STOCKS ET COMMANDES DES FABRICANTS							
277	MANU_NF_new	Nouvelles commandes de l'industrie manufacturière (biens durables)	NF	v727515	v803786	1992M1	5
278	DUR_NF_new	Nouvelles commandes de l'industrie manufacturière (biens durables)	NF	v727527	v803799	1992M1	5
279	MANU_PEI_new	Nouvelles commandes de l'industrie manufacturière (biens durables)	PEI	v727539	v804246	1992M1	5
280	DUR_PEI_new	Nouvelles commandes de l'industrie manufacturière (biens durables)	PEI	v727551	v804259	1992M1	5
281	MANU_NS_new	Nouvelles commandes de l'industrie manufacturière (biens durables)	NS	v727563	v804706	1992M1	5
282	DUR_NS_new	Nouvelles commandes de l'industrie manufacturière (biens durables)	NS	v727577	v804719	1992M1	5
283	MANU_NB_new	Nouvelles commandes de l'industrie manufacturière (biens durables)	NB	v727591	v805166	1992M1	5
284	DUR_NB_new	Nouvelles commandes de l'industrie manufacturière (biens durables)	NB	v727605	v805179	1992M1	5
285	MANU_QC_new	Nouvelles commandes de l'industrie manufacturière (biens durables)	QC	v727617	v805626	1992M1	5
286	DUR_QC_new	Nouvelles commandes de l'industrie manufacturière (biens durables)	QC	v727632	v805639	1992M1	5
287	MANU_ONT_new	Nouvelles commandes de l'industrie manufacturière (biens durables)	ONT	v727646	v806086	1992M1	5
288	DUR_ONT_new	Nouvelles commandes de l'industrie manufacturière (biens durables)	ONT	v727661	v806099	1992M1	5
289	MANU_MAN_new	Nouvelles commandes de l'industrie manufacturière (biens durables)	MAN	v727675	v806546	1992M1	5
290	DUR_MAN_new	Nouvelles commandes de l'industrie manufacturière (biens durables)	MAN	v727689	v806559	1992M1	5
291	MANU_SAS_new	Nouvelles commandes de l'industrie manufacturière (biens durables)	SAS	v727703	v807006	1992M1	5
292	DUR_SAS_new	Nouvelles commandes de l'industrie manufacturière (biens durables)	SAS	v727716	v807019	1992M1	5
293	MANU_ALB_new	Nouvelles commandes de l'industrie manufacturière (biens durables)	ALB	v727729	v807466	1992M1	5
294	DUR_ALB_new	Nouvelles commandes de l'industrie manufacturière (biens durables)	ALB	v727743	v807479	1992M1	5
295	MANU_BC_new	Nouvelles commandes de l'industrie manufacturière (biens durables)	BC	v727756	v807928	1992M1	5
296	DUR_BC_new	Nouvelles commandes de l'industrie manufacturière (biens durables)	BC	v727770	v807941	1992M1	5
PRIX							
297	CPI_ALL_NF	Indice des prix à la consommation (IPC) (tous)	NF	v41691244			5
298	CPI_SHEL_NF	IPC (logement)	NF	v41691277			5
299	CPI_CLTOT_NF	IPC (habillement et chaussures)	NF	v41691304			5
300	CPI_HEA_NF	IPC (santé et soins personnels)	NF	v41691328			5
301	CPI_MINUS_FOO_NF	IPC (ensemble hors alimentation et énergie)	NF	v41691368			5
302	CPI_MINUS_FEN_NF	IPC (ensemble hors alimentation et énergie)	NF	v41691369			5
303	CPI_GOO_NF	IPC (biens)	NF	v41691363			5
304	CPI_DUR_NF	IPC (biens durables)	NF	v41691364			5
305	CPI_SERV_NF	IPC (services)	NF	v41691367			5
306	CPI_ALL_PEI	Indice des prix à la consommation (IPC) (tous)	PEI	v41691379			5
307	CPI_SHEL_PEI	IPC (logement)	PEI	v41691412			5
308	CPI_CLTOT_PEI	IPC (habillement et chaussures)	PEI	v41691439			5
309	CPI_HEA_PEI	IPC (santé et soins personnels)	PEI	v41691462			5
310	CPI_MINUS_FOO_PEI	IPC (ensemble hors alimentation)	PEI	v41691502			5

No	Variable	Description	Région	Vector(1)	Vector(2)	Date	T-code
311	CPI_MINUS_FEN_PEI	IPC (hors alimentation et énergie)	PEI	v41691503			5
312	CPI_GOO_PEI	IPC (biens)	PEI	v41691497			5
313	CPI_DUR_PEI	IPC (biens durables)	PEI	v41691498			5
314	CPI_SERV_PEI	IPC (services)	PEI	v41691501			5
315	CPI_ALL_NS	Indice des prix à la consommation (IPC) (tous)	NS	v41691513			5
316	CPI_SHEL_NS	IPC (logement)	NS	v41691546			5
317	CPI_CLOT_NS	IPC (habillement et chaussures)	NS	v41691573			5
318	CPI_HEA_NS	IPC (santé et soins personnels)	NS	v41691597			5
319	CPI_MINUS_FOO_NS	IPC (hors alimentation)	NS	v41691637			5
320	CPI_MINUS_FEN_NS	IPC (hors alimentation et énergie)	NS	v41691638			5
321	CPI_GOO_NS	IPC (biens)	NS	v41691632			5
322	CPI_DUR_NS	IPC (biens durables)	NS	v41691633			5
323	CPI_SERV_NS	IPC (services)	NS	v41691636			5
324	CPI_ALL_NB	Indice des prix à la consommation (IPC) (tous)	NB	v41691648			5
325	CPI_SHEL_NB	IPC (logement)	NB	v41691681			5
326	CPI_CLOT_NB	IPC (habillement et chaussures)	NB	v41691708			5
327	CPI_HEA_NB	IPC (santé et soins personnels)	NB	v41691732			5
328	CPI_MINUS_FOO_NB	IPC (hors alimentation)	NB	v41691772			5
329	CPI_MINUS_FEN_NB	IPC (hors alimentation et énergie)	NB	v41691773			5
330	CPI_GOO_NB	IPC (biens)	NB	v41691767			5
331	CPI_DUR_NB	IPC (biens durables)	NB	v41691768			5
332	CPI_SERV_NB	IPC (services)	NB	v41691771			5
333	CPI_ALL_QC	Indice des prix à la consommation (IPC) (tous)	QC	v41691783			5
334	CPI_SHEL_QC	IPC (logement)	QC	v41691816			5
335	CPI_CLOT_QC	IPC (habillement et chaussures)	QC	v41691844			5
336	CPI_HEA_QC	IPC (santé et soins personnels)	QC	v41691868			5
337	CPI_MINUS_FOO_QC	IPC (hors alimentation)	QC	v41691908			5
338	CPI_MINUS_FEN_QC	IPC (hors alimentation et énergie)	QC	v41691909			5
339	CPI_GOO_QC	IPC (biens)	QC	v41691903			5
340	CPI_DUR_QC	IPC (biens durables)	QC	v41691904			5
341	CPI_SERV_QC	IPC (services)	QC	v41691907			5
342	CPI_ALL_ONT	Indice des prix à la consommation (IPC) (tous)	ONT	v41691919			5
343	CPI_SHEL_ONT	IPC (logement)	ONT	v41691952			5
351	CPI_ALL_MAN	Indice des prix à la consommation (IPC) (tous)	MAN	v41692055			5
352	CPI_SHEL_MAN	IPC (logement)	MAN	v41692088			5
353	CPI_CLOT_MAN	IPC (habillement et chaussures)	MAN	v41692116			5
354	CPI_HEA_MAN	IPC (santé et soins personnels)	MAN	v41692140			5
355	CPI_MINUS_FOO_MAN	IPC (hors alimentation)	MAN	v41692180			5
356	CPI_MINUS_FEN_MAN	IPC (hors alimentation et énergie)	MAN	v41692181			5
357	CPI_GOO_MAN	IPC (biens)	MAN	v41692175			5
358	CPI_DUR_MAN	IPC (biens durables)	MAN	v41692176			5
359	CPI_SERV_MAN	IPC (services)	MAN	v41692179			5
360	CPI_ALL_SAS	Indice des prix à la consommation (IPC) (tous)	SAS	v41692191			5
361	CPI_SHEL_SAS	IPC (logement)	SAS	v41692224			5
362	CPI_CLOT_SAS	IPC (habillement et chaussures)	SAS	v41692252			5
363	CPI_HEA_SAS	IPC (santé et soins personnels)	SAS	v41692276			5
364	CPI_MINUS_FOO_SAS	IPC (hors alimentation)	SAS	v41692316			5
365	CPI_MINUS_FEN_SAS	IPC (hors alimentation et énergie)	SAS	v41692317			5
366	CPI_GOO_SAS	IPC (biens)	SAS	v41692311			5
367	CPI_DUR_SAS	IPC (biens durables)	SAS	v41692312			5
368	CPI_SERV_SAS	IPC (services)	SAS	v41692315			5
369	CPI_ALL_ALB	Indice des prix à la consommation (IPC) (tous)	ALB	v41692327			5
370	CPI_SHEL_ALB	IPC (logement)	ALB	v41692360			5
371	CPI_CLOT_ALB	IPC (habillement et chaussures)	ALB	v41692387			5
372	CPI_HEA_ALB	IPC (santé et soins personnels)	ALB	v41692411			5
373	CPI_MINUS_FOO_ALB	IPC (hors alimentation)	ALB	v41692451			5
374	CPI_MINUS_FEN_ALB	IPC (hors alimentation et énergie)	ALB	v41692452			5
375	CPI_GOO_ALB	IPC (biens)	ALB	v41692446			5
376	CPI_DUR_ALB	IPC (biens durables)	ALB	v41692447			5
377	CPI_SERV_ALB	IPC (services)	ALB	v41692450			5
378	CPI_ALL_BC	Indice des prix à la consommation (IPC) (tous)	BC	v41692462			5
379	CPI_SHEL_BC	IPC (logement)	BC	v41692495			5
380	CPI_CLOT_BC	IPC (habillement et chaussures)	BC	v41692523			5
381	CPI_HEA_BC	IPC (santé et soins personnels)	BC	v41692547			5
382	CPI_MINUS_FOO_BC	IPC (hors alimentation)	BC	v41692587			5
383	CPI_MINUS_FEN_BC	IPC (hors alimentation et énergie)	BC	v41692588			5
384	CPI_GOO_BC	IPC (biens)	BC	v41692582			5
385	CPI_DUR_BC	IPC (biens durables)	BC	v41692583			5
386	CPI_SERV_BC	IPC (services)	BC	v41692586			5

La colonne *tcode* indique les transformations de données appliquées à une série x : (1) aucune transformation ; (2) Δx_t ; (3) $\Delta^2 x_t$; (4) $\log(x_t)$; (5) $\Delta \log(x_t)$; (6) $\Delta^2 \log(x_t)$; (7) $\Delta \left(\frac{x_t}{x_{t-1}} - 1.0 \right)$. La colonne *fred* fournit des mnémoniques utilisées dans FRED, suivies d'une brève description. La série comparable dans Perspectives Globales (*Global Insight*) est donnée dans la colonne *gsi*.

Tableau II.2 : Données macroéconomiques FRED-MD

Groupe 1 : Production et revenu

	id	tcode	fred	description	gsi	gsi:description
1	1	5	RPI	Revenu personnel réel	M_14386177	RP
2	2	5	W875RX1	Revenu personnel réel hors transferts	M_145256755	RP hors transferts
3	6	5	INDPRO	Indice de Production Industrielle (IP)	M_116460980	IP : total
4	7	5	IPFPNSS	IP : Produits finaux et fournitures non industrielles	M_116460981	IP : produits
5	8	5	IPFINAL	IP : Produits finaux (Groupe de marché)	M_116461268	IP : prod finale
6	9	5	IPCONGD	IP : Biens de consommation	M_116460982	IP : biens cons
7	10	5	IPDCONGD	IP : Biens de consommation durables	M_116460983	IP : cons dur
8	11	5	IPNCONGD	IP : Biens de consommation non durables	M_116460988	IP : cons non dur
9	12	5	IPBUSEQ	IP : Équipement industriel	M_116460995	IP : eqpt ent
10	13	5	IPMAT	IP : Matériaux	M_116461002	IP : mat
11	14	5	IPDMAT	IP : Matériaux durables	M_116461004	IP : mat dur
12	15	5	IPNMAT	IP : Matériaux non durables	M_116461008	IP : mat non dur
13	16	5	IPMANSICS	IP : Fabrication (SIC)	M_116461013	IP : fabr
14	17	5	IPB51222S	IP : Services publics résidentiels	M_116461276	IP : util rés
15	18	5	IPFUELS	IP : Carburants	M_116461275	IP : carb
16	19	1	NAPMPI	ISM Manufacturier : Indice de production	M_110157212	NAPM prod
17	20	2	CUMFNS	Utilisation de la capacité : fabrication	M_116461602	Util cap

Groupe 2 : Marché du travail

	id	tcode	fred	description	gsi	gsi:description
1	21*	2	HWI	Indice d'offres d'emploi pour les États-Unis		Ind. offres empl.
2	22*	2	HWIURATIO	Ratio offres d'emploi/nombre de chômeurs	M_110156531	off. empl./chôm.
3	23	5	CLF16OV	Population active civile	M_110156467	Empl CPS total
4	24	5	CE16OV	Emploi civil	M_110156498	Empl CPS non agr.
5	25	2	UNRATE	Taux de chômage civil	M_110156541	C : tout
6	26	2	UEMPMEAN	Durée moyenne du chômage (semaines)	M_110156528	C : durée moy.
7	27	5	UEMPLT5	Chômeurs civils < 5 semaines	M_110156527	C < 5 sem
8	28	5	UEMP5TO14	Chômeurs civils 5-14 semaines	M_110156523	C 5-14 sem
9	29	5	UEMP15OV	Chômeurs civils 15 semaines et plus	M_110156524	C 15+ sem
10	30	5	UEMP15T26	Chômeurs civils 15-26 semaines	M_110156525	C 15-26 sem
11	31	5	UEMP27OV	Chômeurs civils 27 semaines et plus	M_110156526	C 27+ sem
12	32*	5	CLAIMSx	Nouvelles demandes d'allocations chômage	M_15186204	Dem chôûm UI
13	33	5	PAYEMS	Tous employés : total hors agriculture	M_123109146	Empl : total
14	34	5	USGOOD	Tous employés : ind. productrices de biens	M_123109172	Empl : prod biens
15	35	5	CES1021000001	Tous employés : extraction (mines)	M_123109244	Empl : extraction
16	36	5	USCONS	Tous employés : construction	M_123109331	Empl : const
17	37	5	MANEMP	Tous employés : fabrication	M_123109542	Empl : fabr
18	38	5	DMANEMP	Tous employés : biens durables	M_123109573	Empl : biens dur
19	39	5	NDMANEMP	Tous employés : biens non durables	M_123110741	Empl : biens non dur
20	40	5	SRVPRD	Tous employés : ind. de services	M_123109193	Empl : services
21	41	5	USTPU	Tous employés : commerce, transport, utilités	M_123115453	Empl : CTU
22	42	5	USWTRADE	Tous employés : commerce de gros	M_123111563	Empl : gros
23	43	5	USTRADE	Tous employés : commerce de détail	M_123111867	Empl : détail
24	44	5	USFIRE	Tous employés : activités financières	M_123112777	Empl : fin
25	45	5	USGOVT	Tous employés : admin. publique	M_123114411	Empl : gouv
26	46	1	CES0600000007	H. moy. hebdo : prod. biens	M_140687274	H moy
27	47	2	AWOTMAN	H. moy. suppl. hebdo : fabr	M_123109554	Suppl : fabr
28	48	1	AWHMAN	H. moy. hebdo : fabrication	M_14386098	H moy : fabr
29	49	1	NAPMEI	ISM Fabrication : Indice d'emploi	M_110157206	NAPM empl.
30	127	6	CES0600000008	Rémun. horaire moy. : prod. biens	M_123109182	RHM : biens
31	128	6	CES2000000008	Rémun. horaire moy. : construction	M_123109341	RHM : const
32	129	6	CES3000000008	Rémun. horaire moy. : fabrication	M_123109552	RHM : fabr

Groupe 3 : Consommation et commandes

	id	tcode	fred	description	gsi	gsi:description
1	50	4	HOUST	Mises en chantier : Total Nouveau Propriété Privé	M_110155536	Chant : hors agriculture
2	51	4	HOUSTNE	Mises en chantier, Nord-Est	M_110155538	Chant : NE
3	52	4	HOUSTMW	Mises en chantier, Mi-Ouest	M_110155537	Chant : MO
4	53	4	HOUSTS	Mises en chantier, Sud	M_110155543	Chant : Sud
5	54	4	HOUSTW	Mises en chantier, Ouest	M_110155544	Chant : Ouest
6	55	4	PERMIT	Nouveaux permis privés (SAAR)	M_110155532	PC : total
7	56	4	PERMITNE	Permis privés, Nord-Est (SAAR)	M_110155531	PC : NE
8	57	4	PERMITMW	Permis privés, Midwest (SAAR)	M_110155530	PC : MW
9	58	4	PERMITS	Permis privés, Sud (SAAR)	M_110155533	PC : Sud
10	59	4	PERMITW	Permis privés, Ouest (SAAR)	M_110155534	PC : Ouest

Groupe 4 : Commandes et stocks

	id	tcode	fred	description	gsi	gsi:description
1	3	5	DPCERA3M086SBEA	Dépenses réelles de consommation ménages	M_123008274	Conso réelle
2	4*	5	CMRMTSPLx	Ventes réelles manu. et comm.	M_110156998	M&T sales
3	5*	5	RETAILx	Ventes au détail et serv. alimentaires	M_130439509	Ventes détail
4	60	1	NAPM	ISM : Indice PMI composite	M_110157208	PMI
5	61	1	NAPMNOI	ISM : Indice nouvelles commandes	M_110157210	NAPM nouv cmdes
6	62	1	NAPMSDI	ISM : Indice livraisons fournisseurs	M_110157205	NAPM liv fourn
7	63	1	NAPMII	ISM : Indice des stocks	M_110157211	NAPM stocks
8	64	5	ACOGNO	Nouv. cmdes biens de consommation	M_14385863	Cmdes : biens cons
9	65*	5	AMDNOx	Nouv. cmdes biens durables	M_14386110	Cmdes : biens dur
10	66*	5	ANDENOx	Nouv. cmdes biens d'équip. hors défense	M_178554409	Cmdes : biens cap
11	67*	5	ANDMUOx	Cmdes non exécutées biens durables	M_14385946	Cmdes non liv : dur
12	68*	5	BUSINVx	Stocks totaux entreprises	M_15192014	M&T invent
13	69*	2	ISRATIOx	Ratio stocks/ventes total	M_15191529	M&T invent/ventes
14	130*	2	UMCSENTx	Indice de confiance des consommateurs	hhsntn	Att. consom.

Groupe 5 : Monnaie et crédit

	id	tcode	fred	description	gsi	gsi:description
1	70	6	M1SL	Masse monétaire M1	M_110154984	M1
2	71	6	M2SL	Masse monétaire M2	M_110154985	M2
3	72	5	M2REAL	Masse monétaire M2 réelle	M_110154985	M2 (réelle)
4	73	6	AMBSL	Base monétaire ajustée (St. Louis)	M_110154995	MB
5	74	6	TOTRESNS	Réserves totales des institutions déposantes	M_110155011	Réserves tot
6	75	7	NONBORRES	Réserves des institutions déposantes (non empruntées)	M_110155009	Réserves nonbor
7	76	6	BUSLOANS	Prêts commerciaux et industriels	BUSLOANS	C&I loan plus
8	77	6	REALLN	Prêts immobiliers (toutes banques comm.)	BUSLOANS	DC&I loans
9	78	6	NONREVSL	Crédit total non renouvelable	M_110154564	Cons credit
10	79*	2	CONSPI	Crédit conso. non renouvelable / revenu pers.	M_110154569	Inst cred/PI
11	131	6	MZMSL	Masse monétaire MZM	N.D.	N.D.
12	132	6	DTCOLNVHFNM	Encours des prêts automobiles consommateurs	N.D.	N.D.
13	133	6	DTCTHFNM	Encours total prêts et baux consommateurs	N.D.	N.D.
14	134	6	INVEST	Titres dans crédit bancaire (toutes banques comm.)	N.D.	N.D.

Groupe 6 : Taux d'intérêt et taux de change

id	tcode	fred	description	gsi	gsi:description
1	84	2	FEDFUNDS	Taux effectif des fonds fédéraux	M_110155157 Fonds Fédéraux
2	85*	2	CP3Mx	Taux du papier commercial financier AA à 3 mois	CPF3M Papier comm.
3	86	2	TB3MS	Bon du Trésor à 3 mois	M_110155165 BT 3 mois
4	87	2	TB6MS	Bon du Trésor à 6 mois	M_110155166 BT 6 mois
5	88	2	GS1	Taux du Trésor à 1 an	M_110155168 BT 1 an
6	89	2	GS5	Taux du Trésor à 5 ans	M_110155174 BT 5 ans
7	90	2	GS10	Taux du Trésor à 10 ans	M_110155169 BT 10 ans
8	91	2	AAA	Rendement oblig. d'entreprises Aaa	Oblig. Aaa
9	92	2	BAA	Rendement oblig. d'entreprises Baa	Oblig. Baa
10	93*	1	COMPAPFFx	Papier comm. 3 mois - FEDFUNDS	Écart CP-FF
11	94	1	TB3SMFFM	B/T 3 mois - FEDFUNDS	Écart 3 mois-FF
12	95	1	TB6SMFFM	B/T 6 mois - FEDFUNDS	Écart 6 mois-FF
13	96	1	T1YFFM	B/T 1 an - FEDFUNDS	Écart 1 an-FF
14	97	1	T5YFFM	B/T 5 ans - FEDFUNDS	Écart 5 ans-FF
15	98	1	T10YFFM	B/T 10 ans - FEDFUNDS	Écart 10 ans-FF
16	99	1	AAAFFM	Aaa - FEDFUNDS	Écart Aaa-FF
17	100	1	BAAFFM	Baa - FEDFUNDS	Écart Baa-FF
18	101	5	TWEXMMTH	Taux de ch. pondéré USD : devises majeures	Tx ch: moy
19	102*	5	EXSZUSx	Taux de change Suisse / US	M_110154768 Tx ch: Suisse
20	103*	5	EXJPUSx	Taux de change Japon / US	M_110154755 Tx ch: Japon
21	104*	5	EXUSUKx	Taux de change US / UK	M_110154772 Tx ch: UK
22	105*	5	EXCAUSx	Taux de change Canada / US	M_110154744 Tx ch: Canada

Groupe 7 : Prix

id	tcode	fred	description	gsi	gsi:description
1	106	6	WPSFD49207	PPI : Biens finis	M110157517 PPI: biens finis
2	107	6	WPSFD49502	PPI : Biens de cons. finis	M110157508 PPI: biens cons
3	108	6	WPSID61	PPI : Matériaux intermédiaires	M_110157527 PPI: mat. int.
4	109	6	WPSID62	PPI : Matériaux bruts	M_110157500 PPI: mat. bruts
5	110*	6	OILPRICEx	Pétrole brut, WTI+Cushing épissé	M_110157273 Prix spot
6	111	6	PPICMM	PPI : Métaux et prod. métalliques	M_110157335 PPI: non ferreux
7	112	1	NAPMPRI	ISM Manufacturier : Indice des prix	M_110157204 NAPM px comm
8	113	6	CPIAUSCL	IPC : Tous les postes	M_110157323 IPC-U: tous
9	114	6	CPIAPPSL	IPC : Habillement	M_110157299 IPC-U: habillement
10	115	6	CPITRNSL	IPC : Transport	M_110157302 IPC-U: transp
11	116	6	CPIMEDSL	IPC : Soins médicaux	M_110157304 IPC-U: médical
12	117	6	CUSR0000SAC	IPC : Produits	M_110157314 IPC-U: prod.
13	118	6	CUUR0000SAD	IPC : Durables	M_110157315 IPC-U: durables
14	119	6	CUSR0000SAS	IPC : Services	M_110157325 IPC-U: services
15	120	6	CPIULFSL	IPC : Hors alimentation	M_110157328 IPC-U: hors alim
16	121	6	CUUR0000SA0L2	IPC : Hors logement	M_110157329 IPC-U: hors logt
17	122	6	CUSR0000SA0L5	IPC : Hors soins médicaux	M_110157330 IPC-U: hors méd
18	123	6	PCEPI	Dép. conso. pers. : Indice chaîné	gmde PCE defl
19	124	6	DDURRG3M086SBEA	Dép. conso. pers. : Biens durables	gmdd PCE defl: dlbes
20	125	6	DNDGRG3M086SBEA	Dép. conso. pers. : Biens non durables	gmddn PCE defl: nondble
21	126	6	DSERRG3M086SBEA	Dép. conso. pers. : Services	gmddcs PCE defl: services

Groupe 8 : Marché boursier

id	tcode	fred	description	gsi	gsi:description
1	80*	5	S&P 500	Indice S&P d'actions ordinaires : composite	M_110155044 S&P 500
2	81*	5	S&P: indust	Indice S&P d'actions ordinaires : industrielles	M_110155047 S&P: indust
3	82*	2	S&P div yield	S&P : rendement de dividendes (actions ordinaires)	N.D. S&P div yield
4	83*	5	S&P PE ratio	S&P : ratio cours/bénéf. (actions ordin.)	N.D. S&P PE ratio

APPENDICE III

HYPERPARAMÈTRES

Tableau III.1 : Hyperparamètres des modèles de régressions

Modèle	Hyperparamètres	Valeur/Plage
Ridge	Coefficient de régularisation (alpha)	[0.05]
	Itérations maximales (max_iter)	[5000]
	Tolérance (tol)	[0.0001]
	Méthode de résolution (solver)	[auto]
Recherche Bayésienne	Coefficient de régularisation (alpha)	[0.01, 1.0]
	Itérations maximales (max_iter)	[1000, 10000]
	Tolérance (tol)	[0.00001, 0.001]
	Méthode de résolution (solver)	[auto, lbfgs]
Recherche par grille	Coefficient de régularisation (alpha)	[0.1, 0.2, 0.3]
	Itérations maximales (max_iter)	[1000, 2000, 3000]
	Méthode de résolution (solver)	[auto]

(a) Ridge

Modèle	Hyperparamètres	Valeur/Plage
AdaBoost	Nombre d'estimateurs (n_estimators)	[500]
	Taux d'apprentissage (learning_rate)	[0.5]
	Fonction de perte (loss)	[exponentielle]
Recherche Bayésienne	Nombre d'estimateurs (n_estimators)	[50, 500]
	Taux d'apprentissage (learning_rate)	[0.01, 1.0]
	Fonction de perte (loss)	[linéaire, quadratique, exponentielle]
Recherche par grille	Nombre d'estimateurs (n_estimators)	[50, 100, 200]
	Taux d'apprentissage (learning_rate)	[0.01, 0.1, 0.5]
	Fonction de perte (loss)	[linéaire, quadratique]

(b) Ada Boost

Modèle	Hyperparamètres	Valeur/Plage
XGBoost	Profondeur maximale (max_depth)	[3, 10]
	Taux d'apprentissage (learning_rate)	[0.01, 0.3]
	Nombre d'estimateurs (n_estimators)	[50, 500]
	Sous-échantillonnage (subsample)	[0.5, 1.0]
	Fraction des colonnes (colsample_bytree)	[0.5, 1.0]
	Régularisation L1 (reg_alpha)	[0.0, 1.0]
	Régularisation L2 (reg_lambda)	[0.0, 1.0]
	Paramètre gamma	[0.0, 0.5]
	Poids des classes (scale_pos_weight)	[1.0, 10.0]
Paramètres de recherche par grille	Profondeur maximale (max_depth)	[3, 5, 10]
	Taux d'apprentissage (learning_rate)	[0.01, 0.1, 0.2]
	Nombre d'estimateurs (n_estimators)	[100, 200, 300]
	Sous-échantillonnage (subsample)	[0.8, 1.0]
	Fraction des colonnes (colsample_bytree)	[0.8, 1.0]
	Régularisation L1 (reg_alpha)	[0.0, 0.1, 0.5]
	Régularisation L2 (reg_lambda)	[0.0, 0.1, 0.5]
	Paramètre gamma	[0.0, 0.1, 0.2]
	Poids des classes (scale_pos_weight)	[1.0, 2.0, 5.0]

(c) XGBoost

Modèle	Hyperparamètres	Valeur/Plage
Extra Trees	Nombre d'estimateurs (n_estimators)	[100]
	Critère (criterion)	[erreur quadratique]
	Échantillons minimum pour division (min_samples_split)	[2]
	Échantillons minimum par feuille (min_samples_leaf)	[1]
	Nombre maximal de caractéristiques (max_features)	[1.0]
	Bootstrap (bootstrap)	[Faux]
	Paramètre de complexité (ccp_alpha)	[0.5]
Recherche Bayésienne	Nombre d'estimateurs (n_estimators)	[50, 300]
	Profondeur maximale (max_depth)	[5, 20]
	Échantillons minimum pour division (min_samples_split)	[2, 10]
	Échantillons minimum par feuille (min_samples_leaf)	[1, 5]
	Nombre maximal de caractéristiques (max_features)	[0.1, 1.0]
	Paramètre de complexité (ccp_alpha)	[0.0, 0.5]
	Bootstrap (bootstrap)	[Vrai, Faux]
Recherche par grille	Nombre d'estimateurs (n_estimators)	[50, 100, 200]
	Critère (criterion)	[erreur quadratique]
	Profondeur maximale (max_depth)	[7, 10]
	Échantillons minimum pour division (min_samples_split)	[2]
	Échantillons minimum par feuille (min_samples_leaf)	[1]
	Nombre maximal de caractéristiques (max_features)	[sqrt]
	Paramètre de complexité (ccp_alpha)	[0.2]

(d) Extra Trees

Tableau III.2 : Hyperparamètres des modèles de classifications

Modèle	Hyperparamètres	Valeur/Plage
Régression logistique Classification	Pénalité (penalty)	[elasticnet]
	Tolérance (tol)	[0.0001]
	Coefficient de régularisation (C)	[10]
	Méthode de résolution (solver)	[saga]
	Itérations maximales (max_iter)	[500]
	Initialisation à chaud (warm_start)	[Vrai]
Recherche Bayésienne	Tolérance (tol)	[0.00001, 0.01]
	Coefficient de régularisation (C)	[0.1, 100.0]
	Méthode de résolution (solver)	[saga]
	Itérations maximales (max_iter)	[100, 1000]
	Initialisation à chaud (warm_start)	[Vrai, Faux]
	Ratio l1 (l1_ratio)	[0.0, 1.0]
Recherche par grille	Tolérance (tol)	[0.0001, 0.001, 0.01]
	Coefficient de régularisation (C)	[1.0, 10.0]
	Itérations maximales (max_iter)	[50, 100, 200]
	Méthode de résolution (solver)	[lbfgs, liblinear]

(a) Régression logistique

Modèle	Hyperparamètres	Valeur/Plage
AdaBoost Classification	Nombre d'estimateurs (n_estimators)	[300]
	Taux d'apprentissage (learning_rate)	[0.1]
	Algorithme (algorithm)	[SAMME]
Recherche Bayésienne	Nombre d'estimateurs (n_estimators)	[50, 500]
	Taux d'apprentissage (learning_rate)	[0.01, 0.3]
	Algorithme (algorithm)	[SAMME]
Recherche par grille	Nombre d'estimateurs (n_estimators)	[50, 100, 200]
	Taux d'apprentissage (learning_rate)	[0.01, 0.05]

(b) Ada Boost Classification

Modèle	Hyperparamètres	Valeur/Plage
XGBoost Classification	Profondeur maximale (max_depth)	[6]
	Taux d'apprentissage (learning_rate)	[0.1]
	Nombre d'estimateurs (n_estimators)	[100]
	Échantillons (subsample)	[0.8]
	Fraction des caractéristiques (colsample_bytree)	[0.8]
	Régularisation L1 (reg_alpha)	[0.1]
	Régularisation L2 (reg_lambda)	[1.0]
	Complexité minimale (gamma)	[0.0]
Recherche Bayésienne	Profondeur maximale (max_depth)	[3, 10]
	Taux d'apprentissage (learning_rate)	[0.01, 0.3]
	Nombre d'estimateurs (n_estimators)	[50, 500]
	Échantillons (subsample)	[0.5, 1.0]
	Fraction des caractéristiques (colsample_bytree)	[0.5, 1.0]
	Régularisation L1 (reg_alpha)	[0.0, 1.0]
	Régularisation L2 (reg_lambda)	[0.0, 1.0]
	Complexité minimale (gamma)	[0.0, 0.5]
Recherche par grille	Profondeur maximale (max_depth)	[3, 5, 10]
	Taux d'apprentissage (learning_rate)	[0.01, 0.1, 0.2]
	Nombre d'estimateurs (n_estimators)	[100, 200, 300]
	Échantillons (subsample)	[0.8, 1.0]
	Fraction des caractéristiques (colsample_bytree)	[0.8, 1.0]
	Régularisation L1 (reg_alpha)	[0.0, 0.1, 0.5]
	Régularisation L2 (reg_lambda)	[0.0, 0.1, 0.5]
	Complexité minimale (gamma)	[0.0, 0.1, 0.2]
	Poids des classes (scale_pos_weight)	[1.0, 2.0, 5.0]

(c) XGBoost Classification

Modèle	Hyperparamètres	Valeur/Plage
Extra Trees Classification	Nombre d'estimateurs (<code>n_estimators</code>)	[100]
	Critère (<code>criterion</code>)	[Gini]
	Profondeur maximale (<code>max_depth</code>)	[5]
	Échantillons minimum pour division (<code>min_samples_split</code>)	[2]
	Échantillons minimum par feuille (<code>min_samples_leaf</code>)	[1]
	Nombre maximal de caractéristiques (<code>max_features</code>)	[Racine carrée]
	Paramètre de complexité (<code>ccp_alpha</code>)	[0.2]
Recherche Bayésienne	Nombre d'estimateurs (<code>n_estimators</code>)	[50, 300]
	Critère (<code>criterion</code>)	[Gini, Entropie]
	Profondeur maximale (<code>max_depth</code>)	[5, 20]
	Échantillons minimum pour division (<code>min_samples_split</code>)	[2, 10]
	Échantillons minimum par feuille (<code>min_samples_leaf</code>)	[1, 5]
	Nombre maximal de caractéristiques (<code>max_features</code>)	[Racine carrée, Log base 2]
	Paramètre de complexité (<code>ccp_alpha</code>)	[0.0, 0.5]
Recherche par grille	Bootstrap (<code>bootstrap</code>)	[Vrai, Faux]
	Nombre d'estimateurs (<code>n_estimators</code>)	[50, 100, 200]
	Critère (<code>criterion</code>)	[Gini, Entropie]
	Profondeur maximale (<code>max_depth</code>)	[7, 10]
	Échantillons minimum pour division (<code>min_samples_split</code>)	[2]
	Échantillons minimum par feuille (<code>min_samples_leaf</code>)	[1]
	Nombre maximal de caractéristiques (<code>max_features</code>)	[Log base 2]
	Paramètre de complexité (<code>ccp_alpha</code>)	[0.1]

(d) Extra Trees Classification

BIBLIOGRAPHIE

- Ardia, D., Bluteau, K., Borms, S. et Boudt, K. (2021). The R Package sentometrics to Compute, Aggregate, and Predict with Textual Sentiment. *Journal of Statistical Software*, 99(2). <https://doi.org/10.18637/jss.v099.i02>
- Avramov, D., Cheng, S. et Metzker, L. (2023). Machine Learning vs. Economic Restrictions: Evidence from Stock Return Predictability. *Management Science*, 69(5), 2587-2619. <https://doi.org/10.1287/mnsc.2022.4449>
- Ballings, M., Van den Poel, D., Hespeels, N. et Gryp, R. (2015). Evaluating multiple classifiers for stock price direction prediction. *Expert Systems with Applications*, 42(20), 7046-7056. <https://doi.org/10.1016/j.eswa.2015.05.013>
- Bañbura, M., Giannone, D. et Reichlin, L. (2010). Large Bayesian vector auto regressions. *Journal of Applied Econometrics*, 25(1), 71-92. <https://doi.org/10.1002/jae.1137>
- Banz, R. W. (1981). The relationship between return and market value of common stocks. *Journal of Financial Economics*, 9(1), 3-18. [https://doi.org/10.1016/0304-405X\(81\)90018-0](https://doi.org/10.1016/0304-405X(81)90018-0)
- Bodie, Z., Kane, A. et Marcus, A. J. (2014). *Investments* (10. ed). Mc-Graw-Hill Education.
- Campbell, J. Y. et Thompson, S. B. (2008). Predicting Excess Stock Returns Out of Sample: Can Anything Beat the Historical Average? *Review of Financial Studies*, 21(4), 1509-1531. <https://doi.org/10.1093/rfs/hhm055>
- Chen, L., Pelger, M. et Zhu, J. (2019). Deep Learning in Asset Pricing. *SSRN Electronic Journal*. <https://doi.org/10.2139/ssrn.3350138>
- Chen, M., Hanauer, M. X. et Kalsbach, T. (2024). Design choices, machine learning, and the cross-section of stock returns. *SSRN Electronic Journal*. <https://doi.org/10.2139/ssrn.5031755>
- Chen, T. et Guestrin, C. (2016). *XGBoost: A Scalable Tree Boosting System*. <https://doi.org/10.48550/ARXIV.1603.02754>
- Cox, D. R. (1958). The Regression Analysis of Binary Sequences. *Journal of the Royal Statistical Society Series B: Statistical Methodology*, 20(2), 215-232. <https://doi.org/10.1111/j.2517-6161.1958.tb00292.x>
- Fama, E. F. (1965). The Behavior of Stock-Market Prices. *The Journal of Business*, 38(1), 34-105.
- Fama, E. F. (1970). Efficient Capital Markets: A Review of Theory and Empirical Work. *The Journal of Finance*, 25(2), 383. <https://doi.org/10.2307/2325486>

- Fama, E. F. et French, K. R. (1992). The Cross-Section of Expected Stock Returns. *The Journal of Finance*, 47(2), 427-465. <https://doi.org/10.1111/j.1540-6261.1992.tb04398.x>
- Fama, E. F. et French, K. R. (2015). A five-factor asset pricing model. *Journal of Financial Economics*, 116(1), 1-22. <https://doi.org/10.1016/j.jfineco.2014.10.010>
- Feng, G., Giglio, S. et Xiu, D. (2020). Taming the Factor Zoo: A Test of New Factors. *The Journal of Finance*, 75(3), 1327-1370. <https://doi.org/10.1111/jofi.12883>
- Fortin-Gagnon, O., Leroux, M., Stevanovic, D. et Surprenant, S. (2022). A large Canadian database for macroeconomic analysis. *Canadian Journal of Economics/Revue canadienne d'économie*, 55(4), 1799-1833. <https://doi.org/10.1111/caje.12618>
- Freund, Y. (2001). An Adaptive Version of the Boost by Majority Algorithm. *Machine Learning*, 43(3), 293-318. <https://doi.org/10.1023/A:1010852229904>
- Freyberger, J., Neuhierl, A. et Weber, M. (2020). Dissecting Characteristics Nonparametrically. *The Review of Financial Studies*, 33(5), 2326-2377. <https://doi.org/10.1093/rfs/hhz123>
- Geurts, P., Ernst, D. et Wehenkel, L. (2006). Extremely randomized trees. *Machine Learning*, 63(1), 3-42. <https://doi.org/10.1007/s10994-006-6226-1>
- Goulet Coulombe, P. et Göbel, M. (2023). Maximally Machine-Learnable Portfolios. *SSRN Electronic Journal*. <https://doi.org/10.2139/ssrn.4428178>
- Green, J. et Zhao, W. (2022). Forecasting earnings and returns: A review of recent advancements. *The Journal of Finance and Data Science*, 8, 120-137. <https://doi.org/10.1016/j.jfds.2022.04.004>
- Gu, S., Kelly, B. et Xiu, D. (2020). Empirical Asset Pricing via Machine Learning. *The Review of Financial Studies*, 33(5), 2223-2273. <https://doi.org/10.1093/rfs/hhaa009>
- Hanauer, M. X. et Kalsbach, T. (2023). Machine learning and the cross-section of emerging market stock returns. *Emerging Markets Review*, 55, 101022. <https://doi.org/10.1016/j.ememar.2023.101022>
- Harvey, C. R., Liu, Y. et Zhu, H. (2016). ... and the Cross-Section of Expected Returns. *Review of Financial Studies*, 29(1), 5-68. <https://doi.org/10.1093/rfs/hhv059>
- Hastie, T., Tibshirani, R. et Friedman, J. (2009). *The Elements of Statistical Learning*. Springer New York. <https://doi.org/10.1007/978-0-387-84858-7>
- Hoerl, A. E. et Kennard, R. W. (1970). Ridge Regression: Biased Estimation for Nonorthogonal Problems. *Technometrics*, 12(1), 55-67. <https://doi.org/10.1080/00401706.1970.10488634>
- Jacobs, H. (2015). What Explains the Dynamics of 100 Anomalies? *SSRN Electronic Journal*. <https://doi.org/10.2139/ssrn.2564706>

- Jern Tat, C., Lin, H. et Mei, Y. (2022). Machine Learning and the Cross-Section of Stock Returns. *SSRN Electronic Journal*. <https://doi.org/10.2139/ssrn.4282614>
- Kahneman, D. et Tversky, A. (1979). Prospect Theory: An Analysis of Decision under Risk. *Econometrica*, 47(2), 263. <https://doi.org/10.2307/1914185>
- Ke, G., Meng, Q., Finley, T., Wang, T., Chen, W., Ma, W., Ye, Q. et Liu, T.-Y. (s. d.). *LightGBM: A Highly Efficient Gradient Boosting Decision Tree*.
- Kozak, S., Nagel, S. et Santosh, S. (2020). Shrinking the cross-section. *Journal of Financial Economics*, 135(2), 271-292. <https://doi.org/10.1016/j.jfineco.2019.06.008>
- Krauss, C., Do, X. A. et Huck, N. (2017). Deep neural networks, gradient-boosted trees, random forests: Statistical arbitrage on the S&P 500. *European Journal of Operational Research*, 259(2), 689-702. <https://doi.org/10.1016/j.ejor.2016.10.031>
- Levy, R. A. (1967). RELATIVE STRENGTH AS A CRITERION FOR INVESTMENT SELECTION. *The Journal of Finance*, 22(4), 595-610. <https://doi.org/10.1111/j.1540-6261.1967.tb00295.x>
- Lintner, J. (1965). The Valuation of Risk Assets and the Selection of Risky Investments in Stock Portfolios and Capital Budgets. *The Review of Economics and Statistics*, 47(1), 13. <https://doi.org/10.2307/1924119>
- López de Prado, M. M. (2018). *Advances in financial machine learning*. Wiley.
- Lundberg, S. et Lee, S.-I. (2017). *A Unified Approach to Interpreting Model Predictions*. arXiv. <https://doi.org/10.48550/ARXIV.1705.07874>
- Malkiel, B. G. (2003). The Efficient Market Hypothesis and Its Critics. *Journal of Economic Perspectives*, 17(1), 59-82. <https://doi.org/10.1257/089533003321164958>
- Markowitz, H. (1952). Portfolio Selection. *The Journal of Finance*, 7(1), 77. <https://doi.org/10.2307/2975974>
- Markowitz, H. M. (1959). *Portfolio Selection: Efficient Diversification of Investments*. Yale University Press. <https://doi.org/10.12987/9780300191677>
- Martínez-Barbero, X., Cervelló-Royo, R. et Ribal, J. (2024). Portfolio Optimization with Prediction-Based Return Using Long Short-Term Memory Neural Networks: Testing on Upward and Downward European Markets. *Computational Economics*. <https://doi.org/10.1007/s10614-024-10604-6>
- McCracken, M. W. et Ng, S. (2015). *FRED-MD: A Monthly Database for Macroeconomic Research*. <https://doi.org/10.20955/wp.2015.012>
- Moritz, B. et Zimmermann, T. (2014). Deep conditional portfolio sorts: The relation between past and future stock returns. *LMU Munich and Harvard University Working paper*.

- Moritz, B. et Zimmermann, T. (2016). Tree-Based Conditional Portfolio Sorts: The Relation between Past and Future Stock Returns. *SSRN Electronic Journal*.
<https://doi.org/10.2139/ssrn.2740751>
- Mossin, J. (1966). Equilibrium in a Capital Asset Market. *Econometrica*, 34(4), 768.
<https://doi.org/10.2307/1910098>
- Nikou, M., Mansourfar, G. et Bagherzadeh, J. (2019). Stock price prediction using DEEP learning algorithm and its comparison with machine learning algorithms. *Intelligent Systems in Accounting, Finance and Management*, 26(4), 164-174.
<https://doi.org/10.1002/isaf.1459>
- Provost, F. et Fawcett, T. (s. d.). *Data Science for Business*.
- Rapach, D. E., Strauss, J. K. et Zhou, G. (2010). Out-of-Sample Equity Premium Prediction: Combination Forecasts and Links to the Real Economy. *Review of Financial Studies*, 23(2), 821-862. <https://doi.org/10.1093/rfs/hhp063>
- Ross, S. A. (1976). The arbitrage theory of capital asset pricing. *Journal of Economic Theory*, 13(3), 341-360. [https://doi.org/10.1016/0022-0531\(76\)90046-6](https://doi.org/10.1016/0022-0531(76)90046-6)
- Sharpe, W. F. (1964). Capital Asset Prices: A Theory of Market Equilibrium under Conditions of Risk. *The Journal of Finance*, 19(3), 425. <https://doi.org/10.2307/2977928>
- Shiller, R. J. (2003). From Efficient Markets Theory to Behavioral Finance. *Journal of Economic Perspectives*, 17(1), 83-104. <https://doi.org/10.1257/089533003321164967>
- Snoek, J., Larochelle, H. et Adams, R. P. (2012). *Practical Bayesian Optimization of Machine Learning Algorithms*. arXiv. <https://doi.org/10.48550/ARXIV.1206.2944>
- Sutiene, K., Schwendner, P., Sipos, C., Lorenzo, L., Mirchev, M., Lameski, P., Kabasinskas, A., Tidjani, C., Ozturkkal, B. et Cerneviene, J. (2024). Enhancing portfolio management using artificial intelligence: literature review. *Frontiers in Artificial Intelligence*, 7, 1371502. <https://doi.org/10.3389/frai.2024.1371502>
- Zhang, X., Wu, L. et Chen, Z. (2021). *Constructing long-short stock portfolio with a new listwise learn-to-rank algorithm*. arXiv. <https://doi.org/10.48550/ARXIV.2104.12484>